

Exercices

Chapitre 5 - Prétraitement des données

Hiver 2025

L'objectif de ces exercices est de réaliser un prétraitement sur un ensemble de données.

Soit l'ensemble de données `carsPreprocessing.xlsx` disponible sur Léa. Ce fichier contient deux feuilles `cars.xls`, le fichier original des données et `carsMod.xls`, un fichier modifié des données que nous allons utiliser pour les exercices du cours.

Exercice 1 : Lecture des données

1. Téléchargez les données du fichier '`carsPreprocessing.xlsx`' et stockez le contenu de la feuille `cars` dans `df` et le contenu de la feuille `carsMod` dans `df1`
2. Déterminez le nombre d'individus et de variables
3. Identifiez le type de chacune des variables

Exercice 2 : Traitement des données manquantes

1. Comptez les individus ayant des données manquantes
2. Affichez les individus ayant des données manquantes
3. Supprimez les individus ayant des données manquantes.
4. Stockez le résultat dans `df1Del`
5. Vérifiez le nombre d'individus et de variables de `df1Del`
6. Remplacez les individus ayant des données manquantes quantitatives par la moyenne (`df1ImputeMean`) et par la médiane (`df1ImputeMedian`)

7. Affichez les résultats d'imputation par les deux stratégies
8. Comparez les résultats aux données réelles (df)
9. Commentez les résultats

Exercice 3 : Traitement des données aberrantes

1. Représentez le diagramme de dispersion de la variable prix en fonction de puissance de l'ensemble de données df
2. Représentez le diagramme en boîte de la variable prix et de la variable puissance
3. Commentez les résultats
4. Détectez les valeurs aberrantes en utilisant un seuil η de 3 et un seuil η de 2
5. Représentez les diagrammes en boîte correspondants
6. Commentez les résultats

Exercice 4 : Normalisation et standardisation

1. Créer un tableau **x** avec la variable cylindree
2. Normalisez la variable **x** en utilisant une mise à l'échelle min-max et stocker le résultat dans **x_minmax**
3. Standardisez la variable **x** et stocker le résultat dans **x_standard**
4. Représentez l'histogramme des variables **x**, **x_minmax** et **x_standard**