

26 Sept 2025

1-) Operations de pre-traitements

2-) Contenu de la presentation.

---

TP: EDA, pre-traitement.  
Questions & Responses

Values manquants

1-) Series  
Enregistré

↳ Imputing  $\Rightarrow$  Strategies de  
Remplacement

→


	x		x		
	x				
	x				

Suppression  $\Rightarrow$  Retrait  $\Rightarrow$  perte  
d'information

Age ← salaire .

Distribution Prob

Normal.



18  
75

25000  
150.000



Standard Scale.  $\rightarrow X \sim \text{Normal}(\mu, \sigma^2)$


Robust Scale  $\rightarrow$  En presence Valeurs Aberrantes.

Min-Max Scale  $\rightarrow$  Distribution est autre  
que Normal

Preliminaires: Déterminer la Distribution de  $X$ .

Σ-sample Input

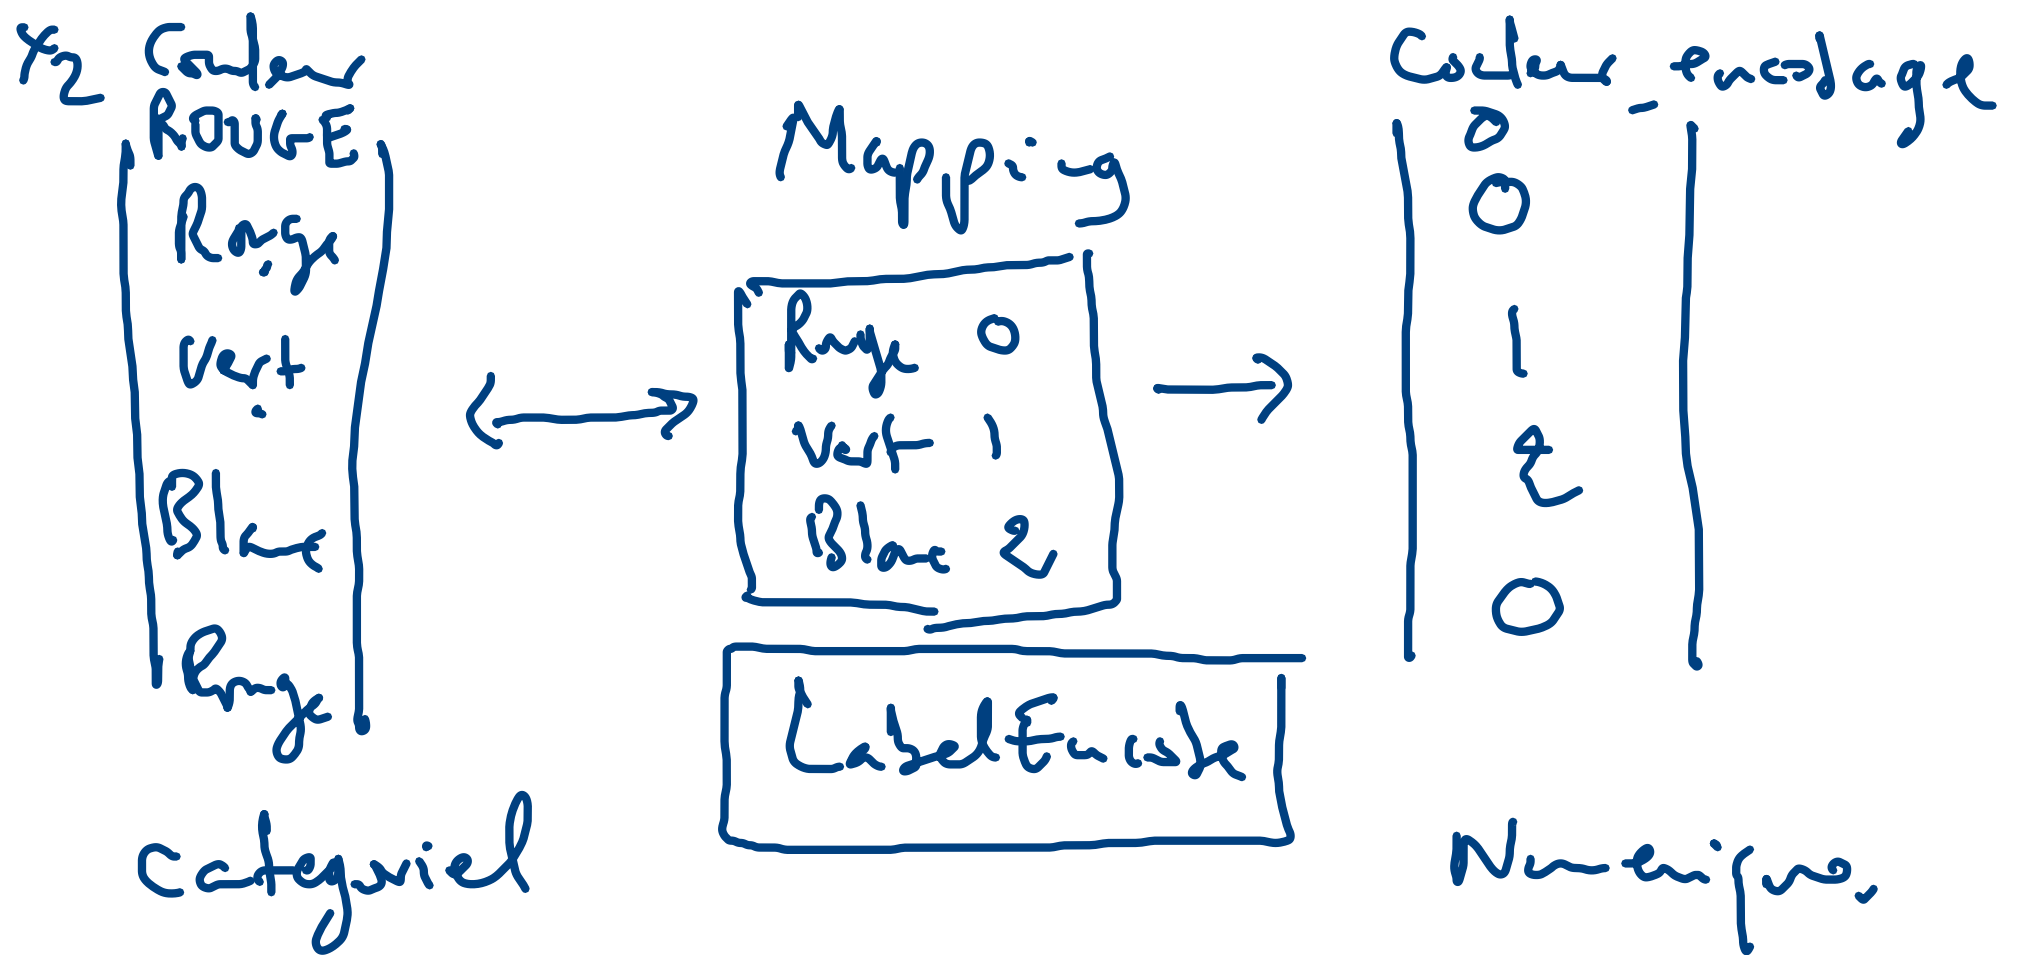
inputting



mean

mean

moyenne  
median.



`df['x2'].map(lambda r: r.upper())`

↙ for `tmp` in `x2`:

`tmp.upper()`

OHE  
one hot  
encoder

~~$x_2$~~   
Range  
Range  
vert  
Blanc  
Blanc  
Range



$x_{2-range}$	$x_{2-vert}$	$x_{2-Blanc}$
1	0	0
1	0	0
0	1	0
0	0	1
0	0	1
1	0	0

Plus de  
Zero.

Zero  
/ / / / /

# Présentation.

15 min - 20 min.

- 1- Présentation du Besoin. 12-15 slides
- 2- Chaine de Dev utilisée.
- 3- Type model et Algo(s) utilisés.
- 4- Métriques obtenues.
- 5- Comparaison et Interprétation des modèles.
- 6- Difficultés rencontrées.
- 7- Compétences acquises.
- 8- Conclusion



Regression

RL.  
Ridge.  
Lasso.

RMSE  
R<sup>2</sup>

Classification

KNN.  
DT  
R.F

Accuracy.  
: Precision.  
:

1-2-3-4-5-6


}

	y
	0
	0
	0
	0
	1

$$0 \rightarrow 4/5 \quad ?$$

$$1 \rightarrow 1/5$$

predict 0 ++  
1



$\Rightarrow$

Resampling du  
Dataset

machine learning  
mastery

