

# Quiz sur l'Analyse Exploratoire des Données (EDA) en Apprentissage Machine

## 1. Comprendre la distribution des données

### Question :

Pourquoi est-il important d'analyser la distribution des données avant d'entraîner un modèle d'apprentissage machine ?

**Réponse :** Cela permet d'identifier d'éventuelles asymétries, tendances ou valeurs extrêmes qui pourraient impacter la performance du modèle.

## 2. Détecter les valeurs manquantes et aberrantes

### Question :

Quelle méthode peut être utilisée pour détecter les valeurs aberrantes dans un jeu de données ?

**Réponse :** La méthode des quartiles (IQR - Interquartile Range), le Z-score, ainsi que des techniques avancées comme Isolation Forest et LOF (Local Outlier Factor).

## 3. Étudier les relations entre les variables

### Question :

Quelle est l'utilité d'une matrice de corrélation dans l'analyse exploratoire des données ?

**Réponse :** Elle permet d'identifier les relations entre différentes variables et de détecter les corrélations fortes qui pourraient influencer la modélisation.

## 4. Détection des biais et déséquilibres des classes

**Question :**

Comment peut-on équilibrer un jeu de données fortement déséquilibré ?

**Réponse :** On peut utiliser l'oversampling (ex : SMOTE) pour augmenter les classes minoritaires, l'undersampling pour réduire la taille des classes majoritaires, ou encore ajuster les poids des classes dans l'algorithme d'apprentissage.

## **5. Analyse des distributions conditionnelles**

**Question :**

Quelle technique peut être utilisée pour comparer la distribution d'une variable continue en fonction d'une variable catégorielle ?

**Réponse :** On peut utiliser les boxplots, les violin plots, ou encore les histogrammes conditionnels.

## **6. Identification de groupes sous-représentés**

**Question :**

Pourquoi est-il important d'identifier les groupes sous-représentés dans un jeu de données ?

**Réponse :** Cela permet d'éviter que le modèle soit biaisé en faveur des classes majoritaires et assure une meilleure généralisation des prédictions.

## **7. Guider la préparation des données**

**Question :**

Quelle est la différence entre la normalisation et la standardisation ?

**Réponse :** La normalisation (MinMaxScaler) met les valeurs dans une plage spécifique (généralement entre 0 et 1), tandis que la standardisation (StandardScaler) centre les données autour de la moyenne avec un écart-type de 1.

## **8. Importance de la qualité des données**

**Question :**

Pourquoi la qualité des données est-elle cruciale dans le développement d'une application d'IA ?

**Réponse :** Des données de mauvaise qualité peuvent introduire du bruit, biaiser les modèles et réduire leur performance et leur capacité à généraliser à de nouvelles données.

## **PARTIE QCM**

### **1. Comprendre la distribution des données**

**Question :**

Quelle méthode permet d'analyser la répartition des valeurs d'une variable ?

- A) Matrice de corrélation
- B) Histogramme
- C) SMOTE
- D) Isolation Forest

**Réponse :** B) Histogramme

### **2. Détecter les valeurs manquantes et aberrantes**

**Question :**

Quelle technique n'est pas utilisée pour gérer les valeurs manquantes ?

- A) Remplacement par la moyenne
- B) Suppression des lignes concernées
- C) PCA
- D) KNN Imputer

**Réponse :** C) PCA

### **3. Étudier les relations entre les variables**

**Question :**

Quel outil est couramment utilisé pour visualiser les relations entre plusieurs variables numériques ?

- A) Boxplot
- B) Heatmap de corrélation
- C) Diagramme en barres
- D) One-hot encoding

**Réponse :** B) Heatmap de corrélation

### **4. Détection des biais et déséquilibres des classes**

**Question :**

Quelle approche permet de rééquilibrer un jeu de données fortement déséquilibré ?

- A) Oversampling avec SMOTE
- B) Réduction de la dimensionnalité
- C) Utilisation des statistiques descriptives
- D) Clustering K-Means

**Réponse :** A) Oversampling avec SMOTE

### **5. Analyse des distributions conditionnelles**

**Question :**

Quel graphique est le plus adapté pour comparer une variable numérique selon une catégorie ?

- A) Scatter plot
- B) Boxplot
- C) Heatmap

D) Pair plot

**Réponse :** B) Boxplot

## **6. Identification de groupes sous-représentés**

**Question :**

Pourquoi faut-il détecter les catégories sous-représentées dans un jeu de données ?

- A) Pour accélérer l'entraînement du modèle
- B) Pour éviter un biais du modèle envers les classes majoritaires
- C) Pour réduire la taille du dataset
- D) Pour rendre les calculs plus complexes

**Réponse :** B) Pour éviter un biais du modèle envers les classes majoritaires

## **7. Guider la préparation des données**

**Question :**

Quel est l'objectif principal de la standardisation des données ?

- A) Transformer les variables catégorielles en numériques
- B) Mettre toutes les valeurs entre 0 et 1
- C) Centrer les données autour de la moyenne avec un écart-type de 1
- D) Supprimer les valeurs aberrantes

**Réponse :** C) Centrer les données autour de la moyenne avec un écart-type de 1

## **8. Importance de la qualité des données**

**Question :**

Quel impact une mauvaise qualité des données peut-elle avoir sur un modèle d'apprentissage machine ?

- A) Améliorer la précision
- B) Accélérer l'entraînement
- C) Introduire du bruit et biaiser les prédictions
- D) Réduire le nombre de variables

**Réponse :** C) Introduire du bruit et biaiser les prédictions