

Transformation et manipulation des données



Dr Khadidja Henni

Séance 2: Anonymisation des données

Plan de la séance

- Introduction
- Pourquoi l'anonymisation est-elle importante ?
- Différence entre anonymisation et pseudonymisation?
- Techniques courantes d'anonymisation

- Laboratoire formatif

Introduction

Introduction à l'anonymisation des données

Qu'est-ce que l'anonymisation ?

L'anonymisation des données est un **processus de transformation** qui vise à rendre les données personnelles **non identifiables**, même par recoupement avec d'autres sources. Cela signifie que **même l'entité ayant accès aux données ne peut plus relier l'information à une personne physique identifiable**.

Par exemple :

Une base contenant des informations médicales où les noms, adresses, numéros de téléphone et identifiants uniques ont été supprimés ou modifiés de manière irréversible.

L'anonymisation va donc **au-delà du simple masquage ou chiffrement**. Elle implique que **la réidentification soit pratiquement impossible**, même en combinant plusieurs jeux de données.

Introduction à l'anonymisation des données

Objectifs de l'anonymisation

- **Protéger la vie privée** des individus concernés (patients, clients, utilisateurs...)
- **Réduire les risques légaux et éthiques** liés à l'utilisation des données sensibles
- **Permettre l'analyse de données** à des fins de recherche, d'innovation ou d'amélioration des services, **sans compromettre la confidentialité**

Un enjeu réglementaire majeur

Avec des réglementations comme :

- **RGPD** (Règlement Général sur la Protection des Données) en Europe
- **HIPAA** (Health Insurance Portability and Accountability Act) aux États-Unis

...les entreprises et institutions ont l'obligation de protéger les données personnelles. **L'anonymisation devient ainsi un outil central pour respecter la loi** tout en exploitant les données de manière responsable.

Introduction à l'anonymisation des données

Exemple simple

Donnée originale	Donnée anonymisée
Alice Martin, 32 ans, Paris	[REDACTED], 30-40 ans, Île-de-France

Pourquoi cette thématique est cruciale aujourd'hui ?

- L'explosion des données collectées (IoT, plateformes en ligne, santé connectée...)
- Les risques croissants de fuites de données (cyberattaques, mauvaises pratiques)
- La nécessité de concilier **innovation fondée sur les données** et **respect des libertés individuelles**

Pourquoi l'anonymisation est-elle importante ?

L'importance de l'anonymisation

Pourquoi l'anonymisation est-elle importante ?

L'anonymisation des données n'est pas un simple choix technique : elle constitue aujourd'hui un **enjeu central de conformité, de cybersécurité et de valorisation responsable des données**. Voici les trois raisons majeures qui justifient son importance.

1. **Respect des réglementations sur la vie privée**
2. **Prévention des fuites et des risques de réidentification**
3. **Cas d'usage : analyse de données sensibles**

L'importance de l'anonymisation

a. Respect des réglementations sur la vie privée

Dans un contexte mondial de **renforcement des lois sur la protection des données**, l'anonymisation est devenue un outil juridique indispensable.

- **Au Québec** : La **Loi 25** (entrée en vigueur progressivement entre 2022 et 2024) impose aux entreprises et organismes publics québécois de :

- Désigner un **responsable de la protection des renseignements personnels**
- Évaluer les risques de confidentialité lors de tout projet de collecte ou d'utilisation de données (ÉFVP)
- Appliquer des principes de **protection dès la conception** (« privacy by design »)
- **Détruire ou anonymiser** les renseignements personnels lorsqu'ils ne sont plus requis aux fins de leur collecte

Ainsi, **l'anonymisation est explicitement mentionnée dans la Loi 25** comme une solution acceptable pour conserver des données à des fins de recherche ou de statistiques, **sans contrevenir à la loi**.

- **Ailleurs dans le monde** :

- **RGPD (Europe)** : les données anonymisées ne sont plus soumises aux restrictions du RGPD (article 26), ce qui facilite leur usage.
- **HIPAA (États-Unis)** : impose l'anonymisation (ou dé-identification) des données de santé pour qu'elles puissent être partagées légalement à des fins de recherche.

En résumé : l'anonymisation **permet de concilier exploitation des données et conformité légale**, en réduisant les obligations légales tout en respectant les droits des personnes.

L'importance de l'anonymisation

b. Prévention des fuites et des risques de réidentification

Les fuites de données sont de plus en plus fréquentes, qu'elles soient dues à :

- des **attaques informatiques** (ex. : ransomwares),
- des **erreurs humaines** (fichiers mal partagés, liens publics),
- ou de mauvaises pratiques internes.

Même si une organisation applique toutes les règles de sécurité, le **risque zéro n'existe pas**.

En rendant les données **non identifiables**, l'anonymisation :

- **réduit drastiquement les conséquences d'une fuite** (aucune donnée personnelle exposée),
- **protège la réputation** de l'organisation,
- **évite des sanctions** financières et pénales,
- et **rassure les clients et les citoyens** sur la gestion de leurs données.

Exemple : En 2016, Netflix a publié un jeu de données anonymisé sur les préférences de visionnement. Des chercheurs ont réussi à réidentifier certaines personnes en croisant ces données avec celles d'IMDb. Cet exemple montre qu'une **anonymisation incomplète ou mal pensée peut échouer**.

L'importance de l'anonymisation

c. Cas d'usage : analyse de données sensibles

De nombreuses organisations souhaitent **tirer parti de leurs données** pour :

- améliorer leurs services,
- développer de nouveaux produits,
- mener des recherches scientifiques ou sociales.

Mais dans des domaines comme la **santé, la finance, l'éducation ou les transports**, les données sont souvent **très sensibles et identifiantes**.

Exemples :

Domaine	Données sensibles	Usage anonymisé
Santé	Dossier patient, diagnostic, traitements	Études cliniques, recherche épidémiologique
Finance	Transactions, scores de crédit, revenus	Modélisation de risque, prévision de défaut
Éducation	Notes, retards, historique scolaire	Analyse de performance, études sociologiques
Transport	Trajets GPS, horaires, passagers	Optimisation du réseau, planification urbaine

L'anonymisation permet de **conserver la valeur analytique des données** tout en protégeant les personnes concernées.

Cela facilite aussi le **partage de données** entre institutions ou avec le public (ex. : open data) sans enfreindre la vie privée.

Différence entre anonymisation et pseudonymisation?

Anonymisation Vs pseudonymisation?

Bien que souvent confondues, **l'anonymisation** et la **pseudonymisation** sont deux techniques **fondamentalement différentes** pour protéger les données personnelles. Leur distinction repose principalement sur la **possibilité (ou non) de réidentifier la personne concernée**.

- Anonymisation : irréversible
- Pseudonymisation : réversible sous certaines conditions
- Comparaison avec un tableau

Anonymisation Vs pseudonymisation?

L'anonymisation : une transformation irréversible

a. L'**anonymisation** consiste à transformer des données personnelles de façon **permanente** afin qu'il soit **impossible, même indirectement, d'identifier une personne**.

- Elle supprime ou modifie les identifiants directs (nom, numéro d'assurance sociale) **et** les identifiants indirects (date de naissance, code postal, etc.).
- Même avec d'autres sources d'information externes, **la réidentification reste hautement improbable**, voire techniquement ou légalement impossible.

Exemple : remplacer les dates précises par des plages (ex. : 1960–1970), regrouper les lieux géographiques par région, supprimer tous les identifiants uniques.

- **Avantages** : les données ne sont plus soumises aux lois sur les renseignements personnels (ex. : RGPD, Loi 25).
- **Inconvénient** : perte partielle de la précision ou de l'utilité analytique.

Anonymisation Vs pseudonymisation?

b. La pseudonymisation : une protection réversible

La **pseudonymisation**, au contraire, consiste à **remplacer les identifiants directs** par des **pseudonymes ou des codes**, mais **en conservant une clé de correspondance** sécurisée ailleurs.

- La donnée reste techniquement **réversible**, si la clé de correspondance est retrouvée.
- Elle protège contre l'accès non autorisé, mais **n'est pas une mesure d'anonymisation complète**.

Exemple : remplacer "Julie Tremblay" par "ID_4728", mais stocker quelque part une table de correspondance qui relie cet identifiant pseudonyme à son identité réelle.

- **Avantages** : préserve l'utilité analytique complète, permet de relier plusieurs jeux de données pour un même individu.
- **Inconvénient** : si la clé est compromise, la réidentification est immédiate. Les données restent considérées comme personnelles au sens légal.

Anonymisation Vs pseudonymisation?

c. Tableau comparatif

Critère	Anonymisation	Pseudonymisation
Réversibilité	Non, irréversible	Oui, réversible avec une clé
Protection légale	Plus élevée (les données ne sont plus personnelles)	Moyenne (les données restent personnelles)
Utilité analytique	Moyenne (perte de granularité)	Élevée (données très précises conservées)
Risque de réidentification	Faible à négligeable	Modéré à élevé selon la sécurité de la clé
Exemples d'usage typiques	Publication de données ouvertes, recherche publique	Études longitudinales, analyses internes
Conformité (RGPD / Loi 25)	Données exemptées de la loi	Données toujours soumises à la loi

- L'**anonymisation** est idéale pour **publier ou partager des données** sans risque, mais elle demande des transformations lourdes et réduit parfois la précision.
- La **pseudonymisation** est utile dans un cadre **interne ou temporaire**, où il est encore nécessaire de relier les données à une personne, mais sous contrôle strict.

Attention : seul un processus d'**anonymisation robuste** permet de sortir les données du champ d'application des lois sur la protection des renseignements personnels.

Techniques courantes d'anonymisation

Techniques courantes d'anonymisation

4. Techniques courantes d'anonymisation

L'anonymisation repose sur un **ensemble de méthodes** qui visent à empêcher toute réidentification directe ou indirecte d'un individu à partir des données. Ces techniques peuvent être combinées pour un niveau de protection renforcé, en fonction du contexte d'usage.

1. **Masquage des données** (data masking)
2. **Perturbation** (ajout de bruit, randomisation)
3. **Agrégation** (regroupement des données)
4. **Génération de données synthétiques**
5. **Suppression directe des identifiants**

Techniques courantes d'anonymisation

1. Masquage des données (data masking)

Pourquoi ?

- Pour **cacher les données sensibles** tout en conservant leur structure (ex. : pour des tests ou des démos), sans modifier leur format ni leur type.

Principe

- On **remplace les vraies données par des symboles ou des valeurs factices**, mais en gardant le format d'origine (nombre de caractères, ponctuation). Très utilisé pour les noms, numéros de cartes, adresses e-mail, etc.

Exemple

Une entreprise souhaite transmettre un fichier client à des développeurs pour tester une application. Les vrais numéros de carte bancaire ne doivent **jamais être exposés**, mais les développeurs doivent tester des champs correctement formatés.

Client	Carte bancaire
Alice	4539 1488 0343 6467

Client	Carte bancaire
Alice	**** * 6467

Techniques courantes d'anonymisation

1. Masquage des données (data masking)

```
import pandas as pd

# Données d'exemple
df = pd.DataFrame({
    'Client': ['Alice', 'Bob'],
    'Carte bancaire': ['4539 1488 0343 6467', '5500 0000 0000 0004']
})

# Masquage partiel
def masquer_cb(cb):
    return '**** *' + cb[-4:]

df['Carte masquée'] = df['Carte bancaire'].apply(masquer_cb)
print(df[['Client', 'Carte masquée']])
```

	Client	Carte masquée
0	Alice	**** * 6467
1	Bob	**** * 0004

Techniques courantes d'anonymisation

2. Perturbation (ajout de bruit, randomisation)

Pourquoi ?

Pour **cacher les valeurs exactes** tout en **préservant les tendances générales**. C'est utile lorsque les valeurs individuelles sont sensibles (revenus, santé), mais que l'analyse statistique reste pertinente.

Principe

On **ajoute un bruit aléatoire contrôlé** (souvent gaussien) aux données numériques. L'objectif est de **rendre impossible la re-identification d'un individu** sans détruire les moyennes et corrélations.

Exemple

Dans une base de données RH, on veut publier des statistiques de salaires, mais sans exposer les salaires exacts des employés.

Avant :

Employé	Salaire
Alice	55000

Après (avec ± 5 % d'erreur) :

Employé	Salaire perturbé
Alice	57321

Techniques courantes d'anonymisation

2. Perturbation (ajout de bruit, randomisation)

```
import numpy as np

df = pd.DataFrame({'Employé': ['Alice', 'Bob'], 'Salaire': [55000, 62000]})

# Perturbation ±5%
def perturber(salaire):
    bruit = np.random.normal(0, 0.05 * salaire) # 5% de bruit
    return round(salaire + bruit)

df['Salaire perturbé'] = df['Salaire'].apply(perturber)
print(df)
```

	Employé	Salaire	Salaire perturbé
0	Alice	55000	56405
1	Bob	62000	65323

Techniques courantes d'anonymisation

3. Agrégation (regroupement des données)

Pourquoi ?

Pour **réduire la précision des données sensibles**. Cela empêche la ré-identification d'un individu précis tout en conservant une vue globale (ex. : par groupe d'âge, revenu, localisation).

Principe

On **regroupe les valeurs individuelles en classes ou tranches** (ex. âge : 20–30 ans). Cela rend impossible l'identification exacte d'une personne.

Exemple

Un hôpital veut partager des données sur l'âge des patients sans montrer l'âge exact.

Avant :

Patient	Âge
Alice	24

Après (avec ± 5 % d'erreur) :

Patient	Tranche d'âge
Alice	20–30

Techniques courantes d'anonymisation

3. Agrégation (regroupement des données)

```
df = pd.DataFrame({'Patient': ['Alice', 'Bob'], 'Âge': [24, 38]})

# Tranches d'âge
bins = [0, 20, 30, 40, 50, 60]
labels = ['<20', '20-30', '30-40', '40-50', '50-60']

df['Tranche d'âge'] = pd.cut(df['Âge'], bins=bins, labels=labels)
print(df[['Patient', 'Tranche d'âge']])
```

	Patient	Tranche d'âge
0	Alice	20-30
1	Bob	30-40

Techniques courantes d'anonymisation

4. Génération de données synthétiques

Pourquoi ?

Pour **remplacer entièrement les données réelles** par des données **fictives mais statistiquement similaires**, permettant de travailler sans danger de divulgation.

Principe

On **entraîne un modèle** (génératif ou probabiliste) sur les vraies données, puis on **génère de nouvelles données** imitant leurs distributions. C'est une approche très avancée, utilisée quand la confidentialité est critique (ex. santé, finances).

Exemple

Créer un jeu de données synthétique de patients à partir d'un ensemble réel.

Techniques courantes d'anonymisation

4. Génération de données synthétiques

```
from sklearn.datasets import make_classification
import pandas as pd
import numpy as np

# Génération
X, y = make_classification(n_samples=100, n_features=2, n_informative=2,
                          n_redundant=0, n_clusters_per_class=1, random_state=42)

df = pd.DataFrame(X, columns=['Âge_synthétique', 'Poids_synthétique'])
df['Sexe'] = np.where(y == 1, 'F', 'M')

# Transformation réaliste
df['Âge_synthétique'] = (df['Âge_synthétique'] * 10 + 40).round()
df['Poids_synthétique'] = (df['Poids_synthétique'] * 15 + 65).round()

print(df.head())
```

	Âge_synthétique	Poids_synthétique	Sexe
0	52.0	54.0	M
1	47.0	44.0	M
2	65.0	103.0	F
3	46.0	45.0	M
4	46.0	45.0	M

Techniques courantes d'anonymisation

5. Suppression des identifiants (Direct Identifier Removal)

Pourquoi ?

Parce que certaines données sont **directement identifiantes** (nom, téléphone, numéro de sécurité sociale). Leur **suppression est le premier réflexe** pour anonymiser un jeu de données.

Principe

On **supprime entièrement** les colonnes contenant des identifiants directs. Toutefois, cela **ne suffit pas** si les données indirectes permettent encore une ré-identification croisée.

Exemple

Une université partage une base d'étudiants pour une étude, sans inclure noms ni e-mails.

Avant :

Nom	Email	Âge	Ville
Alice	alice@email.com	23	Paris

Après (avec ± 5 % d'erreur) :

Âge	Ville
23	Paris

Techniques courantes d'anonymisation

5. Suppression des identifiants (Direct Identifier Removal)

```
df = pd.DataFrame({  
    'Nom': ['Alice', 'Bob'],  
    'Email': ['alice@email.com', 'bob@email.com'],  
    'Âge': [23, 45],  
    'Ville': ['Paris', 'Lyon']  
})  
  
# Suppression  
df_anonyme = df.drop(columns=['Nom', 'Email'])  
print(df_anonyme)
```

	Âge	Ville
0	23	Paris
1	45	Lyon

D'autres techniques d'anonymisation

6. Confidentialité différentielle (Differential Privacy)

Pourquoi ?

Pour **quantifier précisément le risque de ré-identification** lorsqu'on interroge une base de données. C'est l'approche la plus rigoureuse utilisée aujourd'hui dans la recherche et l'industrie (ex. : Apple, Google, Facebook).

Principe

On garantit qu'un individu ne peut pas être identifié, **même en connaissant tous les autres enregistrements**. Cela se fait en ajoutant du **bruit calibré mathématiquement** (ex. bruit de Laplace ou gaussien) à des agrégats ou à l'apprentissage d'un modèle.

D'autres techniques d'anonymisation

7. k-anonymat, l-diversité et t-closeness

Ce sont des **techniques formelles basées sur des garanties statistiques**.

1. **k-anonymat** : Chaque enregistrement est rendu **indiscernable parmi au moins k autres** selon les quasi-identifiants (âge, sexe, code postal, ville, etc.).
Ex. : Si $k=5$, alors chaque combinaison d'âge/ville doit apparaître **au moins 5 fois**.
2. **l-diversité** : Pour éviter que toutes les personnes d'un même groupe aient la même sensibilité (ex : même maladie), on impose que chaque groupe ait **l valeurs sensibles différentes**.
3. **t-closeness**: Renforce l-diversité en **comparant la distribution statistique** de la valeur sensible dans chaque groupe à celle de la population globale.

Mise en œuvre

Ces méthodes sont intégrées dans des outils spécialisés comme :

- ARX anonymization tool
- Amnesia (open-source, interface web pour le k-anonymat)

D'autres techniques d'anonymisation

8. Apprentissage fédéré (Federated Learning)

Pourquoi ?

Pour **analyser les données sans jamais les centraliser**. Chaque utilisateur garde ses données localement, et seul le **modèle global est partagé**.

Principe

Les modèles sont **entraînés localement** (par ex. sur téléphone ou hôpital), puis **agrégés de manière sécurisée** pour obtenir un modèle global sans jamais exposer les données.

Exemples

Détection de mots-clés sur téléphone Android (Gboard)

Analyse médicale répartie entre plusieurs hôpitaux

Bibliothèques : [Flower](#), TensorFlow Federated

D'autres techniques d'anonymisation

8. Apprentissage génératif avec contraintes de confidentialité

Pourquoi ?

Pour générer des données synthétiques **anonymisées** mais **utilisables pour l'IA**, tout en intégrant des garanties de confidentialité.

Principe

On utilise des modèles comme les **GANs avec bruit différentiel**, ou des **VAEs conditionnels** entraînés avec des techniques de régularisation adaptées.

Exemples :

- **DP-GAN** : GAN + confidentialité différentielle
- **PATE-GAN** : GAN entraîné sur des votes de modèles « enseignants » anonymes

D'autres techniques d'anonymisation

Technique	Protection	Utilisation typique
Confidentialité différentielle	Mathématiquement prouvée	API, modèles, requêtes analytiques
k-anonymat, l-diversité	Statistique	Bases tabulaires structurées
Apprentissage fédéré	Données non transmises	Applications mobiles, santé distribuée
GAN synthétique + DP	Données fictives + garanties	Partage sécurisé d'ensembles massifs

Risques liés à une mauvaise anonymisation

Risques liés à une mauvaise anonymisation

Même après avoir supprimé les identifiants directs (nom, téléphone...), **les données peuvent rester vulnérables** si l'anonymisation est incomplète ou mal appliquée. Voici les principaux risques :

1. Ré-identification par recoupement (Linkage Attack)

Qu'est-ce que c'est ?

La **ré-identification** se produit lorsqu'un individu peut être retrouvé en **croisant plusieurs sources de données**. Les attributs comme **âge, sexe, code postal** ou profession sont appelés **quasi-identifiants** : ils **ne sont pas uniques** mais peuvent l'être **en combinaison**.

Exemple classique

Un ensemble de données anonymisées contient :

Sexe	Âge	Code postal
F	29	12345

Un attaquant peut croiser cela avec un registre électoral public, où l'on trouve les personnes âgées de 29 ans vivant à 12345. Si une seule correspond, l'identification est réussie.

Le chercheur Latanya Sweeney a montré que **87 % des Américains** peuvent être identifiés par la combinaison **âge + sexe + code postal**.

Risques liés à une mauvaise anonymisation

2. Attaque par corrélation ou inférence (Attribute Disclosure)

Même sans retrouver le nom, on peut **deviner une information sensible**.

Exemple

Dans un jeu de données médicales :

Code postal	Âge	Maladie
12345	53	VIH

Si on sait qu'une seule personne de 53 ans habite ce code postal, **on déduit sa maladie**, même si son nom est supprimé.

3. Attaque par fréquence (Frequency Attack)

Principe: Si certaines valeurs sont **très fréquentes** dans les données (ex : maladie « grippe »), un attaquant peut **deviner** à partir de distributions connues.

Risques liés à une mauvaise anonymisation

4. Fuites par mauvaise pseudonymisation

Le simple remplacement du nom par un identifiant (ex : user_001) **ne suffit pas**, car si cet identifiant est réutilisé ailleurs, il peut être recoupé.

Exemple

- Base A : user_001 → maladie : cancer
- Base B : user_001 → nom : Alice

Même si les deux jeux sont séparés, **l'identifiant est la faille.**

Risques liés à une mauvaise anonymisation

Exemples célèbres de failles d'anonymisation

- **Cas Netflix (2006):**
Netflix a publié des **évaluations anonymisées** de films pour un concours de recommandation.
Des chercheurs ont **recroisé les notes et dates** avec IMDb, permettant de **ré-identifier plusieurs utilisateurs**, dont un employé de Netflix.
- **Cas AOL (2006)**
AOL a publié les **requêtes anonymisées** de 650 000 utilisateurs.
Certaines personnes ont été **reconnues** simplement à partir des recherches effectuées (ex : adresse, nom tapé...).
- **Cas Strava (2018)**
La plateforme de sport Strava a publié une **carte thermique mondiale** d'activités sportives.
Des utilisateurs ont identifié des **bases militaires secrètes** (ex : en Afghanistan) à partir de l'activité des soldats.

Risques liés à une mauvaise anonymisation

Que retenir ?

Une anonymisation mal faite est **pire qu'aucune anonymisation** :

- Elle donne un **faux sentiment de sécurité**.
- Elle peut conduire à des violations **juridiques** (ex. : RGPD).
- Elle **n'empêche pas les recoupements** par des attaquants motivés.

→ **Il est donc crucial d'utiliser des techniques solides** : k-anonymat, confidentialité différentielle, données synthétiques, etc.

Laboratoire formatif

Laboratoire formatif

Anonymisation des données avec titanic3.csv

Objectifs

- Identifier les attributs sensibles du jeu de données Titanic.
- Appliquer les principales techniques d'anonymisation : suppression, masquage, agrégation, perturbation, pseudonymisation, génération de données.
- Comprendre l'impact de chaque méthode sur la confidentialité et l'utilité des données.

Jeu de données : titanic3.csv

Vous devez charger le fichier titanic3.csv et appliquer les techniques d'anonymisation suivantes :

1. Suppression des identifiants directs : Supprimez les colonnes contenant des identifiants directs (par exemple : name, ticket, cabin). Justifiez vos choix.
2. Masquage partiel
 - Masquez la colonne ticket en ne gardant que les 3 derniers caractères visibles.
 - Masquez la colonne home.dest en ne gardant que la ville ou la dernière partie de l'adresse (ex. : "New York").

Laboratoire formatif

3. Agrégation (binning)

Regroupez la colonne age en 5 tranches anonymes :

- 0–12 (enfant)
- 13–18 (ado)
- 19–35 (jeune adulte)
- 36–60 (adulte)
- 60+ (senior)

Ajoutez une nouvelle colonne age_group.

4. Perturbation aléatoire

- Ajoutez un bruit aléatoire ($\pm 10\%$) à la colonne fare pour éviter la ré-identification tout en conservant une structure exploitable pour l'analyse.

5. Pseudonymisation

a. Créez une pseudonymisation simple :

- Attribuez un identifiant numérique unique à chaque passager (par exemple : P0001, P0002, etc.).
 - Stockez les correspondances dans une table à part (dictionnaire ou DataFrame).
-
- Quelle technique a le plus altéré l'utilisabilité des données ?
 - Si vous deviez publier ce jeu anonymisé, quelles colonnes garderiez-vous ? Pourquoi ?