

Transformation et manipulation de données



Dr Khadidja Henni

Séance 7

Réduction de la dimension-
(méthodes supervisées)

Plan de cours

- Pourquoi la réduction de la dimension des données
- Sélection d'attributs
- LDA
- Laboratoire formatif

Réduction de la dimension des données

Pourquoi la réduction de dimensions?

- Il existe plusieurs raisons pour **réduire le nombre de dimensions (de caractéristiques)** des données dans une phase de **prétraitement**.
 - ☞ **L'information utile** pour la classification/régression peut être **noyée dans un océan de données et de mesures**.
 - ☞ **La complexité des algorithmes** d'apprentissage grandit avec le nombre d'attributs d et de données n .
 - ☞ Lorsqu'on détermine qu'un **attribut n'est pas utile** pour notre apprentissage, on s'épargne le temps de le calculer ou de le mesurer sur un objet.

Pourquoi la réduction de dimensions?

- 👉 Lorsque les données peuvent être **expliquées** avec peu d'attributs (**observés ou cachées**):
 - ⇒ On permet en général une meilleure **généralisation** du processus d'apprentissage.
- 👉 Permet de décrire le processus de **génération de données** et **d'extraction de connaissances** de manière plus simple.
- 👉 Lorsque des données peuvent être représentées par quelques dimensions sans perte d'information, on peut les **visualiser** et les **analyser** de manière plus facile.
- 👉 Réduire l'espace de stockage.

Méthodes de réduction de dimensions

- Il existe **deux approches** principales pour réduire le nombre de dimensions des données.

☞ **Sélection d'attributs:**

On s'intéresse à **sélectionner m attributs parmi d** qui donneront l'information requise pour l'apprentissage ($m < d$). On doit donc rejeter $(d - m)$ attributs.

☞ **Extraction d'attributs:**

On s'intéresse à **trouver un nouvel ensemble de m attributs** qui donneront l'information requise pour l'apprentissage. Ces méthodes peuvent être **supervisées** ou **non supervisées**.

Sélection d'attributs

Principe de sélection d'attributs

- Trouver le meilleur sous-ensemble (minimal) d'attributs pour construire une régression/classification précise.
- Une fois un sous-ensemble d'attributs sélectionné, on rejette les autres attributs non sélectionnés.
- En ayant d attributs au départ, Il existera $(2^d - 1)$ sous-ensembles possibles d'attributs qu'on peut former (ex. avec $d = 10$, on aura 2^{10} sous-ensembles).
- En ayant une fonction d'erreur, on ne peut tester rapidement toutes les combinaisons que si d est relativement petit.

Méthodes de sélection d'attributs

- Soit $\mathcal{A} = \{x_1, x_2, \dots, x_d\}$ l'ensemble des d attributs dont nous disposons au départ pour les données, et soit S les attributs sélectionnés.
- Soit $E(S)$ l'erreur de validation produite en utilisant les attributs de S pour faire la classification/régression.
- Il existe deux méthodes de sélection d'attributs:
 - ☞ Sélection **en avant** d'attributs (i.e. par ajout).
 - ☞ Sélection **en arrière** d'attributs (i.e. par élimination).

Méthodes de sélection d'attributs

Sélection **en avant** d'attributs (i.e. par ajout).

☞ Commencer par **un ensemble vide d'attributs** $S = \emptyset$.

☞ **Ajouter** à chaque étape l'attribut x_j qui décroît le plus **l'erreur de validation**: $S \leftarrow S \cup \{x_j\}$,
où:

$$x_j = \operatorname{argmin}_r (E(S \cup \{x_r\}))$$

☞ Arrêter le processus de sélection quand l'erreur de validation $E(S)$ devient **stable** ou **croissante**.

Méthodes de sélection d'attributs

Sélection **en arrière** d'attributs (i.e. par élimination).

☞ Commencer par **un ensemble de tous les attributs**:

$$S = \{x_1, x_2, \dots, x_n\}$$

☞ **Éliminer** à chaque étape l'attribut x_j qui décroît le plus **l'erreur de validation**:
 $S \leftarrow S - \{x_j\}$.

$$x_j = \operatorname{argmin}_r (E(S - \{x_r\}))$$


☞ **Arrêter** quand l'erreur de validation $E(S)$ devient **stable** ou **croissante**.

Etude d'un exemple

Exemple:

- Pour les données IRIS, nous avons $n = 150$ données $d = 4$ attributs $\{x_1, x_2, x_3 \text{ et } x_4\}$.
 - On utilise la K -moyenne pour le regroupement.
 - En utilisant un attribut à la fois, les erreurs de validation obtenue pour les attributs x_1, x_2, x_3 et x_4 sont 0.24, 0.43, 0.08 et 0.06, respectivement.
- 👉 Nous sélectionnons alors x_4 comme 1^{er} attribut.


Etude d'un exemple



Etude d'un exemple

- En ajoutant un 2^e attribut, les erreurs de validation obtenues avec les couples (x_1, x_4) , (x_2, x_4) et (x_3, x_4) sont 0.13, 0.08 et 0.04, respectivement.

➡ Nous sélectionnons alors x_3 comme 2^e attribut.



Conclusions sur la sélection d'attributs

- En ajoutant un 3^e attribut, les précisions obtenues avec les triplets (x_1, x_3, x_4) et (x_2, x_3, x_4) sont égales à 0.06.

👉 On ne rajoute pas de 3^e attribut, car l'erreur de validation est plus grande avec 3 attributs qu'avec 2 attributs.

Limitation:

- Pour certaines applications (ex. reconnaissance faciale), la sélection individuelle d'attributs (ex. pixels) n'est pas très discriminative pour la classification.

👉 Solution : extraction d'attributs.

Extraction d'attributs:

Principe d'extraction d'attributs

- Plusieurs techniques existent pour l'extraction de nouveaux d'attributs dans un ensemble de données.
- Les **méthodes de projection** sont parmi les plus importantes pour l'extraction d'attributs.
- Ces méthodes essayent d'extraire **m attributs** ($m < d$) de l'espace original à d dimensions, de sorte qu'il y a **une perte minimale d'information** sur la structure des données.
- Les méthodes les plus populaires sont l'analyse à **composantes principales** (ACP), **l'analyse discriminante** (AD), **l'analyse factorielle** (AF), **analyse de corrélation** (AC), etc.

Analyse discriminante linéaire (ADL)



Ronald Aylmer Fisher : (17 Février 1890 – 29 Juillet 1962)

Analyse discriminante linéaire (ADL)

- L'ACP est une méthode qui réduit la dimensionnalité des données en préservant l'information de variance.
- Lorsqu'on a besoin de l'information de classification, l'ACP ne possède pas de mécanisme pour l'encoder.
- L'analyse discriminante linéaire (ADL) est une méthode qui permet de réduire la dimension des données en préservant la plus forte discrimination entre des classes.
- Contrairement à l'ACP, l'ADL est une méthode supervisée.

Analyse discriminante linéaire (ADL)

- Soit une classification à $K = 2$ classes (C_1 et C_2).
- Soit $\mathcal{D} = \{(\mathbf{x}^{(1)}, y^{(1)}), (\mathbf{x}^{(2)}, y^{(2)}), \dots, (\mathbf{x}^{(n)}, y^{(n)})\}$ un ensemble de n données où $y^{(i)} = 1$ si $\mathbf{x}^{(i)} \in C_1$ et $y^{(i)} = 0$ si $\mathbf{x}^{(i)} \in C_2$.
- On veut trouver une direction de projection $\mathbf{v}$ telle que $\|\mathbf{v}\| = 1$ et $z = \mathbf{v}^T \mathbf{x}$ a le maximum de séparation entre les classes C_1 et C_2 .
- Soient $\boldsymbol{\mu}^{(1)}$ et $\boldsymbol{\mu}^{(2)}$ les moyennes des données dans les classes C_1 et C_2 , respectivement. Soit $m_1, m_2 \in \mathbb{R}$ les moyennes des classes après la projection des données sur $\mathbf{v}$.

Analyse discriminante linéaire (ADL)

- Quelle est la direction de projection $\mathbf{v}$ qui **maximisera la discrimination** entre les deux classes C_1 et C_2 ?


Exemple: (nombre de dimensions $d = 2$)

$$\boldsymbol{\mu}^{(1)} = \begin{bmatrix} -3 \\ 1 \end{bmatrix}$$

$$\boldsymbol{\mu}^{(2)} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$


$$\mathbf{S}^{(1)} = \begin{bmatrix} 4 & 3 \\ 3 & 3 \end{bmatrix}$$

$$\mathbf{S}^{(2)} = \begin{bmatrix} 4 & 3 \\ 3 & 3 \end{bmatrix}$$



Analyse discriminante linéaire (ADL)

- Soient m_1 et m_2 les moyennes des données de C_1 et C_2 après leurs projections sur $\mathbf{v}$ et s_1 et s_2 leurs variances.



Analyse discriminante linéaire (ADL)

- On remarquera que:

$$m_1 = \frac{\sum_{i=1}^n \mathbf{v}^T \mathbf{x}^{(i)} y^{(i)}}{\sum_{i=1}^n y^{(i)}} = \mathbf{v}^T \boldsymbol{\mu}^{(1)}$$

$$m_2 = \frac{\sum_{i=1}^n \mathbf{v}^T \mathbf{x}^{(i)} (1 - y^{(i)})}{\sum_{i=1}^n (1 - y^{(i)})} = \mathbf{v}^T \boldsymbol{\mu}^{(2)}$$

$$s_1^2 = \sum_{i=1}^n (\mathbf{v}^T \mathbf{x}^{(i)} - m_1)^2 y^{(i)}$$

$$s_2^2 = \sum_{i=1}^n (\mathbf{v}^T \mathbf{x}^{(i)} - m_2)^2 (1 - y^{(i)})$$

Analyse discriminante linéaire (ADL)

- La direction $\mathbf{v}$ qui maximise la discrimination entre C_1 et C_2 est celle qui maximise la quantité:

$$J(\mathbf{v}) = \frac{(m_1 - m_2)^2}{s_1^2 + s_2^2}$$

- Le terme $(m_1 - m_2)^2$ peut être réécrit comme suit :

$$\begin{aligned}(m_1 - m_2)^2 &= (\mathbf{v}^T \boldsymbol{\mu}^{(1)} - \mathbf{v}^T \boldsymbol{\mu}^{(2)})^2 \\ &= \mathbf{v}^T (\boldsymbol{\mu}^{(1)} - \boldsymbol{\mu}^{(2)}) (\boldsymbol{\mu}^{(1)} - \boldsymbol{\mu}^{(2)})^T \mathbf{v} \\ &= \mathbf{v}^T \mathbf{S}_{inter} \mathbf{v}\end{aligned}$$

- On appelle $\mathbf{S}_{inter}$ la matrice de variance **inter-classes**.

Analyse discriminante linéaire (ADL)

- Par ailleurs, on a:

$$\begin{aligned} s_1^2 &= \frac{1}{n_1} \sum_{i=1}^n (\mathbf{v}^T \mathbf{x}^{(i)} - m_1)^2 y^{(i)} \\ &= \frac{1}{n_1} \sum_{i=1}^n (\mathbf{v}^T \mathbf{x}^{(i)} - m_1)(\mathbf{v}^T \mathbf{x}^{(i)} - m_1)^T y^{(i)} \\ &= \frac{1}{n_1} \sum_{i=1}^n \mathbf{v}^T (\mathbf{x}^{(i)} - \boldsymbol{\mu}^{(1)})(\mathbf{x}^{(i)} - \boldsymbol{\mu}^{(1)})^T \mathbf{v} y^{(i)} \\ &= \mathbf{v}^T \mathbf{S}_1 \mathbf{v} \end{aligned}$$

où $\mathbf{S}_1$ la matrice de variance intra-classe de $\mathcal{C}_1$.

Analyse discriminante linéaire (ADL)

- De même, on définira par $\mathbf{S}_2$ la matrice intra-classe de $\mathcal{C}_2$.
- La variance totale intra classe après projection est:

$$\begin{aligned} s_1^2 + s_2^2 &= \mathbf{v}^T \mathbf{S}_1 \mathbf{v} + \mathbf{v}^T \mathbf{S}_2 \mathbf{v} \\ &= \mathbf{v}^T (\mathbf{S}_1 + \mathbf{S}_2) \mathbf{v} \\ &= \mathbf{v}^T \mathbf{S}_{intra} \mathbf{v} \end{aligned}$$

- La fonction à maximiser sur $\mathbf{v}$ st alors donnée par:

$$J(\mathbf{v}) = \frac{\mathbf{v}^T \mathbf{S}_{inter} \mathbf{v}}{\mathbf{v}^T \mathbf{S}_{intra} \mathbf{v}}$$

Analyse discriminante linéaire (ADL)

- Après la dérivation de $J(\mathbf{v})$ par rapport à $\mathbf{v}$, on obtient:

$$\mathbf{v} \approx \mathbf{S}_{intra}^{-1}(\boldsymbol{\mu}^{(1)} - \boldsymbol{\mu}^{(2)})$$

- Pour notre exemple


$$\mathbf{S}_{intra} = \mathbf{S}_1 + \mathbf{S}_2 = 2 \begin{bmatrix} 4 & 3 \\ 3 & 3 \end{bmatrix}$$

$$\Rightarrow \mathbf{S}_{intra}^{-1} \approx \begin{bmatrix} 0.5 & -0.50 \\ -0.5 & 0.67 \end{bmatrix}$$

$$\mathbf{v} = \mathbf{S}_{intra}^{-1}(\boldsymbol{\mu}^{(2)} - \boldsymbol{\mu}^{(1)}) = \begin{bmatrix} 0.5 & -0.50 \\ -0.5 & 0.67 \end{bmatrix} \times \begin{bmatrix} 4 \\ -3 \end{bmatrix} = \begin{bmatrix} 3.5 \\ -4 \end{bmatrix}$$

Analyse discriminante linéaire (ADL)

- Le vecteur $\mathbf{v}$ obtenu est en effet celui désiré.



Analyse discriminante linéaire (ADL)

- **Calcul des vecteurs propres et valeurs propres** : La première étape de l'algorithme LDA est de calculer les matrices de dispersion inter-classe et intra-classe, et trouver les vecteurs et les valeurs propres des matrices de dispersion (S).
- **Sélection des vecteurs propres** : Les vecteurs propres sont triés par ordre décroissant de leurs valeurs propres correspondantes. Ces vecteurs propres définissent les directions qui maximisent la séparation entre les classes. Pour une réduction de dimension, vous choisissez les k premiers vecteurs propres, où k est le nombre de dimensions souhaité .
- **Projection des données** : Une fois les vecteurs propres pertinents sélectionnés, vous pouvez projeter les données d'origine sur ces vecteurs pour obtenir de nouvelles caractéristiques. Cela se fait en multipliant les données d'origine par une matrice contenant les vecteurs propres sélectionnés.
- **Extraction des caractéristiques pertinentes** : Les nouvelles caractéristiques obtenues après la projection sont les caractéristiques extraites que vous utiliserez pour la classification ou toute autre tâche de machine learning. Ces caractéristiques sont censées mieux représenter les variations entre les classes par rapport aux caractéristiques originales.

Laboratoire formatif

Laboratoire formatif

- Utilisez le jeu de données 'Digits Dataset'
- Appliquez la méthode LDA et testez la classification de ces données avec et sans réduction de dimension avec l'algorithme Random forest, svm et kpp.
- Appliquez la méthode de sélection de caractéristiques (SelectKbest) et testez la classification de ces données avec et sans réduction de dimension avec l'algorithme Random forest, svm et kpp,
- Comparez les résultats.