

Transformation et manipulation de données



Dr Khadidja Henni

Séance 8: Méthodes non
supervisées de sélection et
réduction des dimensions

Introduction

Tableau: ensemble de lignes (individus) et de colonnes (variables)

Etude des individus:

- Comment faire un bilan des ressemblances entre individus?
- Construction de groupes d'individus, partitions d'individus.

Etude des variables:

- Recherche de ressemblances entre variables

→ Recherche d'indicateurs pour résumer l'ensemble des variables

STRUCTURER L'INFORMATION

**Réduction de dimensions
pertinent**

→ Trouver un espace de projection des données

Introduction

Pourquoi réduire la dimensionnalité ?

- Améliorer les performances des algorithmes d'apprentissage automatique en supprimant les informations redondantes.
- Réduire la complexité computationnelle en diminuant le nombre de variables traitées.
- Faciliter la visualisation des données en les projetant dans des espaces de dimension inférieure.
- Gérer la malédiction de la dimension en évitant l'augmentation exponentielle du volume de données requis pour des analyses précises.
- Exemples d'application : reconnaissance d'images, génomique, finance, compression de données, etc.

Introduction

La malédiction de la dimension

- Plus la dimension est élevée, plus les distances entre les points deviennent similaires, ce qui nuit à la discrimination des classes.
- Augmentation exponentielle des besoins en données pour maintenir la performance des modèles.
- Difficulté à visualiser et interpréter des données dans des espaces de grande dimension.

Types de réduction de dimension

- Réduction de dimension linéaire vs non linéaire.
- Méthodes basées sur la variance, la distance et l'apprentissage profond.

Réduction de dimension vs Sélection de dimension

Réduction de dimension

- Transforme les données en un nouvel espace de plus faible dimension.
- Utilise des techniques comme LDA, PCA, t-SNE, UMAP, Autoencoders.
- Maintient une représentation condensée des données.
- Modifie la structure originale des variables.

Sélection de dimension

- Choisit un sous-ensemble optimal des variables existantes.
- Méthodes : filtrage, wrappers, sélection par modèles.
- Maintient l'interprétabilité des variables originales.
- Peut être utilisée en complément de la réduction de dimension.

Principal component Analysis (ACP)

Les méthodes multifactorielles d'Analyse des Données

- **ACP** : Analyse en Composantes Principales, pour les tableaux de variables quantitatives.
- **AFTD** : Analyse Factorielle d'un Tableau de Distances, pour les tableaux de distances.
- **AFC** : Analyse Factorielle des Correspondances, pour les tableaux de contingence.
- **ACM** : Analyse des Correspondances Multiples, pour les tableaux de variables qualitatives.
- **STATIS** : Structuration des Tableaux A Trois Indices de la Statistique
- **AFM** : Analyse Factorielle Multiple
- **DACP** : Double Analyse en Composante Principale
- La liste n'est pas exhaustive.

T-SNE (t-Distributed Stochastic Neighbor Embedding)

Principe de l'algorithme T-SNE


- L'objectif principal du t-SNE est de projeter des points de données en haute dimension dans un espace de plus faible dimension (généralement 2D ou 3D) tout en préservant les relations locales entre les points.
- Il mesure la similarité entre les points dans l'espace de départ et essaie de reproduire cette même structure dans l'espace réduit.
- Pour cela, il construit une distribution de probabilité représentant la similarité entre les points en haute dimension et cherche à minimiser la différence avec une distribution équivalente en basse dimension en utilisant la descente de gradient.
- Cette approche permet au t-SNE de capturer efficacement la structure locale des données, ce qui le rend particulièrement utile pour la visualisation d'ensembles complexes et la découverte de motifs significatifs.

Principe de l'algorithme T-SNE


Préservation des relations locales entre les points

- **Que signifie préserver les relations locales ?**
 - Cela signifie que si deux points sont proches dans l'espace original à haute dimension, ils doivent également rester proches après la réduction de dimension.
 - Inversement, si deux points sont éloignés dans l'espace d'origine, ils doivent également l'être dans l'espace réduit.
 - L'objectif est donc de maintenir les distances relatives entre les points pour garantir une représentation fidèle des données.
- Exemple : Si des points représentent des images similaires dans un espace 100D, après application du t-SNE en 2D, ces images doivent rester groupées.


Principe de l'algorithme T-SNE




Principe de l'algorithme T-SNE



T-sne déplace ces points, légèrement et a chaque étape, jusqu'à ce qu'il les regroupe




Ces points attirent



Alors que ces points éjectent


Principe de l'algorithme T-SNE



L'algorithme T-SNE


Étape 1 : Calcul des similarités en haute dimension

- Une approche simple serait d'utiliser la distance entre les points, mais cette méthode devient peu fiable en haute dimension à cause de la malédiction de la dimension.
- À la place, le t-SNE adopte une approche probabiliste :
 - Pour chaque point, une distribution gaussienne est placée autour avec une moyenne de zéro.
 - L'écart-type est déterminé en fonction de la densité des points voisins.
 - La probabilité de similarité entre chaque paire de points est calculée et enregistrée sous forme de matrice.
 - Cette probabilité n'est pas symétrique : la proximité de x_1 avec x_2 peut être différente de celle de x_2 avec x_1 .




L'algorithme T-SNE


1



2



3




L'algorithme T-SNE

Étape 2 - Réduction de dimension et distribution initiale

- Une fois la matrice de similarité établie en haute dimension, les points sont projetés aléatoirement dans un espace de plus faible dimension.
- Une nouvelle matrice de similarité est calculée dans cet espace réduit.

Le paramètre σ contrôle l'étalement des probabilités (σ petit favorise la proximité des voisins immédiats en assignant des probabilités de proximité plus élevées aux points proches, tandis que σ grand répartit les similarités plus uniformément sur l'ensemble des points).

L'algorithme T-SNE



T-snet moves the points a little bit at a time, and each step it chooses a direction that makes the matrix on the left more like the matrix on the right.




L'algorithme T-SNE


Étape 3 - Alignement des matrices de similarité

- L'algorithme ajuste progressivement la position des points en basse dimension afin de minimiser la différence entre la matrice de similarité en haute et en basse dimension.
- Cela est réalisé par **descente de gradient**, qui ajuste la position des points étape par étape.
- Le processus continue jusqu'à ce que la distribution des points en basse dimension reflète au mieux la structure locale de l'espace original.


L'algorithme T-SNE



Le but de déplacer ce point est que nous voulons que cette ligne ressemble à celle-ci.



L'algorithme T-SNE



T-SNE : Phyton et hyperparamètres

```
from sklearn.manifold import TSNE
import matplotlib.pyplot as plt

# Chargement des données (exemple avec MNIST)
tsne = TSNE(n_components=2, perplexity=30, random_state=42)
X_embedded = tsne.fit_transform(X)
```

Choix des hyperparamètres

- **Perplexité** : détermine le nombre de voisins pris en compte pour le calcul des probabilités.
- **Taux d'apprentissage** : impacte la vitesse de convergence de l'optimisation.
- **Nombre d'itérations** : plus il est grand, plus la convergence est stable.

T-SNE : Cas d'utilisation et recommandations

- **Avantages et Inconvénients du t-SNE**

- Excellente préservation des structures locales.
- Très efficace pour la visualisation de clusters.
- Sensible aux hyperparamètres (perplexité, taux d'apprentissage).
- Coût computationnel élevé, notamment pour de grands ensembles de données.

T-SNE : Cas d'utilisation et recommandations

- **Quand utiliser t-SNE ?**

- Pour visualiser des ensembles de données complexes.
- Pour détecter des structures sous-jacentes dans des bases de données non supervisées.
- Pour explorer des clusters de données avant d'appliquer un algorithme de classification.

- **Quand éviter t-SNE ?**

- Lorsque les données sont de très grande taille (préférer UMAP).
- Lorsque l'objectif est d'obtenir une transformation interprétable (préférer PCA).

T-SNE Vs ACP

Critère	PCA	t-SNE	BCP (Autoencoders, UMAP, etc.)
Type	Linéaire	Non linéaire	Non linéaire
Préservation locale	Moyenne	Excellente	Variable selon l'algorithme
Préservation globale	Bonne	Faible	Dépend du modèle
Interprétabilité	Facile	Difficile	Dépend de la méthode utilisée
Complexité	Faible	Élevée	Variable selon la méthode
Vitesse	Rapide	Lent	Variable
Utilisation recommandée	Données avec structure linéaire	Visualisation et clustering	Très grandes données et deep learning

Selection des dimensions

Sélection des dimensions


La sélection de dimension une multitude d'avantages.

- **Amélioration des performances** : En se concentrant sur les caractéristiques les plus pertinentes, vos modèles d'apprentissage automatique peuvent apprendre plus rapidement et faire des prédictions plus précises.
- **Réduction du temps d'entraînement** : Moins de données signifie moins de puissance de calcul nécessaire, ce qui entraîne des temps d'entraînement plus rapides pour vos modèles
- **Meilleure interprétabilité** : Avec moins de caractéristiques encombrant l'analyse, il devient plus facile de comprendre comment votre modèle parvient à ses prédictions. C'est un atout majeur pour le débogage et l'explication du comportement du modèle.
- **Éviter la malédiction de la dimensionnalité** : Trop de caractéristiques peuvent entraîner un phénomène appelé la "**malédiction de la dimensionnalité**", où le modèle peine à bien fonctionner dans un espace de grande dimension.

Sélection des dimensions

Les Grandes Familles de Méthodes


- Filter Methods
- Wrapper Methods
- Embedded Methods



Sélection des dimensions: filter methods

- **Définition** : Ces méthodes sélectionnent des caractéristiques en utilisant des critères statistiques avant l'entraînement du modèle, indépendamment de l'algorithme final.
- Imaginez un détective examinant minutieusement une scène de crime à la recherche d'indices.
- Les **méthodes de filtrage** fonctionnent de la même manière : elles analysent chaque caractéristique de manière indépendante en utilisant un **critère pré-défini** (corrélation avec la variable cible, gain d'information, etc.). Les caractéristiques jugées non pertinentes sont éliminées, ce qui permet d'obtenir un ensemble de données plus épuré.

Sélection des dimensions: filter methods



Sélection des dimensions: filter methods

Avantages des Méthodes de Filtrage :

- **Rapides et efficaces** : Ces méthodes sont peu coûteuses en calcul, ce qui les rend idéales pour les grands ensembles de données.
- **Faciles à implémenter** : Elles sont souvent intégrées aux bibliothèques populaires de machine learning, nécessitant peu de code.
- **Indépendantes du modèle** : Ces méthodes peuvent être utilisées avec n'importe quel type de modèle d'apprentissage automatique, ce qui les rend très polyvalentes.

Inconvénients des Méthodes de Filtrage :

- **Interaction limitée avec le modèle** : Puisqu'elles fonctionnent indépendamment du modèle, elles peuvent passer à côté d'interactions importantes entre les données.
- **Choix du bon critère** : Sélectionner la bonne métrique en fonction des données et de la tâche est crucial pour de bonnes performances.

Sélection des dimensions: filter methods

Exemples de Méthodes de Filtrage :

- **Information Gain** : Mesure la réduction d'incertitude sur la variable cible après l'ajout d'une caractéristique.
- **Test du Khi-Deux (Chi-square Test)** : Évalue l'association entre une caractéristique catégorielle et la variable cible.
- **Seuil de Variance (Variance Threshold)** : Supprime les caractéristiques ayant une faible variance, suggérant qu'elles ne contribuent pas significativement à l'apprentissage du modèle.
- **Mutual Information** (Mesure d'indépendance entre variables)
- **Spectral Feature Selection** (Méthodes basées sur la matrice de similarité)
- **Laplace Score** (Analyse de la structure du graphe des données)

Sélection des dimensions: filter methods

Pourquoi la Variance est Importante ?

- Une caractéristique avec **une variance très faible** signifie qu'elle a **peu de variabilité** parmi les échantillons.
- Si une caractéristique prend **presque toujours la même valeur**, elle **n'apporte pas d'information utile** pour la modélisation.

Exemple : Une colonne avec uniquement des valeurs 0 et 1 où 99% des valeurs sont des 0 n'apporte pas de diversité.

$$Var(X_i) = \frac{1}{n} \sum_{j=1}^n (X_{ij} - \bar{X}_i)^2$$

où $\bar{X}_i$ est la moyenne des valeurs de la caractéristique X_i . Si la variance est inférieure à un seuil défini, la variable est supprimée.

Sélection des dimensions: filter methods

Implémentation en Python avec Scikit-Learn

```
from sklearn.feature_selection import VarianceThreshold
import numpy as np

# Création d'un jeu de données
X = np.array([[0, 2, 0, 3],
              [0, 1, 4, 3],
              [0, 1, 1, 3]])

# Application de VarianceThreshold avec un seuil de 0
sel = VarianceThreshold(threshold=0)
X_new = sel.fit_transform(X)
print(X_new)
```

Avant sélection :

```
[[0, 2, 0, 3],
 [0, 1, 4, 3],
 [0, 1, 1, 3]]
```

Après application de VarianceThreshold :

```
[[2, 0, 3],
 [1, 4, 3],
 [1, 1, 3]]
```

Sélection des dimensions: filter methods

Variance Threshold Algorithm


- **Définition** : Variance Threshold est une méthode de sélection de caractéristiques qui supprime les variables ayant une faible variance dans les données.
- **Type** : Méthode de filtrage (Filter Method)
- **Utilité** : Réduit la dimensionnalité en supprimant les caractéristiques non informatives.

Sélection des dimensions: wrapper methods

Wrapper Methods

- **Définition** : Ces méthodes évaluent différentes combinaisons de caractéristiques en utilisant une mesure de performance.
- Imaginez les méthodes **Wrapper** comme une équipe d'analystes travaillant en étroite collaboration avec un modèle d'apprentissage automatique.
- Ces techniques évaluent des **sous-ensembles de caractéristiques** en fonction de leur performance avec le modèle choisi. Elles ajoutent ou suppriment des caractéristiques de manière **itérative**, dans le but de trouver la combinaison qui optimise **les performances du modèle**.

Sélection des dimensions: wrapper methods



Sélection des dimensions: wrapper methods

Avantages des Méthodes Wrapper :

- **Optimisation spécifique au modèle** : Ces méthodes prennent directement en compte les interactions entre caractéristiques et leur impact sur le modèle, ce qui peut conduire à **de meilleures performances** par rapport aux méthodes de filtrage.
- **Flexibles** : Elles peuvent être adaptées à divers **types de modèles et métriques d'évaluation**.

Inconvénients des Méthodes Wrapper :

- **Coût computationnel élevé** : Tester différentes combinaisons de caractéristiques peut être **très long**, surtout pour les grands ensembles de données.
- **Risque de surapprentissage (overfitting)** : Ajuster trop finement les caractéristiques à un modèle spécifique peut entraîner un **modèle sur-ajusté**, qui généralise mal aux nouvelles données.

Sélection des dimensions: wrapper methods

- **Sélection avant (Forward Selection)** : Commence avec un ensemble vide et **ajoute progressivement** les caractéristiques qui améliorent le plus la performance du modèle.
- **Sélection arrière (Backward Selection)** : Commence avec **toutes les caractéristiques** et les supprime **progressivement**, en retirant celles qui contribuent le moins à la performance du modèle.
- **Élimination Réursive de Caractéristiques (Recursive Feature Elimination - RFE)** : Similaire à la sélection arrière, mais utilise **un critère de classement des caractéristiques** pour guider le processus d'élimination.


Sélection des dimensions: Embedded methods

Embedded Methods

- **Définition** : Ces méthodes intègrent la sélection des caractéristiques directement dans l'entraînement du modèle.
- Les méthodes intégrées adoptent une approche "**pourquoi ne pas faire les deux ?**". Elles intègrent la sélection de caractéristiques directement dans le processus d'entraînement du modèle. Cela permet au modèle d'apprendre **non seulement la relation entre les caractéristiques et la variable cible**, mais aussi **quelles caractéristiques sont les plus pertinentes**.

Sélection des dimensions: Embedded methods

Embedded Methods



Sélection des dimensions: Embedded methods

La majorité des Embedded Methods implémentées sont supervisées:

- **LASSO (Least Absolute Shrinkage and Selection Operator)**
 - Applique une régularisation **L1** à une **régression linéaire supervisée**.
 - Les caractéristiques non importantes voient leur **coefficient réduit à zéro**, ce qui équivaut à une sélection automatique des variables.
- **Ridge Regression**
 - Applique une régularisation **L2**, qui réduit l'impact des caractéristiques moins importantes mais sans les annuler complètement.
- **Elastic Net**
 - Combine **LASSO (L1)** et **Ridge Regression (L2)** pour bénéficier des avantages des deux.

Sélection des dimensions: Embedded methods

Avantages des Méthodes Intégrées

- **Efficacité et performance** : Ces méthodes obtiennent de bons résultats sans nécessiter le coût computationnel élevé des méthodes Wrapper.
- **Apprentissage spécifique au modèle** : Comme les méthodes Wrapper, elles exploitent le processus d'apprentissage pour identifier les caractéristiques les plus utiles.

Inconvénients des Méthodes Intégrées

- **Interprétabilité limitée** : Elles peuvent être plus difficiles à expliquer que les méthodes de filtrage, ce qui rend plus complexe la compréhension des caractéristiques sélectionnées.
- **Non universelles** : Toutes les techniques d'apprentissage automatique ne prennent pas en charge ces méthodes de sélection de caractéristiques.

Sélection des dimensions

Méthode	Approche	Exemples	Avantages	Inconvénients
Filter	Indépendant du modèle	Variance Threshold, Laplace Score	Rapide, simple, scalable	Ignore les interactions entre caractéristiques
Wrapper	Basé sur l'évaluation d'un modèle	RFE, Autoencoders	Prend en compte les relations entre features	Coût computationnel élevé
Embedded	Intégré dans l'algorithme d'apprentissage	Sparse PCA, LASSO	Sélection optimisée avec le modèle	Dépend du modèle utilisé

Conclusion

- La **Feature Selection en non supervisé** est cruciale pour réduire la dimensionnalité des données et améliorer les performances.
- Actuellement, les autoencoders sont les réseaux de neurones les plus utilisés pour la présentation des données dans un espace de dimension réduit (ils sont supervisés/non supervisés)
- **Choix de la méthode** : dépend du **temps de calcul**, de la **complexité des données** et de la **nécessité de prendre en compte les interactions** entre les caractéristiques.

Laboratoire formatif

Laboratoire formatif

1. Charger le dataset `breast_cancer` (`sklearn.datasets`).
2. Extraire `X` (features) et `y` (étiquette).
3. Standardiser `X` avec `StandardScaler`.
4. Diviser en `X_train`, `X_test`, `y_train`, `y_test` (70/30).
5. Entraîner un `DecisionTreeClassifier` sur les données complètes.
6. Mesurer l'accuracy et le temps d'exécution.
7. Réduction de dimension :
 - Appliquer `VarianceThreshold` (commencer par seuil = 0.01) sur `X`.
 - Répéter étapes 4–6 sur les données réduites.
 - Appliquer `TSNE(n_components=2)` sur `X`.
 - Répéter étapes 4–6 sur les données 2D.