

Transformation et manipulation de données



Dr Khadidja Henni

Séance 10

Transformation et
manipulation des données
textuelles.

Plan de cours

- Introduction
- Analyse de documents textuels
- Classification de documents textuels
- Laboratoire formatif

Analyse et classification des documents textuels

Introduction

- On dispose d'un ensemble de documents textuels $\mathcal{D}$, appelé corpus, et un ensemble de classes de documents (thèmes).
- Les documents textuels peuvent être des courriels, des messages de newsgroups, des articles de magazines, etc.
- Les classes peuvent être: {spam, non-spam}, {les domaines des sciences: physique, mathématique, psychologie, etc.}, {les différents pays: Canada, USA, etc.}, etc.
- Le but de la classification de texte est de déterminer la classe la plus probable pour chaque document textuel.

Introduction

- Plusieurs applications pour la classification de texte:
 - ➡ Classification de messages **de newsgroups**.
 - ➡ Classification de messages **de courriels, tweets, SMS, etc.**
 - ➡ Classification de **dépêches de presse** (ex. par thèmes, etc.).
 - ➡ Classification de **pages web** (ex. par intérêt, sujets, etc.).
 - ➡ Classification **d'archives**.
 - ➡ Classification **d'opinions**, etc.
 - ➡ Classification **du genre et de l'âge des** ,auteurs etc.
- Les domaines de la **sécurité, l'archivage, la gestion du contenu Web, la recherche et l'indexation de l'information textuelle**, utilisent souvent la classification du texte.

Analyse de documents textuels

Documents textuels

- Un document textuel est une suite de caractères, chiffres, ponctuation, espaces, etc., stocké dans un fichier.

```
<REUTERS TOPICS='YES' LEWISSPLIT='TRAIN'  
CGISPLIT='TRAINING-SET' OLDID='12981' NEWID='798'>  
<DATE> 2-MAR-1987 16:51:43.42</DATE>  
<TOPICS><D>livestock</D><D>hog</D></TOPICS>  
<TITLE>AMERICAN PORK CONGRESS KICKS OFF TOMORROW</TITLE>  
<DATELINE> CHICAGO, March 2 - </DATELINE><BODY>The American Pork  
Congress kicks off tomorrow, March 3, in Indianapolis with 160  
of the nations pork producers from 44 member states determining  
industry positions on a number of issues, according to the  
National Pork Producers Council, NPPC.  
Delegates to the three day Congress will be considering 26  
resolutions concerning various issues, including the future  
direction of farm policy and the tax law as it applies to the  
agriculture sector. The delegates will also debate whether to  
endorse concepts of a national PRV (pseudorabies virus) control  
and eradication program, the NPPC said. A large  
trade show, in conjunction with the congress, will feature  
the latest in technology in all areas of the industry, the NPPC  
added. Reuter  
&\#3;</BODY></TEXT></REUTERS>
```

- Il est nécessaire de mettre le document sous une forme (représentation) afin qu'il puisse être traité par un classificateur quelconque.

Documents textuels


- Un document textuel peut être un livre, un magazine, un courriel, une pièce jointe de courriel, un article scientifique, une page web, etc.
 - Dans un magazine, deux mots se trouvant au départ et à la fin ne seront pas nécessairement relié par le même thème.
 - Il serait moins précis, voire inutile, de classer le thème d'un magazine au complet.
- 👉 classer individuellement chaque article du magazine.

Longueur d'un document textuel

- Il en va de même pour un **courriel et sa pièce jointe**, pour les **chapitres/paragraphes** d'un livre, etc., pour les séparer et classer leurs thèmes individuellement.
- Il est important de déterminer à l'avance le niveau de **granularité** et **la taille** des documents textuels à classer pour chaque application.
 - ☞ Si un **document est trop réduit** (ex. une phrase), on peut rater le thème global du texte du document.
 - ☞ Si un **document est trop grand** (ex. un livre), on peut trouver plusieurs thèmes à l'intérieur du document.

Représentation de documents textuels

- Pour classer les documents, il est nécessaire de trouver **une représentation** des documents en utilisant **les termes (mots)**.



Vocabulaire d'un texte

- Soit $\mathcal{V}$ l'ensemble des **mots (words)** utilisé dans un texte (ex. tous les mots du français, de l'anglais, etc.). On appelle $\mathcal{V}$ un **vocabulaire**
- Soit $|\mathcal{V}|$ la cardinalité de $\mathcal{V}$ (nombre de mots composant $\mathcal{V}$). Un vocabulaire typique (ex. anglais) peut contenir jusqu'à 5×10^5 mots.
- Avant de classer un document, il est important de **recenser les mots** apparaissant dans le texte du document.

👉 **Plusieurs étapes de prétraitement du texte.**

Prétraitement linguistique: Segmentation

Segmentation (Tokenisation)

- En ayant une séquence de caractères, la **segmentation** consiste à diviser le texte en **unités** appelées **mots (tokens)**, et par là-même **écarter certains caractères** (ex. ponctuation).

Exemple: Soit le texte suivant:

'dear students !, dear professors !, dear assistance ! ...'

- Après segmentation, on produira les mots suivants:

<i>dear</i>	<i>students</i>	<i>dear</i>	<i>professors</i>	<i>dear</i>	<i>assistance</i>
-------------	-----------------	-------------	-------------------	-------------	-------------------

Prétraitement linguistique: Segmentation

- Une bonne segmentation dépend de la prise en compte des spécificités de la langue des textes traitées.
- Pour certaines langues (ex. le chinois), les mots dans un texte ne sont pas séparés par des espaces. La segmentation sera alors une tâche plus ardue.
- Pour des langues indo-européennes, la segmentation est plus aisée puisque l'espace, et les signes de ponctuation donnent une première indication de séparation entre les éléments lexicaux.

Prétraitement linguistique: Segmentation

- Par exemple, pour le français, nous avons :
 - 👉 **Les composés lexicaux à trait d'union:** ex. chassé-croisé, peut-être, etc., ou avec apostrophe (ex. jusqu'où, aujourd'hui, prud'homme, etc.).
 - 👉 **Les expressions idiomatiques:** ex. poser un lapin, tomber dans les pommes, etc.
 - 👉 **Les formes contractées:** ex. Gad'zarts (les gars des Arts et Métiers) , M'sieur, etc.) et les sigles et acronymes (ex. K7, A.R., CV, c.-à-d., P.-V. , etc.
- En allemand, les noms composés s'écrivent sans espace:

Exemple: Rindfleischetikettierungsüberwachungsaufgabenübertragungsgesetz

En anglais: <Beef labeling control supervision transfer legislation>.

Prétraitement linguistique: Segmentation

Suppression de mots vides

- Certains mots sont **extrêmement utilisés** mais ne rajoutent rien dans la détermination du sens d'un texte (ex. and, or, etc.).
- Ce genre de mots sont appelés **mots vides** et doivent être exclus du vocabulaire utilisé pour la classification du texte.

Exemple: {*a, an, and, as, at, by, from, where*, etc.} sont des **mots vides**. On peut les exclure du vocabulaire pour la classification.

- Des listes de ces mots sont en général disponibles.

Prétraitement d'un document textuel

- Pour les **langues européennes**, différents logiciels de segmentation commerciaux existent.
- Le but de certains de ces logiciels est de faire une analyse plus poussée du texte en associant aux mots d'une phrase **leur fonction grammaticale**.
- Pour la segmentation de texte en Python, notamment pour diviser des textes en phrases ou en mots, il y a plusieurs bibliothèques utiles. Voici quelques outils que vous pourriez utiliser :
 1. NLTK (Natural Language Toolkit): C'est une bibliothèque très complète pour le traitement de texte en langue naturelle. Elle offre des fonctionnalités pour la tokenisation de phrases et de mots.
 2. spaCy: C'est une bibliothèque moderne et rapide pour le traitement de texte, qui supporte de nombreuses langues. Elle est très efficace pour la segmentation de phrases.
 3. Stanza: Développée par l'université Stanford, cette bibliothèque supporte également plusieurs langues et est très performante pour diverses tâches de NLP, y compris la tokenisation.

Prétraitement d'un document textuel

Normalisation

- Est le processus de **canonisation des tokens** de sorte que les **différences superficielles d'apparences** d'un mot du vocabulaire soient enlevées (ex. *USA* et *U.S.A*, *And* et *and*, etc.).
- Plusieurs méthodes existent (avec des désavantages!):
 - ➡ Créer **des classes d'équivalence** pour les mots du vocabulaire (ex. *USA* et *U.S.A* doivent avoir la même classe).
 - ➡ Enlever les **diacritiques** (ex. *cliché* → *cliche*).
 - ➡ Transformer toutes les majuscules en minuscules.
 - ➡ Trouver des équivalences de mots (ex. *color* et *colour*).

Prétraitement d'un document textuel

Racinisation (stemization)

- Les documents peuvent utiliser **différentes formes** d'un mot (ex. *organize, organizes, organizing, organizers*, etc).
- Des mots peuvent sous-entendre le même sens (ex. *democracy, democratic, democratization*, etc.).
- La **racinisation** consiste à regrouper les différentes variantes morphologiques d'un mot autour d'une même racine (en anglais **stem**).

Prétraitement d'un document textuel

Racinisation (stemization)

- Ce procédé repose sur **un ensemble de règles** supprimant les flexions et les suffixes des mots. Ces règles dépendent fortement de la langue utilisée.
- Un des algorithmes les plus célèbres de **racinisation des mots en anglais** est celui de **Porter**.

<https://tartarus.org/martin/PorterStemmer/matlab.txt>

Pour utiliser l'algorithme de Porter en Python, vous pouvez utiliser la bibliothèque 'nltk', qui comprend une implémentation de cet algorithme.

Traitement de mots spéciaux

- Il est parfois possible de rencontrer **des mots inconnus** (c.-à-d. ne font pas partie de $\mathcal{V}$) dans les documents du corpus.
- Pour traiter ce genre de situation, on peut ajouter le mot '**inconnu**' au vocabulaire $\mathcal{V}$ pour présenter toute chaîne de caractère inconnu.
- On peut aussi ajouter des **mots spéciaux** pour représenter des suites de caractères particulières, par exemple:
 - ➡ '**lien**': pour les liens Web.
 - ➡ '**courriel**': pour les adresses courriels.
 - ➡ '**nombre**': pour les suites de nombres, etc.

Classification de documents textuels

Classification de texte

- Soit les K **classes** $\{C_1, C_2, \dots, C_K\}$ reflétant **les thèmes/sujets** que des documents abordent, ou simplement le **type de documents** (ex. spam/non spams, etc.).
- Soit $\mathcal{D} = \{d^{(1)}, d^{(2)}, \dots, d^{(n)}\}$ un ensemble de n **documents d'apprentissage** et $T = \{t^{(1)}, t^{(2)}, \dots, t^{(n)}\}$ les **thèmes** auxquels peuvent appartenir ces documents.
- On doit alors construire **un classificateur par apprentissage supervisé** qui utilisera $\mathcal{D}$ et T . Ce dernier sera utilisé **pour prédire les thèmes de nouveaux documents**.

Utilisation du classificateur de Bayes

- Ayant l'ensemble des classes $\{C_1, C_2, \dots, C_K\}$, soit un **document** $d^* \notin \mathcal{D}$ dont on veut prédire la classe. Ceci peut se faire en maximisant **la probabilité a posteriori (MAP)**:

$$t = \operatorname{argmax}_k p(C_k | d^*)$$

- En appliquant **la règle de Bayes**, on aura:

$$p(C_k | d^*) = \frac{p(d^* | C_k) p(C_k)}{p(d^*)}$$

- Maximiser **$p(C_k | d^*)$** revient à maximiser: **$p(d^* | C_k) p(C_k)$** .

Utilisation du classificateur de Bayes

- Comment calculer les probabilités $p(d^*|C_k)$ et $p(C_k)$?
- Soit $\mathcal{V}$ le vocabulaire constitué de l'ensemble des **mots** (words) utilisés dans une collection de documents. On désignera par:
 - ☞ $m_j, j \in \{1, \dots, |\mathcal{V}|\}$: **un mot** quelconque de $\mathcal{V}$.
 - ☞ $n_{j,k}$: **nombre de** documents dans la classe C_k comportant le mot m_j .
 - ☞ n_k : nombre de documents assignés à la classe C_k .
 - ☞ n : nombre de documents dans toute la collection $\mathcal{D}$.

Utilisation du classificateur de Bayes

- Il est clair que la probabilité a priori d'une classe $p(C_k)$ peut être estimée à partir des données d'apprentissage par:

$$p(C_k) \approx \frac{n_k}{\sum_{l=1}^K n_l} = \frac{n_k}{n}$$

- Pour estimer les probabilités conditionnelles $p(d^*|C_k)$, deux possibilités peuvent être envisageables:
 - 👉 **Modèle de Bernoulli** (2 choix par mot dans le document).
 - 👉 **Modèle multinomial** ($\mathcal{V}$ choix par mot dans le document).

Modèle de Bernoulli

- Pour le document à classer d^* , le modèle de Bernoulli génère **une variable indicatrice** $r_{j,d^*} \in \{0,1\}$ pour chaque mot m_j du vocabulaire $\mathcal{V}$.
- Si le mot m_j est présent dans le document d^* ($m_j \in d^*$), alors $r_{j,d^*} = 1$, autrement $r_{j,d^*} = 0$.
- Le document d^* est alors représenté par le vecteur de variables $r_{d^*} = (r_{1,d^*}, r_{2,d^*}, \dots, r_{|\mathcal{V}|,d^*})$. Par l'hypothèse de Bayes naïve:

$$p(d^* | C_k) = \prod_{j=1}^{|\mathcal{V}|} \theta_{j,k}^{r_{j,d^*}} (1 - \theta_{j,k})^{1-r_{j,d^*}}$$

Modèle de Bernoulli

- Le paramètre $\theta_{j,k}$ représente la probabilité que le mot m_j soit présent dans les documents de la classe C_k .
- Cette probabilité peut être estimée par la formule suivante:

$$\theta_{j,k} \approx \frac{n_{j,k}}{n_k}$$

- Pour éviter les probabilités nulles, on utilise la correction de Laplace:

$$\theta_{j,k} \approx \frac{n_{j,k} + 1}{n_k + 2}$$

Modèle de Bernoulli

Exemple: Soit une collection $\mathcal{D}$ de 6 documents répartis en 2 classes: $C_1 = \textit{informatique}$ et $C_2 = \textit{biologie}$.

$d^{(1)} = \textit{'The Windows computer CD-ROM is easy to use'}$;

$d^{(2)} = \textit{'The driver CD-ROM of mouse is in the computer'}$;

$d^{(3)} = \textit{'The memory of a computer is composed of cells'}$;

$d^{(4)} = \textit{'The brain cells of a human are composed of neurons.'}$;

$d^{(5)} = \textit{'The ADN of a cell in the mouse liver'}$;

$d^{(6)} = \textit{'Genes are expressed in mice liver cells and brain cells'}$;

- Soit $d^{(1)}, d^{(2)}, d^{(3)} \in C_1$ et $d^{(4)}, d^{(5)}, d^{(6)} \in C_2$.
- D'après les données, on a $p(C_1) = p(C_2) = 0.5$. Les paramètres $\theta_{j,k}$ seront calculés comme suit:

Modèle de Bernoulli

<i>Mot</i>	m_j	$\theta_{j,1}$	$\theta_{j,2}$
<i>ADN</i>	m_1	$(0 + 1)/(3 + 2) = 1/5$	$(1 + 1)/(3 + 2) = 2/5$
<i>brain</i>	m_2	$(0 + 1)/(3 + 2) = 1/5$	$(2 + 1)/(3 + 2) = 3/5$
<i>CDROM</i>	m_3	$(2 + 1)/(3 + 2) = 3/5$	$(0 + 1)/(3 + 2) = 1/5$
<i>cell</i>	m_4	$(1 + 1)/(3 + 2) = 2/5$	$(3 + 1)/(3 + 2) = 4/5$
<i>compose</i>	m_5	$(1 + 1)/(3 + 2) = 2/5$	$(1 + 1)/(3 + 2) = 2/5$
<i>computer</i>	m_6	$(3 + 1)/(3 + 2) = 4/5$	$(0 + 1)/(3 + 2) = 1/5$
<i>driver</i>	m_7	$(1 + 1)/(3 + 2) = 2/5$	$(0 + 1)/(3 + 2) = 1/5$
<i>easy</i>	m_8	$(1 + 1)/(3 + 2) = 2/5$	$(0 + 1)/(3 + 2) = 1/5$
<i>express</i>	m_9	$(0 + 1)/(3 + 2) = 1/5$	$(1 + 1)/(3 + 2) = 2/5$
<i>gene</i>	m_{10}	$(0 + 1)/(3 + 2) = 1/5$	$(1 + 1)/(3 + 2) = 2/5$
<i>human</i>	m_{11}	$(0 + 1)/(3 + 2) = 1/5$	$(1 + 1)/(3 + 2) = 2/5$
<i>liver</i>	m_{12}	$(0 + 1)/(3 + 2) = 1/5$	$(2 + 1)/(3 + 2) = 3/5$
<i>memory</i>	m_{13}	$(1 + 1)/(3 + 2) = 2/5$	$(0 + 1)/(3 + 2) = 1/5$
<i>mouse</i>	m_{14}	$(1 + 1)/(3 + 2) = 2/5$	$(2 + 1)/(3 + 2) = 3/5$
<i>neuron</i>	m_{15}	$(0 + 1)/(3 + 2) = 1/5$	$(1 + 1)/(3 + 2) = 2/5$
<i>use</i>	m_{16}	$(1 + 1)/(3 + 2) = 2/5$	$(0 + 1)/(3 + 2) = 1/5$
<i>windows</i>	m_{17}	$(1 + 1)/(3 + 2) = 2/5$	$(0 + 1)/(3 + 2) = 1/5$

Modèle de Bernoulli

- Classer les documents suivants:

$d^{(7)} = \text{'The memory of a Window computer'}$;

$d^{(8)} = \text{'The brain cell of a mouse'}$;

- On a les vecteurs indicateurs $r_{d^{(7)}}$ et $r_{d^{(8)}}$ pour $d^{(7)}$ et $d^{(8)}$:

$$r_{d^{(7)}} = (0,0,0,0,0,1,0,0,0,0,0,0,1,0,0,0,1)$$

$$p(d^{(7)}|C_1) = \frac{4}{5} \times \frac{4}{5} \times \frac{2}{5} \times \frac{3}{5} \times \frac{3}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{3}{5} \times \frac{4}{5} \times \frac{4}{5} \times \frac{4}{5} \times \frac{4}{5} \times \frac{2}{5} \times \frac{3}{5} \times \frac{4}{5} \times \frac{2}{5} \times \frac{2}{5} \approx 6.26 \times 10^{-4}$$

$$p(d^{(7)}|C_2) = \frac{3}{5} \times \frac{2}{5} \times \frac{4}{5} \times \frac{1}{5} \times \frac{3}{5} \times \frac{1}{5} \times \frac{4}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{3}{5} \times \frac{3}{5} \times \frac{2}{5} \times \frac{1}{5} \times \frac{2}{5} \times \frac{3}{5} \times \frac{4}{5} \times \frac{1}{5} \approx 2.61 \times 10^{-6}$$

Modèle de Bernoulli

$$r_{d^{(8)}} = (0,1,0,1,0,0,0,0,0,0,0,0,1,0,0,0)$$

$$p(d^{(8)}|C_1) = \frac{4}{5} \times \frac{1}{5} \times \frac{2}{5} \times \frac{2}{5} \times \frac{3}{5} \times \frac{1}{5} \times \frac{3}{5} \times \frac{3}{5} \times \frac{4}{5} \times \frac{4}{5} \times \frac{4}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{2}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{3}{5} \approx 3.13 \times 10^{-5}$$

$$p(d^{(8)}|C_2) = \frac{3}{5} \times \frac{3}{5} \times \frac{4}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{4}{5} \times \frac{4}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{3}{5} \times \frac{3}{5} \times \frac{2}{5} \times \frac{4}{5} \times \frac{3}{5} \times \frac{3}{5} \times \frac{4}{5} \times \frac{4}{5} \approx 11 \times 10^{-4}$$

- On voit que:

$$p(d^{(7)}|C_1) > p(d^{(7)}|C_2)$$

$$p(d^{(8)}|C_1) < p(d^{(8)}|C_2)$$

- Donc, le document $d^{(7)}$ va être assigné à la classe C_1 et le document $d^{(8)}$ sera assigné à la classe C_2 .

Modèle Multinomial

- Pour le document à classer d^* , le **modèle multinomial** considère le document comme une séquence ordonnée de mots: $m_{(1)}, m_{(2)}, \dots, m_{(N_d)}$ générés à partir de $\mathcal{V}$.
- Avec l'hypothèse de Byes naïve, de Bayes naïve:

$$p(d^* | C_k) = \prod_{j=1}^{N_d} \hat{\theta}_{j,k}$$

- Où $0 \leq \hat{\theta}_{j,k} \leq 1$ est la probabilité de génération du mot $m_{(j)}$ dans la classe C_k . Le **modèle multinomial capture la fréquence des mots dans le document.**

Modèle Multinomial

- La probabilité $\hat{\theta}_{j,k}$ est calculée comme suit:

$$\hat{\theta}_{j,k} = \frac{\sum_{d \in C_k} n_{j,d}}{\sum_{j=1}^{|\mathcal{V}|} \sum_{d \in C_k} n_{j,d}}$$

- Et avec la correction de Laplace, on aura:

$$\hat{\theta}_{j,k} = \frac{\sum_{d \in C_k} n_{j,d} + 1}{\sum_{i=1}^{|\mathcal{V}|} \sum_{d \in C_k} n_{i,d} + |\mathcal{V}|}$$

- Pour l'exemple avec 6 documents d'apprentissage, on aura:

Modèle Multinomial

<i>Mot</i>	m_j	$\hat{\theta}_{j,1}$	$\hat{\theta}_{j,2}$
<i>ADN</i>	m_1	$(0 + 1)/(13 + 17) = 1/30$	$(1 + 1)/(16 + 17) = 2/33$
<i>brain</i>	m_2	$(0 + 1)/(13 + 17) = 1/30$	$(2 + 1)/(16 + 17) = 3/33$
<i>CDROM</i>	m_3	$(2 + 1)/(13 + 17) = 3/30$	$(0 + 1)/(16 + 17) = 1/33$
<i>cell</i>	m_4	$(1 + 1)/(13 + 17) = 2/30$	$(4 + 1)/(16 + 17) = 5/33$
<i>compose</i>	m_5	$(1 + 1)/(13 + 17) = 2/30$	$(1 + 1)/(16 + 17) = 2/33$
<i>computer</i>	m_6	$(3 + 1)/(13 + 17) = 4/30$	$(0 + 1)/(16 + 17) = 1/33$
<i>driver</i>	m_7	$(1 + 1)/(13 + 17) = 2/30$	$(0 + 1)/(16 + 17) = 1/33$
<i>easy</i>	m_8	$(1 + 1)/(13 + 17) = 2/30$	$(0 + 1)/(16 + 17) = 1/33$
<i>express</i>	m_9	$(0 + 1)/(13 + 17) = 1/30$	$(1 + 1)/(16 + 17) = 2/33$
<i>gene</i>	m_{10}	$(0 + 1)/(13 + 17) = 1/30$	$(1 + 1)/(16 + 17) = 2/33$
<i>human</i>	m_{11}	$(0 + 1)/(13 + 17) = 1/30$	$(1 + 1)/(16 + 17) = 2/33$
<i>liver</i>	m_{12}	$(0 + 1)/(13 + 17) = 1/30$	$(2 + 1)/(16 + 17) = 3/33$
<i>memory</i>	m_{13}	$(1 + 1)/(13 + 17) = 2/30$	$(0 + 1)/(16 + 17) = 1/33$
<i>mouse</i>	m_{14}	$(1 + 1)/(13 + 17) = 2/30$	$(2 + 1)/(16 + 17) = 3/33$
<i>neuron</i>	m_{15}	$(0 + 1)/(13 + 17) = 1/30$	$(1 + 1)/(16 + 17) = 2/33$
<i>use</i>	m_{16}	$(1 + 1)/(13 + 17) = 2/30$	$(0 + 1)/(16 + 17) = 1/33$
<i>windows</i>	m_{17}	$(1 + 1)/(13 + 17) = 2/30$	$(0 + 1)/(16 + 17) = 1/33$

Modèle Multinomial

- Les documents à classer sont:

$d^{(7)}$ = *'The memory of a Window computer';*

$d^{(8)}$ = *'The brain cell of a mouse';*

$$\left. \begin{aligned} p(d^{(7)}|C_1) &= \frac{2}{30} \times \frac{2}{30} \times \frac{4}{30} \approx 5.9 \times 10^{-4} \\ p(d^{(7)}|C_2) &= \frac{1}{33} \times \frac{1}{33} \times \frac{1}{33} \approx 2.8 \times 10^{-5} \end{aligned} \right\} p(d^{(7)}|C_1) > p(d^{(7)}|C_2)$$

$$\left. \begin{aligned} p(d^{(8)}|C_1) &= \frac{1}{30} \times \frac{2}{30} \times \frac{1}{30} \approx 1.48 \times 10^{-4} \\ p(d^{(8)}|C_2) &= \frac{1}{33} \times \frac{1}{33} \times \frac{1}{33} \approx 13 \times 10^{-4} \end{aligned} \right\} p(d^{(8)}|C_1) < p(d^{(8)}|C_2)$$

- Donc, le document $d^{(7)}$ va être assigné à la classe C_1 et le document $d^{(8)}$ sera assigné à la classe C_2 .


Autres classificateurs de texte

- On peut utiliser des vecteurs de données représentant l'absence/présence de chaque mot $m_j \in \mathcal{V}$ dans un document, ou bien sa fréquence d'apparition.
- Un document d va donc être un vecteur d'attributs que peut utiliser un classificateur (ex. arbre de décision: AD, SVM, régression logistique: RL, réseau de neurones: RN, etc.).
- On peut aussi utiliser les algorithmes de regroupement (ex. K-moyennes, MMG, groupement hiérarchique, etc.) pour créer des groupes homogènes de textes selon le thème.

Modèles N -grams

Modèle: *sac-à-mots*

- Le modèle basé sur la présence de mots d'un certain vocabulaire est communément appelé **modèle de sac-à-mots** (**bag of words**).



- On peut représenter un document comme l'expérience de **tirer avec remplacement** des mots dans un sac.

Modèle n -grams

- Le fait de traiter les mots de manière **indépendante** dans le **modèle sac-à-mots** enlève parfois de la sémantique du texte.

Exemple: ces deux textes sont équivalents en terme de mots:

1) 'have an account at the bank of Montreal'

2) 'have an account in a Montreal bank'.

- On peut par exemple utiliser **les séquences de 2, 3,..., n mots** qui se succèdent comme des **attributs** à part entière. Ces mots sont appelés des **n -grams**.

Modèle n -grams

- On peut combiner alors des mots de 1-gram, 2-grams, etc., pour la classification de texte.
- Il est à noter que le nombre de N-grams qu'on peut générer avec un vocabulaire $\mathcal{V}$ est $|\mathcal{V}|^N$.
 - 👉 Énorme lorsque N est grand !
- Il est en général plus pratique de se limiter à des 1-gram et 2-grams pour la classification de texte. On assure une meilleure représentation sémantique à moindre complexité.

Etude de cas: classification de spams

- On peut utiliser les courriels pour l'apprentissage des **spams** et des **non-spams** (hams).

Spam: Wholesale Fashion Watches -57% today. Designer watches for cheap..

Spam: You can buy Viagra Fr\$1.85. All medications at unbeatable prices! ...

Spam: WE CAN TREAT ANYTHING YOU SUFFER FROM JUST TRUST US...

Spam: Start ear*ning the salary yo,u d-serve by o'btaning the prope'r crede'ntials...

Ham: The pratictical signifcace of machine learning algorithms...

Ham: Good to see you my friend. I hope to meet you in another occasion...

Ham: Dear professor, I m looking to pursue a Master degree in computer science...

Ham: Dear cutomer, This is to acknowledge the transaction of your purchase...

Wholesale Fashion
for cheap
buy Viagra
TRUST US
TREAT ANYTHING
...

Sélection de mots discriminatifs par filtrage

- En plus du vocabulaire, on peut aussi ajouter d'autres indicateurs pour la classification de spams:
 - ➡ Présence/absence de liens Web;
 - ➡ Présence/absence d'images;
 - ➡ Taille du courriel;
 - ➡ Adresse de l'expéditeur, du serveur.
 - ➡ Langue utilisée dans le texte, ..., etc.
- Habituellement, on opère une sélection d'attributs pour avoir des classificateurs rapides, qu'on peut mettre à jour facilement.

Sélection de mots discriminatifs par filtrage

- L'information mutuelle mesure combien la présence/absence d'un mot contribue à la classification.
- Soit r_j la variable binaire indiquant si le mot m_j apparaît parmi les documents de C_k . L'information mutuelle entre C_k et m_j est définie par:

$$I(m_j, C_k) = \sum_{s \in \{0,1\}} \sum_{h \in \{1,2\}} p(r_j = s, C_h) \log_2 \left(\frac{p(r_j = s, C_h)}{p(r_j = s)p(C_h)} \right)$$

Proposition:

- ☞ Les mots les plus discriminatifs pour la classe C_k auront une information mutuelle très grande avec la classe C_k .

Etude de cas: classification de spams

Exemple:

- Spam:** Online lottery can make you rich in one day and purchase a million...*
- C_1 ***Spam:** You can play lottery at \$1.85. Your money can earn you a fortune ...*
- Spam:** Protect your money from any risk by insurance...*
- Spam:** Dear customer, save your money, you can purchase for cheap price*
- Ham:** The practical significance of machine learning algorithms...*
- Ham:** Hey how are you my friend? With risk to know that ...*
- C_2 ***Ham:** Dear professor, I'm looking to pursue a Master degree and learn ...*
- Ham:** Dear John, This is to acknowledge the transaction of your last purchase...*

Etude de cas: classification de spams

- Le tableau suivant montre quelques exemples de probabilités utilisées pour calculer l'information mutuelle.

<i>mots</i>	m_j	$p(r_j = 1, C_1)$	$p(r_j = 0, C_1)$	$p(r_j = 1, C_2)$	$p(r_j = 0, C_2)$	$p(r_j = 1)$	$p(r_j = 0)$
<i>lottery</i>	m_1	2/8	2/8	0/8	4/8	2/8	6/8
<i>customer</i>	m_2	1/8	3/8	0/8	4/8	1/8	7/8
<i>purchase</i>	m_3	2/8	2/8	1/8	3/8	3/8	5/8
<i>learn</i>	m_4	0/8	4/8	2/8	2/8	2/8	6/8
<i>money</i>	m_5	3/8	1/8	0/8	4/8	3/8	5/8
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮

Etude de cas: classification de spams

$$I('lottery', C_1) = \frac{2}{8} \log_2 \left(\frac{\frac{2}{8}}{\frac{2}{8} \times \frac{1}{2}} \right) + \frac{2}{8} \log_2 \left(\frac{\frac{2}{8}}{\frac{6}{8} \times \frac{1}{2}} \right) + 0 \log_2 \left(\frac{0}{\frac{2}{8} \times \frac{1}{2}} \right) + \frac{4}{8} \log_2 \left(\frac{\frac{4}{8}}{\frac{6}{8} \times \frac{1}{2}} \right) \approx 0.31$$

$$I('custumer', C_1) = \frac{1}{8} \log_2 \left(\frac{\frac{1}{8}}{\frac{1}{8} \times \frac{1}{2}} \right) + \frac{3}{8} \log_2 \left(\frac{\frac{3}{8}}{\frac{7}{8} \times \frac{1}{2}} \right) + \frac{0}{8} \log_2 \left(\frac{\frac{0}{8}}{\frac{1}{8} \times \frac{1}{2}} \right) + \frac{4}{8} \log_2 \left(\frac{\frac{4}{8}}{\frac{7}{8} \times \frac{1}{2}} \right) \approx 0.13$$

$$I('purchase', C_1) = \frac{2}{8} \log_2 \left(\frac{\frac{2}{8}}{\frac{3}{8} \times \frac{1}{2}} \right) + \frac{2}{8} \log_2 \left(\frac{\frac{2}{8}}{\frac{5}{8} \times \frac{1}{2}} \right) + \frac{1}{8} \log_2 \left(\frac{\frac{1}{8}}{\frac{3}{8} \times \frac{1}{2}} \right) + \frac{3}{8} \log_2 \left(\frac{\frac{3}{8}}{\frac{5}{8} \times \frac{1}{2}} \right) \approx 0.033$$

Les mots '*lottery*' et '*custumer*', sont plus discriminants que '*purchase*'.

Ce qui se fait actuellement

Ce processus passe par plusieurs étapes de **transformation et de manipulation du texte**, de plus en plus optimisées aujourd'hui grâce à l'évolution du NLP.

1. Nettoyage du texte

Le texte brut contient souvent du bruit inutile :

- Suppression de la ponctuation, des chiffres et des caractères spéciaux.
- Conversion en minuscules.
- Suppression des balises HTML ou des caractères invisibles.
- Élimination des stopwords (mots très fréquents comme "le", "de", "et") dans certains cas.

2. Tokenisation

Le texte est découpé en unités élémentaires :

- **Word-level tokenization** : division en mots.
- **Subword tokenization** (ex. WordPiece ou BPE) : utile pour les modèles de type Transformers (ex. BERT).
- **Sentence tokenization** si le contexte par phrase est requis.

3. Normalisation linguistique

- **Lemmatisation** : réduction des mots à leur forme canonique (ex. : "mangeons" → "manger").
- **Stemming** : coupe les mots à leur racine (ex. : "mangerait", "mangerons" → "mang").

Ce qui se fait actuellement

4. Encodage du texte

Le texte doit être converti en vecteurs numériques :

- **Bag of Words (BoW)** : compte de mots sans ordre.
- **TF-IDF** : pondération des mots selon leur importance dans un document.
- **Word Embeddings** : vecteurs denses préentraînés (Word2Vec, GloVe, FastText).
- **Contextual embeddings** : représentations issues de modèles Transformers comme BERT ou RoBERTa, qui tiennent compte du contexte dans lequel le mot apparaît.

5. Troncature et Padding

Les séquences textuelles sont normalisées à une longueur fixe :

- **Troncature** des séquences trop longues.
- **Padding** des séquences trop courtes avec des tokens spéciaux (ex. : [PAD]).

6. Augmentation de données (optionnelle)

Pour améliorer la robustesse du modèle :

- Synonymes (via WordNet), paraphrases, traduction automatique.
- Remplacement aléatoire de mots ou de groupes de mots.
- Back-translation (traduire et retraduire).

7. Séparation des jeux de données

- **Train/Test split**, souvent avec une validation croisée.
- Préservation de l'équilibre des classes dans le cas de classification binaire/multi-classes déséquilibrée.

Ce qui se fait actuellement

Qu'est-ce qu'un *embedding textuel* ?

Un **embedding textuel** est une représentation numérique d'un mot, d'une phrase ou d'un document sous forme de vecteur de nombres réels.

Au lieu de manipuler des mots sous forme brute (ex. : "chien", "manger", "Canada"), on les convertit en **vecteurs numériques** pour que les modèles de machine learning ou de deep learning puissent les traiter.

Exemple :

Mot	Vecteur (simplifié)
"chat"	[0.1, 0.4, -0.3, 0.8]
"chien"	[0.2, 0.3, -0.2, 0.9]
"voiture"	[0.9, -0.1, 0.4, 0.0]

Les mots ayant un **sens proche** sont représentés par des vecteurs **proches** dans l'**espace vectoriel**.

Ce qui se fait actuellement

Pourquoi utiliser BERT pour l'embedding textuel ?

Avant, on utilisait des méthodes simples comme :

- **Bag of Words** : basées sur la fréquence des mots, sans contexte.
- **TF-IDF** : pondère l'importance des mots, mais toujours sans contexte.
- **Word2Vec / GloVe** : génèrent des vecteurs de mots, mais un mot a **toujours le même vecteur**, peu importe le contexte.

Problème : le mot "banc" a un seul vecteur, qu'il s'agisse d'un banc pour s'asseoir ou d'un banc de poissons.

Laboratoire formatif

Laboratoire formatif

1. Charger l'ensemble des données d'entraînement et de validation 'sentiment analysis' de Kaggle <https://www.kaggle.com/datasets/jp797498e/twitter-entity-sentiment-analysis>.
2. Explorez les données et corrigez le problème des données manquantes.
3. Prétraitez les données en convertissant les sentiments en données numériques (0, 1, 2, 3) pour Negative, Neutral, Positive et ,,,.
4. Création du vecteur de caractéristiques en utilisant le sac de mots.
5. Entraînement du modèle de Bernoulli Naive Bayes, DecisionTreeClassifier, SVC et LogisticRegression.
6. Prédiction sur les données de validation.
7. Évaluation du modèle avec calcul de la précision et affichage du rapport de classification