

Transformation et manipulation de données



Dr Khadidja Henni

Séance 13- Fusion de données multimodales

Plan de cours

- Les modalités des données
- La fusion des données
- Laboratoire formatif

Modalités des données

Introduction

La **fusion de données multimodales** consiste à combiner plusieurs sources d'information, appelées **modalités**, qui peuvent être très différentes dans leur nature :

- **Texte** (articles, sous-titres, transcriptions),
- **Images** (photos, IRM, radiographies),
- **Audio** (parole, musique, signaux vocaux),
- **Signaux** (EEG, ECG, capteurs IoT),
- **Vidéo** (séquence d'images + son).

L'objectif est de **résoudre une tâche commune** (comme la classification, la détection ou la prédiction) en s'appuyant sur la **complémentarité** de ces modalités.

Une seule modalité peut être limitée :

- Une **image** donne l'apparence mais pas le contexte.
- Le **texte** donne du sens, mais pas l'aspect visuel.
- Un **signal** ECG détecte une activité cardiaque, mais sans localisation anatomique.
- En **fusionnant ces sources**, on obtient une **représentation plus riche, plus robuste et souvent plus précise**.

Introduction

1. Reconnaissance d'émotion humaine :

1. Image → expressions faciales,
2. Audio → intonation de la voix,
3. Texte → choix des mots.

→ La fusion des trois donne une meilleure analyse émotionnelle.

2. Médecine multimodale :

1. IRM → anomalies structurelles du cerveau,
2. Données cliniques textuelles → antécédents médicaux,
3. EEG → activité électrique.

→ Fusionner ces données améliore le diagnostic d'Alzheimer ou d'épilepsie.

3. Multimédia (YouTube, Netflix) :

1. Vidéo → contenu visuel,
2. Audio → bande sonore,
3. Texte → sous-titres ou résumé.

→ Améliore la recherche et la recommandation de contenu.

Objectifs de la fusion multimodale

La fusion de données multimodales poursuit plusieurs **objectifs clés** qui justifient son usage dans de nombreux domaines :

- 1. Complémentarité:** Chaque modalité apporte une **information unique** qui n'est pas toujours présente dans les autres.
 - Exemple : en biomédical, l'IRM donne des images structurales du cerveau tandis que l'EEG fournit l'activité électrique en temps réel.
 - En combinant les deux, on couvre à la fois la structure et la dynamique.
- 2. Robustesse:** Un système multimodal peut rester **fiable même si une modalité est absente, bruitée ou défailante**.
 - Exemple : dans une vidéoconférence, si le son est de mauvaise qualité, les expressions faciales (vidéo) permettent encore de détecter l'émotion.
 - Dans un réseau de capteurs IoT, si un capteur tombe en panne, d'autres modalités peuvent compenser.
- 3. Précision accrue:** La combinaison de plusieurs sources permet une **meilleure généralisation et de meilleures performances prédictives**.
 - Exemple : un modèle qui analyse à la fois les pixels d'une radiographie et le rapport médical du patient obtient de meilleures performances qu'un modèle basé uniquement sur l'image.
- 4. Interprétabilité:** La fusion permet aussi d'obtenir des résultats plus **explicables**.
 - Exemple : un diagnostic médical est plus convaincant s'il s'appuie sur une corrélation entre une image IRM, un signal ECG et un rapport clinique écrit.
 - En IA, un modèle multimodal peut justifier une décision en citant à la fois une preuve visuelle et textuelle.

Par exemple: Recherche d'information multimédia : un film peut être retrouvé par son affiche (image), son résumé (texte), ou un extrait sonore (audio) → Précision accrue grâce à la combinaison.

Exemples d'applications multimodales

La fusion multimodale trouve des applications dans **de nombreux domaines**, chacun exploitant la complémentarité entre plusieurs types de données :

1. Domaine médical: Les médecins combinent souvent **images médicales (IRM, scanner)**, **signaux physiologiques (ECG, EEG)** et **données cliniques textuelles** (comptes rendus, antécédents).

- Exemple : pour détecter la maladie d'Alzheimer, un système peut fusionner l'IRM (structure cérébrale), l'EEG (activité électrique), et un test cognitif (texte).
- Avantage : diagnostic plus précis et réduction du risque d'erreurs médicales.

2. Reconnaissance d'émotions humaines: Les émotions se manifestent de façon **multicanale** :

- Visage → expressions (images),
- Voix → ton et intensité (audio),
- Langage → choix des mots (texte).

Exemple : un assistant vocal intelligent (comme Alexa ou Siri) peut détecter la colère ou la joie en combinant la voix et les mots, renforcés par l'analyse faciale.

Exemples d'applications multimodales

3. **Smart Grids (réseaux électriques intelligents):** Les opérateurs énergétiques fusionnent :

- Données de capteurs électriques (tension, courant),
- Informations météorologiques (soleil, vent, température),
- Données de consommation historiques.

Exemple : optimiser la distribution d'énergie en tenant compte des prévisions météo et de la demande des utilisateurs.

Avantage : meilleure gestion des ressources et réduction des coûts énergétiques.

4. **Multimédia et vidéos:** Les plateformes comme YouTube, Netflix ou TikTok utilisent la fusion pour :

- Générer automatiquement des **sous-titres** (vidéo + audio),
- Recommander des contenus (texte des descriptions + image des affiches + historique d'écoute),
- Détecter des scènes (fusion image + son).

Principaux défis de la fusion multimodale

Même si la fusion multimodale offre des avantages considérables, sa mise en œuvre pratique présente de **grands défis techniques et scientifiques** :

1. Hétérogénéité des données:

- Les modalités n'ont pas le même format :
 - Les **images** sont des matrices de pixels,
 - Le **texte** est une séquence de mots,
 - L'**audio** est un signal temporel continu,
 - Les **signaux biomédicaux** (ECG, EEG) sont des séries temporelles multi-capteurs.
- Fusionner ces représentations demande des techniques adaptées (CNN, RNN, embeddings, normalisation).
- Exemple : comment mettre en correspondance un vecteur de 1 000 pixels et une phrase de 10 mots ?

2. Désynchronisation temporelle

- Certaines modalités ne sont pas alignées dans le temps.
- Exemple : dans une vidéo, l'image (30 fps) et l'audio (44 kHz) ne sont pas naturellement synchronisés.
- En biomédical, l'ECG (battements cardiaques) et l'EEG (activité cérébrale) ont des fréquences différentes.
- Solution : techniques de time alignment (Dynamic Time Warping, alignement attentionnel).

Principaux défis de la fusion multimodale

3. Données manquantes ou bruitées

- Dans la réalité, il est courant qu'une modalité soit absente ou corrompue.
- Exemple : lors d'un appel vidéo, la caméra peut être coupée, ou le micro saturé.
- En capteurs IoT, une panne peut interrompre une modalité.
- Le système doit être robuste et continuer à fonctionner avec les modalités restantes.

4. Haute dimension et coût computationnel

- Fusionner plusieurs modalités crée des vecteurs gigantesques.
- Exemple : concaténer une image (224×224), un texte (300 dimensions d'embedding) et un spectrogramme audio → vecteur de très haute dimension.
- Risque : surapprentissage (overfitting) et coûts de calcul très élevés.
- Solution : réduction de dimension (PCA, autoencodeurs, attention).

Les niveaux de fusion

La fusion multimodale peut être réalisée à **trois niveaux différents**, selon le moment où l'on combine les modalités dans la chaîne de traitement :

1. Early Fusion (fusion précoce)

- Les modalités sont combinées **dès le début**, soit au niveau des données brutes, soit après une extraction simple de caractéristiques.
- Exemple : concaténer des pixels d'images et des MFCC d'audio dans un seul vecteur.
- Avantage : exploite toute l'information brute, favorise les interactions entre modalités.
- Limite : sensible au bruit et aux différences de dimension (un texte court peut être « écrasé » par une image très riche en données).

2. Intermediate Fusion (fusion intermédiaire)

- Chaque modalité est d'abord traitée par un modèle spécialisé (CNN pour images, LSTM pour texte, CNN 1D pour signaux audio).
- On fusionne ensuite les **représentations latentes** apprises.
- Exemple : un CNN extrait des features visuelles et un LSTM extrait des features textuelles → les deux vecteurs sont concaténés avant la classification.
- Avantage : permet une meilleure exploitation des spécificités de chaque modalité.
- Limite : complexité accrue et besoin de synchroniser les représentations.

Les niveaux de fusion

3. Late Fusion (fusion tardive)

- Chaque modalité est traitée indépendamment jusqu'à la décision finale.
- Exemple : un CNN dit « chat », un RNN dit « chat », un SVM dit « chien » → on applique un vote majoritaire (2/3).
- Avantage : robuste si une modalité est manquante.
- Limite : perd les interactions riches entre modalités car elles ne sont jamais combinées avant la décision.

Niveau de fusion	Exemple typique	Avantage principal	Limite principale
Early Fusion	Pixels + MFCC concaténés → NB/SVM	Exploite toute l'info brute	Sensible au bruit et dimensions
Intermediate Fusion	CNN (image) + LSTM (texte) → dense layer	Capture le meilleur des deux	Plus complexe à entraîner
Late Fusion	CNN (image), RNN (texte), SVM (audio) → vote	Robuste si modalité absente	Pas d'interaction riche

Early Fusion (fusion précoce)

- La fusion précoce combine les données ou leurs caractéristiques dès le début du pipeline de traitement.
- Concrètement, on concatène directement les vecteurs issus de plusieurs modalités pour former un vecteur unique qui sera traité par un modèle de classification ou de régression.

Exemple simple : Pour un système multimédia, on peut prendre :

- Les **MFCC** (coefficients cepstraux) d'un signal audio (vecteur de 50 dimensions),
- Les **pixels normalisés** d'une image (vecteur de 784 dimensions pour une image 28×28),
- Les fusionner en un vecteur combiné (834 dimensions),
- Puis appliquer un classifieur (Naïve Bayes, SVM ou réseau dense).

Cette méthode est intuitive et exploite toute l'information brute disponible.

Early Fusion (fusion précoce)

Limites:

- **Sensibilité au bruit** : une modalité bruitée peut dégrader toute la fusion.
- **Différences d'échelle** : texte, image et audio n'ont pas les mêmes dimensions → une modalité peut dominer artificiellement l'autre.
- **Explosion dimensionnelle** : concaténer plusieurs vecteurs très riches crée un vecteur énorme → risque de **surapprentissage (overfitting)**.
- **Problème de données manquantes** : difficile à gérer si une modalité est absente.

Avantages:

- **Simplicité conceptuelle** : facile à implémenter.
- **Exploitabilité totale** : toutes les caractéristiques sont intégrées dans un même espace.
- **Capacité d'interaction** : permet au modèle d'apprendre directement des relations croisées entre modalités.

Intermediate Fusion (fusion intermédiaire)

- La fusion intermédiaire traite chaque modalité par un modèle spécialisé afin d'extraire une représentation latente optimisée.
- Ces représentations sont ensuite fusionnées (concaténation, somme pondérée, attention croisée, etc.) pour alimenter un classifieur commun.

Exemple concret de pipeline :

- **Image** → CNN (ex. : ResNet) → vecteur latent (512 dimensions).
- **Texte** → LSTM ou Transformer → vecteur latent (300 dimensions).
- **Audio** → CNN 1D sur spectrogrammes → vecteur latent (128 dimensions).
- **Fusion** des trois vecteurs → couche dense → classifieur final (ex. softmax pour une classification).

Cette approche s'inspire de la logique humaine : **on analyse chaque modalité séparément, puis on combine nos conclusions partielles.**

Intermediate Fusion (fusion intermédiaire)

Avantages

- **Exploitation spécialisée** : chaque modalité est traitée par un réseau adapté (CNN pour images, RNN/Transformer pour séquences, etc.).
- **Meilleure performance** : les représentations latentes capturent des patterns profonds propres à chaque modalité.
- **Flexibilité** : facile d'ajouter ou de retirer une modalité.
- **Meilleure robustesse aux différences de nature des données.**

Limites

- **Complexité architecturale** : plusieurs modèles doivent être entraînés simultanément.
- **Temps de calcul plus long** : surtout pour les réseaux profonds multimodaux.
- **Problème d'alignement** : les représentations latentes doivent être synchronisées (dans le temps ou dans le sens sémantique).
- **Besoin de grandes bases de données** pour éviter le surapprentissage.

Late Fusion (fusion tardive)

- La fusion tardive traite chaque modalité de manière totalement indépendante jusqu'à la prédiction finale, puis à combiner les sorties des modèles pour prendre une décision globale.
- chaque modalité a son propre modèle, et la fusion se fait au niveau des décisions (probabilités ou labels).

Exemple illustratif :

- Un **CNN** analyse une image et prédit « chat » avec 85 % de probabilité.
- Un **RNN** lit une description textuelle et prédit « chat » avec 70 %.
- Un **SVM** traite un signal audio associé et prédit « chien » avec 65 %.
- La fusion par **vote majoritaire** (2 contre 1) donne la décision finale : « **chat** ».

Cette méthode est proche de l'approche humaine : plusieurs experts donnent chacun leur avis, puis on combine leurs votes

Late Fusion (fusion tardive)

Avantages

- **Robustesse** : si une modalité est manquante ou bruitée, les autres continuent à fonctionner.
- **Flexibilité** : possibilité d'ajouter ou retirer un modèle sans redéfinir toute l'architecture.
- **Simplicité** : plus facile à implémenter qu'une fusion intermédiaire complexe.

Limites:

- **Perte d'information croisée** : les modèles ne partagent pas leurs représentations, donc les **corrélations riches entre modalités sont ignorées**.
- **Moins performant** que l'intermediate fusion dans les tâches nécessitant une forte interaction entre données.
- **Décision parfois arbitraire** si les modèles sont très déséquilibrés en performance.

Méthodes classiques de fusion

- Avant l'essor du deep learning, la fusion multimodale reposait principalement sur des méthodes classiques de combinaison des décisions ou des caractéristiques.
- Ces approches sont encore utilisées aujourd'hui dans certains systèmes car elles sont simples, interprétables et peu coûteuses en calcul.

Voici les principales méthodes :

1. **Vote majoritaire (Majority Voting):**

- Chaque modèle (ou modalité) donne une prédiction.
- La décision finale est celle de la majorité.

Exemple :

- Modèle image → « chat »
- Modèle audio → « chien »
- Modèle texte → « chat »
- Décision finale = « chat » (2 contre 1).

Utilisé dans des systèmes de sécurité ou de diagnostic médical assisté.

Méthodes classiques de fusion

```
import numpy as np
from sklearn.naive_bayes import GaussianNB
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
from scipy.stats import mode
```

```
# =====
# 1) Données synthétiques
```

```
# =====
np.random.seed(0)
X = np.random.randn(200, 4) # 4 features
y = (X[:, 0] + X[:, 1] > 0).astype(int) # classe 0 ou 1
```

```
# Split train/test
X_train, X_test = X[:150], X[150:]
y_train, y_test = y[:150], y[150:]
```

```
# =====
# 2) Trois modèles (dont 2 NB)
```

```
# =====
model_img = GaussianNB() # "modèle image"
model_audio = GaussianNB() # "modèle audio"
model_text = LogisticRegression(max_iter=200) # "modèle texte"
```

```
model_img.fit(X_train[:, :2], y_train) # image = 2 premières features
model_audio.fit(X_train[:, 2:], y_train) # audio = 2 dernières features
model_text.fit(X_train, y_train) # texte = toutes les features
```

```
# =====
# 3) Prédictions individuelles
```

```
# =====
pred_img = model_img.predict(X_test[:, :2])
pred_audio = model_audio.predict(X_test[:, 2:])
pred_text = model_text.predict(X_test)
```

```
# =====
# 4) Vote majoritaire
```

```
# =====
preds = np.vstack([pred_img, pred_audio, pred_text]).T # shape (n_samples, 3)
# mode renvoie la valeur majoritaire par ligne
y_pred_vote = mode(preds, axis=1, keepdims=False).mode
```

```
# =====
# 5) Évaluation
```

```
# =====
print("Accuracy image-only :", accuracy_score(y_test, pred_img))
print("Accuracy audio-only :", accuracy_score(y_test, pred_audio))
print("Accuracy texte-only :", accuracy_score(y_test, pred_text))
print("Accuracy vote-major :", accuracy_score(y_test, y_pred_vote))
```

Méthodes classiques de fusion

2. Somme pondérée des probabilités (Weighted Sum)

- Chaque modèle fournit une probabilité associée à chaque classe.
- On combine ces probabilités avec des poids (selon la fiabilité du modèle).

Exemple :

- CNN (image) → 0.8 « chat », 0.2 « chien »
- RNN (texte) → 0.6 « chat », 0.4 « chien »
- Pondération : image = 70 %, texte = 30 %.
- Fusion : $0.8 \times 0.7 + 0.6 \times 0.3 = 0.74$ « chat »
→ Décision finale : « chat ».

Utile quand certains modèles sont plus fiables que d'autres.

3. Bayes naïf multimodal

- On suppose que chaque modalité est **indépendante** et contribue à la probabilité finale.

Exemple :

$$P(\text{classe} \mid \text{image}, \text{texte}, \text{audio}) \\ \propto P(\text{image} \mid \text{classe}) \times P(\text{texte} \mid \text{classe}) \times P(\text{audio} \mid \text{classe}).$$

- Méthode rapide, mais la supposition d'indépendance est souvent irréaliste.
- Utilisée historiquement en **classification de documents multimédias**.

On veut classer un contenu en « **chat** » ou « **chien** »

Par une image, un **texte descriptif**, un **signal audio**.

Supposons que :

- Le modèle image estime : $P(\text{image} \mid \text{chat}) = 0.9$, $P(\text{image} \mid \text{chien}) = 0.1$.
- Le modèle texte estime : $P(\text{texte} \mid \text{chat}) = 0.7$, $P(\text{texte} \mid \text{chien}) = 0.3$.
- Le modèle audio estime :
 $P(\text{audio} \mid \text{chat}) = 0.6$, $P(\text{audio} \mid \text{chien}) = 0.4$.

Calcul avec Bayes naïf multimodal

- Pour la classe « chat » :
 $P(\text{chat} \mid \text{image}, \text{texte}, \text{audio}) \\ \propto 0.9 \times 0.7 \times 0.6 = 0.378$
- Pour la classe « chien » :
 $P(\text{chien} \mid \text{image}, \text{texte}, \text{audio}) \\ \propto 0.1 \times 0.3 \times 0.4 = 0.012$

est « **chat** ».

Méthodes classiques de fusion

```
# =====  
# 2) ENTRAÎNEMENT BAYES NAÏF MULTIMODAL  
# =====  
clf = GaussianNB()  
clf.fit(X, y)  
  
# Prédiction  
y_pred = clf.predict(X)  
acc = accuracy_score(y, y_pred)  
  
print(f"Accuracy (Naive Bayes multimodal): {acc:.3f}")  
  
# =====  
# 3) PROBABILITÉS POUR UN NOUVEL ÉCHANTILLON  
# =====  
# Supposons qu'on observe: image ~ [1.8, 2.1], audio ~ [1.2, 0.8]  
x_new = np.array([[1.8, 2.1, 1.2, 0.8]])  
proba = clf.predict_proba(x_new)[0]  
  
print("\nNouvel échantillon:", x_new)  
print(f"P(chat) = {proba[0]:.3f}")  
print(f"P(chien) = {proba[1]:.3f}")  
print("Classe prédite:", "chat" if proba[0] > proba[1] else "chien")
```

➤ Accuracy (Naive Bayes multimodal): 1.000

```
Nouvel échantillon: [[1.8 2.1 1.2 0.8]]  
P(chat) = 1.000  
P(chien) = 0.000  
Classe prédite: chat
```

Méthodes classiques de fusion

Méthodes d'ensemble (Ensemble Methods)

- On utilise des algorithmes comme **Random Forest** ou **Boosting (AdaBoost, XGBoost)** pour combiner des features issues de plusieurs modalités.
- Exemple : concaténer des descripteurs d'image (SIFT), des fréquences audio (MFCC) et des mots-clés textuels, puis entraîner une Random Forest.
- Avantage : bonne performance, robustesse.
- Limite : difficile à gérer avec des données de très grande dimension.

Méthodes avancées de fusion multimodale (Deep Learning)

Avec l'essor du **Deep Learning**, la fusion multimodale s'appuie sur des architectures capables d'apprendre automatiquement des représentations complexes et d'interagir entre modalités.

Voici quelques méthodes avancées :

1. Architectures multi-branche

- Chaque modalité a un sous-réseau dédié (CNN pour images, LSTM/Transformer pour texte, CNN 1D pour audio).
- Les vecteurs latents sont fusionnés via concaténation ou couches denses.
- Exemple : un CNN traite une image, un LSTM traite un texte, puis les deux représentations sont concaténées avant une couche softmax.

2. Mécanismes d'attention (Attention & Cross-Attention)

- L'attention permet au modèle de pondérer dynamiquement l'importance de chaque modalité.
- Exemple : pour une question visuelle (« Quelle est la couleur de la voiture ? »), le modèle peut accorder plus de poids à l'image qu'au texte.
- Cross-attention → une modalité « guide » l'autre (ex. texte qui guide l'exploration d'une image).
- Utilisé dans des modèles comme **ViLBERT**, **LXMERT**.

Laboratoire formatif

Étapes :

1. Charger les données

- Charger le fichier digits_text_labels.csv
- Charger le dataset load_digits() depuis sklearn

2. Associer les modalités

- Utiliser image_id pour récupérer l'image correspondante
- Séparer :
 - Image (pixels)
 - Texte
 - Label

3. Prétraitement

- Normaliser les pixels (StandardScaler)
- Transformer le texte en Bag-of-Words (CountVectorizer)
- Séparer train / test (80/20)

4. Modèle Image seule

- Entraîner un classifieur (Logistic Regression, SVM ou RF)
- Calculer accuracy

5. Modèle Texte seul

- Entraîner un classifieur
- Calculer accuracy

6. Early Fusion

- Concaténer les features image + texte
- Entraîner un modèle unique
- Évaluer (accuracy, recall, F1)

7. Late Fusion

- Entraîner un modèle image
- Entraîner un modèle texte
- Combiner les prédictions (vote majoritaire ou moyenne des probabilités)
- Évaluer les performances

8. Analyse

- Comparer les performances
- Discuter :
 - Quelle modalité domine ?
 - La fusion améliore-t-elle ?
 - Différence Early vs Late ?