Titre du cours : Mise en place d'un écosystème d'IA
Code officiel : 420-A57-BB
Professeur : Dr Komi SODOKE

MODULE 05

Contrôler et entretenir l'infrastructure matérielle dans le contexte de l'IA

Spécialisation technique en Intelligence Artificielle

Monitoring | **Alertes & Métriques** | **Maintenance**

PLAN DU COURS

Objectif terminal : Contrôler et entretenir l'infrastructure matérielle dans le contexte de l'IA

I	**Introduction** Pourquoi surveiller et maintenir une infrastructure IA
II	**Systèmes de veille (monitoring)** APM · Watchdog · Prometheus · Grafana · nvidia-smi · htop
III	**Alertes et métriques** Métriques clés GPU/CPU/RAM/Disque · Seuils d'alerte · Dashboards
IV	**Signes avant-coureurs d'une défaillance** GPU · Disque · RAM · Réseau · Détection précoce
V	**Impacts des dégradations sur les opérations IA** Entraînement · Inférence · Données · Coûts
VI	**Questions de compréhension** Quiz avec réponses
VII	**Conclusion & Synthèse**

I

Introduction

Un système IA non surveillé est un système qui va tomber en panne



I — Rappel : le parcours complet

Section I

Ce module est le dernier du programme. Nous allons apprendre à maintenir vivant tout ce que nous avons construit.

Module 1

Besoins matériels

Choix des composantes (CPU, GPU, RAM).

Module 2

Environnement matériel

Installation OS, pilotes, réseau.

Module 3

Environnement logiciel

Python, IDE, PyTorch, TensorFlow.

Module 4

Virtualisation

Docker, Cloud, Big Data.

Module 5

Maintenance

Monitoring, alertes, prévention des pannes.

Pourquoi ce module est critique :

Un GPU qui surchauffe	peut s'arrêter en plein entraînement de 3 jours. Résultat : tout est perdu, il faut recommencer.
Un SSD qui s'use silencieusement	peut corrompre vos datasets ou vos modèles sauvegardés sans prévenir.
Un réseau dégradé	ralentit l'entraînement distribué et peut faire échouer la synchronisation entre GPU.

I — Qu'est-ce que le monitoring ?

Section I

Le monitoring (surveillance ou veille) est l'observation continue et automatisée de l'état de santé d'un système informatique. Il consiste à collecter des métriques (température, utilisation CPU/GPU, mémoire, espace disque), les afficher sur des tableaux de bord (dashboards), et déclencher des alertes quand un seuil critique est dépassé. L'objectif : détecter les problèmes AVANT qu'ils ne causent une panne.

Analogie : Le monitoring, c'est comme le tableau de bord d'une voiture. Vous voyez la vitesse, la température du moteur, le niveau d'essence. Si un voyant s'allume, vous savez qu'il faut agir AVANT la panne. Sans tableau de bord, vous roulez à l'aveugle.

Les 4 piliers du monitoring en IA :

Observer

Collecter en temps réel les métriques du système : température GPU, usage RAM, I/O disque, latence réseau.

Alerter

Déclencher une notification (email, SMS, Slack) quand un seuil est dépassé : GPU > 85°C, disque > 90%.

Analyser

Visualiser les tendances sur des dashboards : la température monte-t-elle progressivement ? Le disque se remplit-il ?

Agir

Intervenir avant la panne : réduire la charge GPU, ajouter du stockage, remplacer un disque vieillissant.

II

Systèmes de veille (monitoring)

APM · Watchdog · Prometheus · Grafana · nvidia-smi



II.A — Outils de monitoring en ligne de commande

Section II

Ces outils sont disponibles sur toute machine Linux. Ils constituent la première couche de monitoring, accessible immédiatement.

nvidia-smi

L'outil n°1 pour les GPU NVIDIA. Affiche en temps réel : nom du GPU, température, utilisation GPU (%), utilisation VRAM, processus en cours, consommation électrique. Indispensable pendant l'entraînement.

```
nvidia-smi                    # Snapshot unique
watch -n 1 nvidia-smi          #
Rafraîchissement chaque seconde
```

htop

Moniteur système interactif. Affiche : tous les processus, usage CPU par cœur, RAM utilisée/disponible, swap. Plus lisible que top grâce aux barres de progression colorées.

```
htop                           # Interface
interactive
```

df -h / iostat

df -h montre l'espace disque disponible sur chaque partition. iostat (paquet sysstat) mesure les performances I/O du disque : débit lecture/écriture, temps d'attente. Crucial pour détecter un goulot d'étranglement disque.

```
df -h                          # Espace disque
sudo apt install sysstat && iostat -x 1  # I/O
en temps réel
```

sensors / lm-sensors

Affiche les températures matérielles : CPU, carte mère, ventilateurs. Complète nvidia-smi qui ne surveille que le GPU.

```
sudo apt install lm-sensors && sensors  #
Températures
```

II.B — Prometheus : le collecteur de métriques

Section II

Prometheus est un système open-source de monitoring et d'alerte. Il collecte des métriques numériques (températures, usage CPU, latences) depuis vos serveurs à intervalles réguliers (toutes les 15 secondes par défaut), les stocke dans une base de données temporelle (time-series), et permet de définir des règles d'alerte. C'est le standard de l'industrie pour le monitoring d'infrastructure.

Fonctionnement : Prometheus « tire » (pull) les métriques depuis vos serveurs via HTTP. Chaque serveur expose ses métriques sur un endpoint (ex : http://serveur:9090/metrics). Prometheus les récupère automatiquement.

Architecture Prometheus :

Exporters	Petits programmes qui exposent les métriques d'un service. node_exporter (CPU, RAM, disque), dcgm-exporter (GPU NVIDIA), mysqld_exporter (base de données).
Prometheus Server	Collecte les métriques depuis les exporters, les stocke en time-series, et évalue les règles d'alerte. Interface web intégrée pour les requêtes PromQL.
Alertmanager	Reçoit les alertes de Prometheus et les route vers les bons canaux : email, Slack, PagerDuty, SMS. Gère le regroupement et la déduplication des alertes.
Grafana (visualisation)	Se connecte à Prometheus pour créer des dashboards visuels magnifiques. Graphiques en temps réel, historiques, annotations. Le couple Prometheus+Grafana est LE standard.

II.C — Grafana : la visualisation

Section II

Grafana est un outil open-source de visualisation de données. Il se connecte à des sources de données (Prometheus, InfluxDB, MySQL) et crée des dashboards interactifs avec des graphiques en temps réel. En IA, un dashboard Grafana typique affiche : la température GPU, l'utilisation VRAM, la loss d'entraînement, le débit réseau et l'espace disque restant — tout sur un seul écran.

Éléments d'un dashboard IA typique :

GPU Temperature

`72°C`

Courbe temps réel (°C). Zone verte (<70°C), jaune (70-85°C), rouge (>85°C). Si rouge → réduire la charge.

GPU Memory Usage

`18/24 Go (75%)`

Jauge avec % utilisé. Si >95% → risque d'OOM (Out of Memory). Réduire le batch size.

CPU Load Average

`6.2 / 16 cœurs`

Charge moyenne sur 1, 5 et 15 minutes. Si > nombre de cœurs → le CPU est saturé.

Disk Space

`450 Go / 1 To (55%)`

Espace restant sur chaque partition. Alerte si <10%. Les checkpoints et logs remplissent vite le disque.

Network I/O

`120 Mo/s`

Débit entrant/sortant en Mo/s. Important pour l'entraînement distribué et le chargement de données.

Training Loss

`0.042 (↓)`

Courbe de la loss au fil des epochs. Si elle stagne ou monte → problème d'hyperparamètres ou de données.

II.D — APM et Watchdog

Section II

APM

Application Performance Monitoring

L'APM surveille les performances des APPLICATIONS (pas du matériel). Il mesure : temps de réponse de l'API, taux d'erreurs, latence des requêtes. Outils : Datadog APM, New Relic, Elastic APM.

- Mesure le temps d'inférence du modèle
- Détecte les requêtes lentes ou échouées
- Trace le parcours d'une requête à travers les services

Watchdog

Le « chien de garde » du système

Un watchdog est un mécanisme qui surveille si un processus est toujours actif. S'il ne répond plus dans un délai donné, le watchdog le redémarre automatiquement. Comme un gardien qui vérifie régulièrement que la porte est fermée.

- systemd watchdog : redémarre un service Linux automatiquement
- Hardware watchdog : timer matériel qui redémarre la machine si l'OS plante
- Supervisord : gestionnaire de processus Python avec auto-restart

Watchdog Docker : redémarrage automatique

```
# Le conteneur redémarre automatiquement s'il crashe
docker run --restart=unless-stopped mon-api-ia

# Healthcheck intégré dans Docker
HEALTHCHECK --interval=30s CMD curl -f http://localhost:8000/health || exit 1
```

III

Alertes et métriques

Métriques clés · Seuils d'alerte · Dashboards



III.A — Métriques clés pour le GPU

Section III

Métrique	Unité	OK ✓	Attention ⚠	Critique ✗	Commande	Action si critique
Température GPU	°C	< 70	70-85	> 85	`nvidia-smi`	Surchauffe → throttling (réduction automatique de la fréquence) → entraînement plus lent
Utilisation GPU	% compute	80-100	50-80	< 50	`nvidia-smi`	Usage < 50% = goulot d'étranglement (CPU, I/O, réseau ou batch size trop petit)
Utilisation VRAM	%	< 85	85-95	> 95	`nvidia-smi`	Si 95%+ → risque d'erreur OOM (Out of Memory). Réduire batch size ou modèle
Power Draw	Watts	Normal	TDP-10%	≥ TDP	`nvidia-smi`	Si = TDP → GPU à pleine charge, vérifier la ventilation
ECC Errors	count	0	1-10	> 10	`nvidia-smi -q`	Erreurs mémoire GPU. >10 = mémoire défectueuse, envisager le remplacement



Règle d'or : nvidia-smi doit tourner en permanence pendant tout entraînement. Commande recommandée : watch -n 2 nvidia-smi (rafraîchit toutes les 2 secondes). Sur un serveur distant, ouvrir un terminal SSH dédié au monitoring.

```
# Monitoring GPU continu avec log dans un fichier
nvidia-smi --query-gpu=timestamp,name,temperature.gpu,utilization.gpu,utilization.memory,memory.used \
  --format=csv -l 5 > gpu_log.csv &
# Lire les logs : tail -f gpu_log.csv
```

III.B — Métriques CPU, RAM et Disque

Section III

Métrique	Unité	OK ✓	Attention ⚠	Critique ✗	Commande	Action si critique
CPU Load Average	ratio	< nb_cœurs	= nb_cœurs	>> nb_cœurs	`htop / uptime`	Trop de processus concurrents. Le CPU est le goulot d'étranglement du data loading.
RAM utilisée	%	< 80	80-90	> 90	`free -h / htop`	Si > 90% → le système utilise le swap (disque) → ralentissement massif de tout.
Swap utilisé	Mo/Go	0	< 1 Go	> 1 Go	`free -h`	Si le swap est utilisé → la RAM est insuffisante. Ajouter de la RAM ou réduire les données en mémoire.
Espace disque	%	< 80	80-90	> 90	`df -h`	Les checkpoints, logs et datasets remplissent vite le disque. Nettoyer régulièrement.
I/O Disk Wait	%	< 5	5-20	> 20	`iostat -x 1`	Si > 20% → le disque est le goulot d'étranglement. Le GPU attend les données. Passer en NVMe.



Script de monitoring rapide : vous pouvez créer un script qui vérifie toutes ces métriques en une commande et envoie un email si un seuil est dépassé. C'est la base d'un système de monitoring « fait maison » avant d'installer Prometheus/Grafana.

```
# Script de vérification rapide
echo "=== SANTÉ SYSTÈME ==="
echo "CPU Load: $(uptime | awk '{print $NF}')"
echo "RAM: $(free -h | awk '/Mem/{print $3"/"$2}')"
echo "Disk: $(df -h / | awk 'NR==2{print $5" used"}')"
nvidia-smi --query-gpu=temperature.gpu,utilization.gpu --format=csv,noheader 2>/dev/null || echo "No GPU"
```

III.C — Configurer des alertes

Section III

Une métrique sans alerte est une métrique inutile. L'alerte est le mécanisme qui vous prévient AVANT la catastrophe.

Email	Simple mais peut être ignoré. Utile pour les alertes non urgentes (disque à 80%). Gmail, Outlook ou serveur SMTP interne.
Slack / Discord	Notification dans un canal dédié (#alertes-ia). Vu immédiatement par toute l'équipe. Intégration facile avec Prometheus/Grafana.
SMS / PagerDuty	Pour les urgences critiques (serveur down, GPU en feu). Réveille quelqu'un à 3h du matin si nécessaire.
Webhook / API	Déclenche automatiquement une action : réduire la charge GPU, arrêter un entraînement, redémarrer un service.

Exemple de règle d'alerte Prometheus :

```
# alert_rules.yml — Alerte si GPU > 85°C pendant 5 minutes
groups:
  - name: gpu_alerts
    rules:
      - alert: GPU_Temperature_High
        expr: nvidia_gpu_temperature_celsius > 85
        for: 5m
        labels: { severity: critical }
        annotations: { summary: 'GPU surchauffe : {{ $value }}°C' }
```

IV

Signes avant-coureurs d'une défaillance

Détecter les problèmes avant la panne



IV.A — Défaillance GPU : signes et prévention

Section IV

Température anormalement élevée

La température monte au-delà de 85°C même pour des tâches légères. La pâte thermique est sèche ou les ventilateurs sont obstrués par la poussière.

Nettoyer les ventilateurs, vérifier le flux d'air du boîtier, remplacer la pâte thermique.

Erreurs CUDA pendant l'entraînement

Messages comme 'CUDA error: unspecified launch failure' ou 'GPU memory corruption'. Souvent causé par une VRAM défectueuse ou un driver instable.

Mettre à jour le driver, tester la VRAM avec gpu-burn. Si persistant : RMA le GPU.

Throttling fréquent

Le GPU réduit automatiquement sa fréquence pour protéger contre la surchauffe. L'entraînement est 30-50% plus lent que prévu.

Vérifier nvidia-smi : si 'Perf' montre P2 au lieu de P0, le GPU est limité. Améliorer le refroidissement.

Augmentation des ECC errors

Les erreurs de mémoire corrigées (correctable ECC) augmentent progressivement. Cela indique une dégradation de la VRAM.

Surveiller avec nvidia-smi -q | grep 'ECC'. Si > 100 erreurs corrigées : planifier le remplacement.

Artefacts visuels / résultats aberrants

Les calculs GPU produisent des résultats incorrects (NaN dans les gradients, images corrompues). La VRAM ou les cœurs CUDA sont endommagés.

Tester avec un benchmark GPU (gpu-burn, 3DMark). Si artefacts confirmés : GPU défectueux.

IV.B — Disque, RAM et Réseau : signes d'alerte

Section IV

SSD / NVMe

Vitesse de lecture/écriture qui diminue progressivement · Erreurs S.M.A.R.T. (smart data) : secteurs réalloués, nombre de wear leveling élevé · Temps de réponse I/O en hausse (iostat montre des await > 50ms)

Surveiller avec : sudo smartctl -a /dev/nvme0n1. Remplacer quand le TBW (Total Bytes Written) atteint 80% de la capacité annoncée.

HDD

Bruits mécaniques anormaux (clics, grincements) · Augmentation des secteurs défectueux dans S.M.A.R.T. · Temps d'accès qui augmente (> 20ms = vieillissement)

Backup immédiat si bruits anormaux. RAID pour la redondance. Remplacer préventivement après 3-4 ans en datacenter.

RAM

Crashs aléatoires de processus (segmentation fault) · Erreurs ECC corrigées en hausse (serveurs) · Blue screens / kernel panic sans cause logicielle

Tester avec memtest86+ (au boot). Si erreurs confirmées : remplacer la barrette défectueuse.

Réseau

Augmentation de la latence ping (>1ms en local → problème) · Paquets perdus (packet loss > 0.1%) · Débit qui ne correspond plus aux spécifications de la carte

Vérifier les câbles, le switch, et les drivers réseau. Pour l'entraînement distribué, un réseau dégradé peut doubler le temps d'entraînement.

V

Impacts des dégradations sur les opérations IA

Entraînement · Inférence · Données · Coûts



V.A — Impacts sur l'entraînement

Section V

Perte totale de l'entraînement

CRITIQUE

Si le GPU crashe à l'epoch 47/50, tout est perdu. Solution : sauvegarder des checkpoints réguliers (tous les 5 epochs minimum). PyTorch : torch.save(model.state_dict(), f'checkpoint_epoch_{epoch}.pt').

Entraînement silencieusement corrompu

SOURNOIS

Un GPU avec des erreurs mémoire peut produire des gradients incorrects. Le modèle converge... vers de mauvais résultats. Solution : valider sur un jeu de test à chaque epoch et surveiller les métriques.

Ralentissement progressif

COÛTEUX

Le GPU throttle à cause de la chaleur. L'entraînement prévu pour 24h prend 36h. Solution : monitorer nvidia-smi et vérifier que le GPU reste en mode P0 (performance maximale).

Saturation mémoire

FRÉQUENT

La RAM ou la VRAM se remplit progressivement (fuite mémoire). Après quelques heures, le système crashe. Solution : surveiller l'usage mémoire au fil du temps, pas seulement au démarrage.

V.B — Impacts sur l'inférence et bonnes pratiques

Section V

Impacts sur l'inférence (production)

- Latence qui augmente → l'API répond en 5s au lieu de 200ms
- Erreurs de prédiction → résultats incohérents (modèle corrompu en mémoire)
- Indisponibilité totale → le service tombe, les utilisateurs sont bloqués
- Coût cloud qui explose → GPU loué H24 pour compenser les ralentissements

Bonnes pratiques de maintenance

- Checkpoints toutes les 5 epochs (torch.save)
- Monitoring continu (nvidia-smi, htop en permanence)
- Alertes configurées (email/Slack si seuil dépassé)
- Nettoyage mensuel poussière + pâte thermique annuelle
- Tests matériels périodiques (memtest86, smartctl, gpu-burn)
- Backups automatiques des datasets et modèles (sur 2 supports minimum)

Calendrier de maintenance proposé

Fréquence	Actions	Commandes / Outils
Quotidien	Vérifier nvidia-smi, htop, espace disque	`watch nvidia-smi · df -h · htop`
Hebdomadaire	Vérifier les logs système, nettoyer les checkpoints anciens	`journalctl -p err · find . -name '*.pt' -mtime +30 -delete`
Mensuel	Mise à jour système + drivers, nettoyage poussière	`apt update && apt upgrade · nettoyage physique`
Trimestriel	Tests matériels complets, backup vérification	`memtest86+ · smartctl · gpu-burn 60`
Annuel	Remplacement pâte thermique GPU, évaluation de l'upgrade	`Pâte thermique · benchmarks comparatifs`

VI

Questions de compréhension

Testez vos connaissances sur le monitoring et la maintenance



VI — Questions de compréhension

Quiz

1. Qu'est-ce que le monitoring ? Donnez une analogie simple et citez 2 outils.
2. Quelle commande Linux permet de surveiller le GPU NVIDIA en temps réel ? Quelles informations affiche-t-elle ?
3. Quelle est la différence entre Prometheus et Grafana ? Pourquoi les utilise-t-on ensemble ?
4. Un GPU affiche 88°C pendant un entraînement. Est-ce normal ? Que faites-vous ?
5. Qu'est-ce qu'un watchdog ? Donnez un exemple concret en contexte IA.
6. Votre SSD montre des erreurs S.M.A.R.T. croissantes. Que signifie ce signe et quelle est l'action prioritaire ?
7. Pourquoi les checkpoints sont-ils indispensables pendant un entraînement long ?
8. Un entraînement prévu pour 24h prend 36h. Citez 3 causes possibles liées au matériel.
9. Qu'est-ce que le throttling GPU et comment le détecter avec nvidia-smi ?
10. Proposez un calendrier de maintenance pour un serveur IA en production (quotidien, hebdomadaire, mensuel).

VI — Réponses aux questions (1-5)

Quiz

1 — Monitoring ?

Observation continue et automatisée de l'état de santé d'un système. Analogie : tableau de bord d'une voiture (vitesse, température, essence). Outils : nvidia-smi (GPU), htop (CPU/RAM), Prometheus+Grafana (dashboards).

2 — Commande GPU ?

nvidia-smi affiche : nom du GPU, température (°C), utilisation GPU (%), utilisation VRAM (Mo), processus en cours, version du driver, version CUDA. Pour un monitoring continu : watch -n 1 nvidia-smi.

3 — Prometheus vs Grafana ?

Prometheus COLLECTE les métriques (pull HTTP toutes les 15s) et les STOCKE dans une base time-series. Grafana VISUALISE les données en créant des dashboards graphiques. Ensemble : Prometheus fournit les données, Grafana les rend lisibles.

4 — GPU à 88°C ?

Ce n'est PAS normal (seuil critique > 85°C). Actions : (1) vérifier les ventilateurs, (2) nettoyer la poussière, (3) réduire la charge (batch size), (4) améliorer le flux d'air du boîtier. Si ça persiste : remplacer la pâte thermique.

5 — Watchdog ?

Mécanisme qui surveille si un processus est actif. S'il ne répond plus, il le redémarre automatiquement. Exemple IA : un watchdog Docker redémarre l'API d'inférence si elle crashe (docker run --restart=unless-stopped).

VI — Réponses aux questions (6-10)

Quiz

6 **Erreurs S.M.A.R.T. ?**

S.M.A.R.T. (Self-Monitoring, Analysis and Reporting) est un système d'auto-diagnostic intégré aux disques. Des erreurs croissantes (secteurs réalloués, wear leveling élevé) signifient que le disque s'use. Action prioritaire : BACKUP IMMÉDIAT puis planifier le remplacement.

7 **Checkpoints ?**

Un checkpoint sauvegarde l'état du modèle (poids, optimizer, epoch) à un instant donné. Si le GPU crashe à l'epoch 47/50, on reprend depuis le dernier checkpoint au lieu de recommencer à zéro. Sans checkpoint = perte totale. Sauvegarder tous les 5 epochs minimum.

8 **Entraînement 36h au lieu de 24h ?**

3 causes matérielles : (1) Throttling GPU : température > 85°C → fréquence réduite automatiquement. (2) I/O disque lent : le GPU attend les données (HDD au lieu de NVMe). (3) RAM saturée : le système utilise le swap (disque) au lieu de la RAM → tout ralentit.

9 **Throttling GPU ?**

Le throttling est la réduction automatique de la fréquence GPU pour protéger contre la surchauffe. Dans nvidia-smi : la colonne 'Perf' montre P0 (max) à P8 (min). Si vous voyez P2 pendant un entraînement, le GPU est limité. Cause : surchauffe ou alimentation insuffisante.

10 **Calendrier maintenance ?**

Quotidien : nvidia-smi + htop + df -h. Hebdomadaire : vérifier logs système (journalctl), nettoyer les vieux checkpoints. Mensuel : apt update/upgrade, nettoyage poussière. Trimestriel : tests matériels (memtest86, smartctl, gpu-burn). Annuel : pâte thermique GPU, évaluer le besoin d'upgrade.

CONCLUSION



Le monitoring est obligatoire : nvidia-smi, htop et df -h doivent tourner en permanence pendant tout entraînement IA.



Les alertes sauvent des projets : configurez des seuils critiques (GPU >85°C, disque >90%, RAM >90%) avec notification automatique.



Prometheus + Grafana est le standard industriel pour les dashboards de monitoring. Investissez du temps à les installer.



Apprenez à reconnaître les signes avant-coureurs : température qui monte, erreurs S.M.A.R.T., throttling GPU, erreurs ECC.



Les checkpoints et les backups sont votre assurance-vie. Sans eux, une panne = tout recommencer à zéro.

Fin du programme : vous maîtrisez maintenant la mise en place complète d'un écosystème d'IA !

Glossaire — Termes clés

Référence

Terme	Définition
`Monitoring`	Surveillance continue et automatisée de l'état de santé d'un système informatique.
`APM`	Application Performance Monitoring. Surveillance des performances des applications (latence, erreurs).
`Watchdog`	Mécanisme qui surveille un processus et le redémarre automatiquement s'il ne répond plus.
`Prometheus`	Système open-source de collecte de métriques et d'alerte. Standard de l'industrie.
`Grafana`	Outil de visualisation de données. Crée des dashboards graphiques à partir de Prometheus.
`nvidia-smi`	Commande NVIDIA pour surveiller les GPU : température, usage, VRAM, processus.
`Throttling`	Réduction automatique de la fréquence du GPU pour protéger contre la surchauffe.
`S.M.A.R.T.`	Self-Monitoring, Analysis, Reporting Technology. Auto-diagnostic intégré aux disques.
`ECC`	Error Correcting Code. Mémoire capable de détecter et corriger les erreurs de bits.
`Checkpoint`	Sauvegarde de l'état d'un modèle en cours d'entraînement pour reprise en cas de panne.
`OOM`	Out of Memory. Erreur quand la VRAM ou la RAM est saturée. Réduire le batch size.
`TBW`	Total Bytes Written. Mesure de la durée de vie d'un SSD en volume de données écrites.