Titre du cours : Mise en place d'un écosystème d'IA
Code officiel : 420-A57-BB
Professeur : Dr Komi SODOKE

AEC : SPÉCIALISATION TECHNIQUE IA

Module 6 : Contrôle et Entretien Materiel

Garantir la pérennité et la performance de l'écosystème IA

INTRODUCTION AU MODULE

Pourquoi ce cours ?

La mise en place d'un écosystème d'IA ne s'arrête pas à l'installation des logiciels. Le matériel (GPU, CPU, Serveurs) est soumis à des contraintes thermiques et électriques extrêmes lors de l'entraînement de modèles lourds.

La finalité Permettre à l'étudiant de devenir le garant de la santé de l'infrastructure, capable de diagnostiquer une panne avant qu'elle ne détruise des semaines de travail de calcul.

Compétences visées

- Interpréter les besoins matériels.
- Configurer les outils de monitoring.
- Détecter les signes de défaillance.
- Maintenir l'infrastructure en condition opérationnelle.

PLAN DE L'APPRENTISSAGE



Veille & Monitoring

Comprendre les outils de surveillance active (APM, Watchdog).



Alertes & Métriques

Définir les seuils critiques pour prévenir les pannes.



Signes de Défaillance

Identifier les alertes physiques et logiques précoces.



Impacts Opérationnels

Évaluer les conséquences des pannes sur les projets IA.



Maintenance

Stratégies préventives et correctives industrielles.



Validation

Vérifier le bon fonctionnement de l'écosystème après intervention.

SECTION I

Systèmes de Veille et Monitoring

QU'EST-CE QUE LE MONITORING ?

Définition Générale

Le monitoring est le processus continu de collecte, d'analyse et de visualisation de données télémétriques provenant de votre infrastructure (serveurs, réseaux, capteurs).

Pourquoi en IA ? Les charges de travail (Training) sont extrêmement lourdes. Une fluctuation de 5% de température peut déclencher un ralentissement (throttling) qui double le temps d'entraînement.



L'APM : MONITORING APPLICATIF

APM

Application Performance Monitoring

L'APM ne surveille pas le matériel, mais la "santé" du logiciel d'IA. Il s'assure que le code s'exécute efficacement.

- **Latence :** Temps de réponse d'une prédiction.
- **Taux d'erreur :** Pourcentage de plantages du script.
- **Débit (Throughput) :** Nombre de requêtes traitées par seconde.

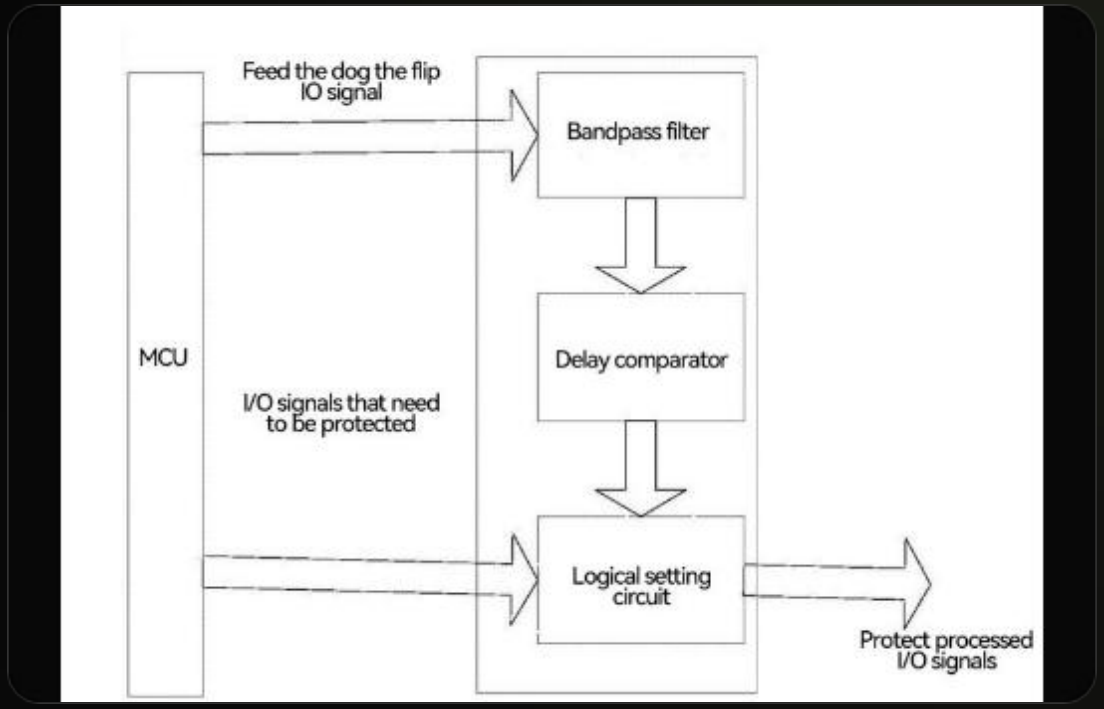
Exemple : Un modèle de vision par ordinateur qui passe de 30 FPS à 5 FPS sans raison apparente est détecté par l'APM.

LE CONCEPT DE WATCHDOG

Le "Chien de Garde"

Un Watchdog est un mécanisme (matériel ou logiciel) qui redémarre automatiquement un système ou un processus s'il ne répond plus.

> **Fonctionnement** Le script d'IA envoie périodiquement un signal "je suis vivant" (Heartbeat). Si le Watchdog ne reçoit plus ce signal après X secondes, il suppose un crash et force le redémarrage.



SECTION II

Alertes et Métriques Critiques

LA STACK DE VEILLE STANDARD

Pour un écosystème d'IA moderne, on utilise généralement la combinaison gagnante suivante :

1. Prometheus

Le moteur de collecte. Il interroge les serveurs à intervalles réguliers pour récupérer les chiffres (température, charge, RAM).

2. Grafana

L'interface visuelle. Elle transforme les chiffres bruts de Prometheus en graphiques et tableaux de bord lisibles.

3. AlertManager

Le cerveau décisionnel. Si une métrique dépasse un seuil, il envoie un e-mail ou un message Slack instantanément.

MÉTRIQUES GPU : LE CŒUR DE L'IA

Le GPU est la ressource la plus critique et la plus chère. Voici ce qu'il faut surveiller :

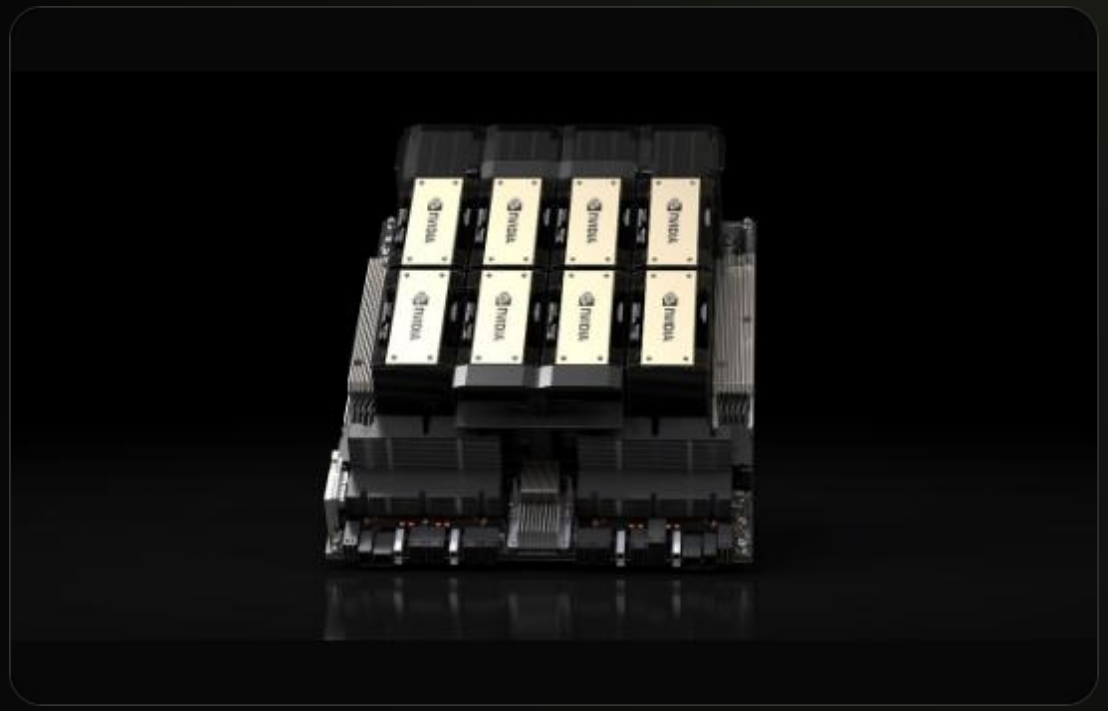
Métrique	Pourquoi la surveiller ?	Seuil Critique
GPU Utilization	Savoir si le modèle utilise bien la puissance disponible.	< 20% (Sous-utilisation)
GPU Temperature	Éviter le "Throttling" (baisse de fréquence auto).	> 83°C
VRAM Used	Éviter l'erreur "Out of Memory" (OOM).	> 90%
Power Draw	Détecter une alimentation défaillante.	> TDP Max

FOCUS : LA MÉMOIRE ECC

Error Correction Code

Contrairement à la RAM classique, la RAM/VRAM ECC peut détecter et corriger les erreurs de bits causées par des interférences ou la chaleur.

Indice de panne imminent Si le nombre d'erreurs "Single-bit" corrigées augmente soudainement, la barrette de mémoire est en train de mourir physiquement.



STOCKAGE ET SANTÉ NVME

En IA, on manipule des Teraoctets de données. Les disques SSD/NVMe ont une durée de vie limitée (TBW - Total Bytes Written).

- **S.M.A.R.T :** Self-Monitoring, Analysis, and Reporting Technology.
- **Wear Range :** Pourcentage d'usure des cellules mémoire.
- **Reallocated Sectors :** Secteurs défaillants remplacés.



SECTION III

Signes Avant-coureurs de Défaillance

SIGNES PHYSIQUES ET THERMIQUES



Bruits de ventilation

Des ventilateurs qui tournent à 100% en permanence ou qui font un bruit de frottement indiquent une obstruction ou une fin de vie mécanique.



Hausse de Base

Si la température "au repos" (IDLE) du serveur augmente de 10°C sur un mois, c'est le signe d'une accumulation de poussière sévère.



Micro-coupures

Des redémarrages aléatoires sous forte charge indiquent souvent une alimentation (PSU) qui ne supporte plus les pics de tension du GPU.

L'ENNEMI N°1 : LA POUSSIÈRE

Dans un écosystème IA, les serveurs brassent des volumes d'air massifs. La poussière crée un tapis isolant sur les composants.

> **Conséquence : Thermal Throttling** Le GPU réduit sa vitesse d'horloge pour ne pas fondre. Vous payez pour une carte à 5000$ qui fonctionne à la vitesse d'une carte à 500$.



SIGNES LOGIQUES : ERREURS XID

Interpréter les Logs Linux

Les pilotes NVIDIA génèrent des codes d'erreur "XID" dans les logs système (`dmesg`). Ils sont vitaux pour le diagnostic.

- **XID 48 :** Erreur de mémoire double-bit (Panne matérielle grave).
- **XID 63 :** Le GPU a dû isoler une zone de mémoire défectueuse.
- **XID 31 :** Problème d'initialisation (Souvent lié au bus PCIe).



SECTION IV

Impacts des Défaillances

IMPACTS SUR LES OPÉRATIONS

Perte de Travail

Un crash à la 99ème heure d'un entraînement de 100 heures peut corrompre les fichiers de sauvegarde (checkpoints).

Modèles "Biaisés"

Une défaillance mémoire subtile peut modifier aléatoirement quelques poids du réseau de neurones, rendant le modèle imprévisible.

Coûts Énergétiques

Un système inefficace consomme plus d'électricité pour dissiper moins de chaleur, augmentant la facture de 30% sans gain de calcul.

ÉTUDE DE CAS : LE CRASH GPT-4

Lors d'un entraînement majeur, un cluster de 1200 GPU a surchauffé simultanément à cause d'un angle mort du monitoring.

> **Bilan de la panne** - 15 Millions $ de matériel détruit.
> - 3 mois de retard sur le projet.
> - Cause : Monitoring thermique absent sur les jonctions mémoire.



SECTION V

Maintenance et Entretien

MAINTENANCE PRÉVENTIVE VS CORRECTIVE

Préventive (Proactive)

Agir avant la panne.

- Nettoyage trimestriel des filtres.
- Mise à jour des firmwares (VBIOS).
- Remplacement préventif des disques à 90% d'usure.

Corrective (Réactive)

Réparer après la panne.

- Remplacement d'un GPU grillé.
- Réinstallation d'un OS corrompu.
- Changement d'une alimentation.

LE CYCLE D'ENTRETIEN MATÉRIEL

Un technicien d'infrastructure IA doit suivre un calendrier strict pour préserver l'investissement.

Checklist Mensuelle 1. Inspection visuelle des câbles.
2. Analyse des logs d'erreurs corrigibles.
3. Test des onduleurs (UPS).
4. Vérification du débit d'air ambiant.



SECTION VI

Questions de Compréhension

AUTO-ÉVALUATION (PARTIE 1)

? Quelle est la différence entre une métrique et un log ?

Une métrique est une valeur numérique (ex: 75°C) mesurée à un instant T. Un log est un message textuel décrivant un événement précis (ex: "Connexion établie").

? Pourquoi le "Thermal Throttling" est-il dangereux pour un projet IA ?

Il ne casse pas le matériel, mais il réduit les performances de façon imprévisible, rendant les benchmarks et les délais d'entraînement impossibles à respecter.

AUTO-ÉVALUATION (PARTIE 2)

? À quoi sert la mémoire ECC en intelligence artificielle ?

> Elle évite que des erreurs de bits (0 qui devient 1) ne corrompent les données d'entraînement ou les paramètres du modèle, garantissant l'intégrité scientifique des résultats.

? Quel outil permet d'afficher des graphiques à partir de Prometheus ?

> C'est Grafana, qui se connecte à la base de données Prometheus pour créer des tableaux de bord visuels.

Conclusion du Module

L'IA est gourmande en ressources. Un bon technicien n'est pas celui qui installe le plus vite, mais celui dont l'infrastructure tourne sans interruption.

LES 3 POINTS CLÉS À RETENIR

Surveiller

Le monitoring n'est pas une option, c'est une assurance vie pour vos calculs.

Interpréter

Un chiffre seul ne veut rien dire. Comprenez la relation entre Chaleur, Puissance et Performance.

Maintenir

La poussière et les connecteurs lâches sont les premiers tueurs de GPU en entreprise.

Merci de votre attention !

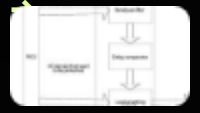
Passez maintenant au Travail Pratique (TP) sur Google Colab.

IMAGE SOURCES



https://grafana.com/api/dashboards/14574/images/10667/image

Source: grafana.com



https://ecdn6.globalso.com/upload/p/1462/image_other/2024-09/sdgdf2-2.jpg

Source: www.sinsmarts.com



https://www.nvidia.com/content/dam/en-zz/Solutions/Data-Center/h200/h200-tensor-og.jpg

Source: www.nvidia.com



https://www.databack.fr/wp-content/uploads/2026/04/smart-disque-dur-ssd.png

Source: www.databack.fr



https://data-clean.fr/wp-content/uploads/2021/03/poussiere-ordinateur.webp

Source: data-clean.fr



https://global.discourse-cdn.com/nvidia/original/4X/d/4/3/d4312a81ceb9f74508314c1d4407b205f24b3202.png

Source: forums.developer.nvidia.com

IMAGE SOURCES



https://thumbs.dreamstime.com/b/sinistre-dans-la-salle-du-serveur-ou-de-stockage-datacenter-en-feu-art-g%C3%A9n%C3%A9r%C3%A9-par-le-r%C3%A9seau-neuronal-l-269541055.jpg

Source: fr.dreamstime.com



https://thumbs.dreamstime.com/b/un-technicien-travaille-avec-beaucoup-de-fils-%C3%A0-centre-donn%C3%A9es-ing%C3%A9nieur-dans-casque-blanc-connecte-les-t%C3%A9l%C3%A9communications-le-171213346.jpg

Source: fr.dreamstime.com