Mise en place d'un écosystème d'IA — 420-A57-BB

TRAVAIL PRATIQUE

Module 4 : Technologies de virtualisation dans le contexte de l'IA

TP d'auto-apprentissage

Environnement	Google Colab + Play with Docker (labs.play-with-docker.com)
Objectif	Découvrir Docker, le cloud et les outils Big Data par la pratique

Préparation

Outil 1 — Google Colab : ouvrez colab.research.google.com et créez un nouveau notebook. Activez le GPU (Exécution → Modifier le type → GPU T4).

Outil 2 — Play with Docker : ouvrez labs.play-with-docker.com dans votre navigateur. Connectez-vous avec un compte Docker Hub (gratuit). Cliquez 'Add New Instance' pour obtenir un terminal Docker prêt à l'emploi — sans rien installer sur votre machine.

Note : Play with Docker est une plateforme gratuite qui fournit un environnement Docker complet dans le navigateur. Les sessions durent 4 heures maximum. Si vous avez Docker installé localement, vous pouvez l'utiliser directement.

Partie 1 — Découvrir le cloud et ses services

Exercice 1.1 — Explorer l'environnement Colab comme service cloud

Google Colab est un exemple concret de PaaS (Platform as a Service). Explorons-le :

Cellule Colab / Terminal

```
# Découvrir l'infrastructure cloud de Colab
import platform, os, subprocess

print('=== INFRASTRUCTURE COLAB ===')
print(f'OS : {platform.platform()}')
print(f'CPU : {os.cpu_count()} cœurs')
print(f'RAM : {os.sysconf("SC_PAGE_SIZE") * os.sysconf("SC_PHYS_PAGES") / (1024**3):.1f}
Go')

# GPU
!nvidia-smi --query-gpu=name,memory.total --format=csv,noheader

# Espace disque
!df -h / | tail -1
```

Question 1 : Combien de CPU, de RAM et quel GPU sont alloués ? Comparez avec votre machine personnelle. Quel modèle de service cloud est Colab (IaaS, PaaS ou SaaS) ? Justifiez.

Exercice 1.2 — Simuler un choix cloud pour un projet IA

Vous devez choisir un service cloud pour entraîner un modèle de classification d'images sur 100 000 images. Complétez le tableau ci-dessous en recherchant les informations sur les sites des fournisseurs :

Critère	AWS	GCP	Azure
Instance GPU recommandée	(à compléter)	(à compléter)	(à compléter)
GPU fourni			
Prix / heure			
Crédit gratuit			
Votre recommandation			

Question 2 : Quel fournisseur recommandez-vous pour un étudiant sans budget ? Et pour une startup avec 5 000 $ de budget ? Justifiez.

Partie 2 — Docker : premiers pas

Pour cette partie, utilisez Play with Docker (labs.play-with-docker.com) ou Docker sur votre machine.

Exercice 2.1 — Découvrir les commandes Docker de base

Exécutez chaque commande et observez le résultat :

```
# a) Vérifier que Docker fonctionne
docker version

# b) Télécharger une image Python
docker pull python:3.11-slim

# c) Lister les images disponibles
docker images

# d) Lancer un conteneur interactif
docker run -it python:3.11-slim python3 -c "print('Bonjour depuis Docker!')"

# e) Lancer un conteneur Ubuntu et explorer
docker run -it ubuntu:22.04 bash
# (dans le conteneur, tapez : uname -a, ls /, exit)

# f) Lister les conteneurs actifs
docker ps -a
```

Question 3 : Quelle est la taille de l'image python:3.11-slim ? Et de ubuntu:22.04 ? Pourquoi l'image 'slim' est plus petite ?

Exercice 2.2 — Créer votre premier Dockerfile

Créez un fichier nommé 'Dockerfile' (sans extension) avec le contenu suivant :

```
# Créer le Dockerfile
cat > Dockerfile << 'EOF'
FROM python:3.11-slim

# Installer les bibliothèques IA
RUN pip install numpy pandas scikit-learn

# Copier le script
COPY train.py /app/train.py
WORKDIR /app

# Lancer le script
CMD ["python", "train.py"]
EOF
```

Puis créez le script train.py :

```
cat > train.py << 'EOF'
from sklearn.datasets import load_iris
from sklearn.ensemble import RandomForestClassifier
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score

iris = load_iris()
X_train, X_test, y_train, y_test = train_test_split(
    iris.data, iris.target, test_size=0.3, random_state=42)

model = RandomForestClassifier(n_estimators=100, random_state=42)
model.fit(X_train, y_train)

accuracy = accuracy_score(y_test, model.predict(X_test))
print(f'Precision du modele : {accuracy:.2%}')
print('Entrainement termine avec succes dans Docker !')
EOF
```

Construisez et lancez :

```
# Construire l'image
docker build -t mon-premier-ia .

# Lancer le conteneur
docker run mon-premier-ia
```

Question 4 : Quel résultat obtenez-vous ? Quelle précision affiche le modèle ? Expliquez chaque instruction du Dockerfile (FROM, RUN, COPY, WORKDIR, CMD).

Exercice 2.3 — Docker Compose : multi-conteneurs

Créez un fichier docker-compose.yml qui lance un conteneur Python + un conteneur de base de données :

```
cat > docker-compose.yml << 'EOF'
version: '3.8'
services:
  app:
    image: python:3.11-slim
    command: python -c "import socket; print(f'App tourne sur {socket.gethostname()}')"

  db:
    image: postgres:15-alpine
    environment:
      POSTGRES_PASSWORD: monmotdepasse
      POSTGRES_DB: ia_db
    ports:
      - '5432:5432'
EOF

# Lancer
docker compose up
```

Question 5 : Combien de conteneurs sont créés ? Que fait chaque service ? Pourquoi séparer l'application et la base de données dans des conteneurs distincts ?

Partie 3 — Introduction au Big Data avec PySpark

Cette partie se fait sur Google Colab.

Exercice 3.1 — Installer et découvrir PySpark sur Colab

Cellule Colab / Terminal

```
!pip install pyspark -q

from pyspark.sql import SparkSession

# Créer une session Spark
spark = SparkSession.builder \
    .appName('TP4-BigData') \
    .master('local[*]') \
    .getOrCreate()

print(f'Spark version : {spark.version}')
print(f'Spark UI : {spark.sparkContext.uiWebUrl}')
```

Exercice 3.2 — Manipuler des données avec Spark DataFrames

Cellule Colab / Terminal

```
# Créer un DataFrame Spark
data = [
    ('Togo', 'Lomé', 8800000, 8.1),
    ('Burkina Faso', 'Ouagadougou', 22100000, 19.7),
    ('Sénégal', 'Dakar', 17700000, 27.6),
    ('Côte d\'Ivoire', 'Abidjan', 28200000, 70.0),
    ('Ghana', 'Accra', 33500000, 77.6),
]

colonnes = ['Pays', 'Capitale', 'Population', 'PIB_Mds_USD']
df_spark = spark.createDataFrame(data, colonnes)

# Afficher
df_spark.show()

# Requête SQL sur les données
df_spark.createOrReplaceTempView('pays_afrique')
resultat = spark.sql('SELECT Pays, PIB_Mds_USD FROM pays_afrique WHERE Population >
20000000 ORDER BY PIB_Mds_USD DESC')
resultat.show()
```

Question 6 : Quels pays ont plus de 20 millions d'habitants ? En quoi un Spark DataFrame est-il différent d'un Pandas DataFrame ? (Indice : distribution sur le cluster)

Exercice 3.3 — Spark MLlib : ML distribué

Cellule Colab / Terminal

```
from pyspark.ml.feature import VectorAssembler
from pyspark.ml.classification import RandomForestClassifier as SparkRF
```

```
from pyspark.ml.evaluation import MulticlassClassificationEvaluator

# Charger les données Iris via Pandas puis convertir
import pandas as pd
from sklearn.datasets import load_iris

iris = load_iris()
pdf = pd.DataFrame(iris.data, columns=iris.feature_names)
pdf['label'] = iris.target

# Convertir en Spark DataFrame
sdf = spark.createDataFrame(pdf)

# Préparer les features
assembler = VectorAssembler(
    inputCols=iris.feature_names, outputCol='features')
sdf = assembler.transform(sdf)

# Split
train_df, test_df = sdf.randomSplit([0.7, 0.3], seed=42)

# Entraîner
rf = SparkRF(numTrees=100, seed=42)
model = rf.fit(train_df)

# Évaluer
predictions = model.transform(test_df)
evaluator = MulticlassClassificationEvaluator(metricName='accuracy')
accuracy = evaluator.evaluate(predictions)
print(f'Précision Spark MLlib : {accuracy:.2%}')
```

Question 7 : Comparez cette approche Spark MLlib avec Scikit-learn (Module 3). Quand utiliser Spark MLlib plutôt que Scikit-learn ? (Indice : volume de données)

Partie 4 — Questions de synthèse

Q1 : Expliquez la différence entre une VM, un conteneur et le serverless. Donnez un cas d'usage IA pour chacun.

Q2 : Qu'est-ce qu'un Dockerfile ? Pourquoi est-il important pour la reproductibilité en IA ?

Q3 : Un collègue vous dit : « Mon code fonctionne sur ma machine mais pas sur le serveur de production ». Quelle solution proposez-vous et pourquoi ?

Q4 : Comparez Hadoop et Spark en 5 lignes. Lequel est plus adapté pour le ML et pourquoi ?

Q5 : Qu'est-ce qu'un Data Lake ? En quoi est-il différent d'une base de données classique ?

Q6 : Vous devez entraîner un modèle sur 1 million d'images. Décrivez le workflow complet en utilisant : Docker, le cloud (AWS ou GCP) et Spark si nécessaire.

Auto-correction : comparez vos réponses avec le corrigé fourni. Si vous avez des doutes, relisez les slides du cours correspondantes.