

Statistique et apprentissage non supervisé

Pourquoi faire ?

→ **Utiliser la variabilité pour distinguer les individus entre eux.**

Réduction dim: Diminuer le nombre de variables pour représenter cette variabilité

Clustering: Regrouper les individus en clusters

Règles associations Trouver des profils (combinaisons de paramètres) d'individus

→ Modèles de représentations des individus

- Prévoir le comportement d'individus non encore observés
- Expliquer la variabilité à l'aide d'autres variables

Manipulation de données

Rappels de statistiques

Etude d'un ensemble d'individus sur lesquels on observe des caractéristiques

Population : ensemble d'individus équivalents (propriétés communes).

Echantillonnage :

Population trop vaste → étudier une partie représentative de la population.

→ Les distributions « statistiques » des variables est un critère important en ML (c'est le cas pour la réduction de dimensions. Particulièrement l'ACP)

Analyse statistique

Etude de la variabilité des caractéristiques des individus.

1. Repérer le nombre de données manquantes
2. Repérer et enlever les doublons
3. Étudier Corrélations et distributions
4. Transformer éventuellement les données

Distributions

Lois continues

Loi Normale


Elle est appelée aussi *loi gaussienne* ou *loi de Laplace-Gauss*.

Elle intervient dans la modélisation probabiliste d'un nombre de grandeurs physiques observée un grand nombre de fois.

Distributions

Lois continues

$$f_X(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right] \quad -\infty < x < \infty$$





distribution normale ou gaussienne
de la variable aléatoire X

$$X \sim \mathcal{N}(\mu, \sigma^2)$$

Distributions

Lois continues



Outliers

Numériquement éloigné des autres individus: biaise les informations statistiques du set de données.

2 types:

- Univariés
- Multivariés

Méthode univariée

1. Test d'Hypothèse

Grubb testing

2. Z-score

Ecart de la moyenne mesurée en terme de nombre d'écart-type

$$Zscore = \frac{X - Mean}{StandardDeviation}$$

3. Robust Z-score

$$R. Z. score = \frac{0.6745 * (X_i - Median)}{MAD}$$

Where MAD = median(|X - median|)

4. I.Q.R

```
mean = np.mean(data)
std = np.std(data)
threshold = 2
outliers = []
for i in data:
    z = (i - mean) / std
    if abs(z) > threshold:
        outliers.append(i)
```


```
med = np.median(data)
ma = stats.median_absolute_deviation(data)
for i in data:
    z = (0.6745 * (i - med)) / (np.median(ma))
    if np.abs(z) > 3:
        out.append(i)
```

```
Q1 = np.percentile(data, 25, interpolation = 'midpoint')
Q2 = np.percentile(data, 50, interpolation = 'midpoint')
Q3 = np.percentile(data, 75, interpolation = 'midpoint')
IQR = Q3 - Q1
low_lim = Q1 - 1.5 * IQR
up_lim = Q3 + 1.5 * IQR
outlier = []
for num in x:
    if ((num > up_lim) or (num < low_lim)):
        outlier.append(num)
```


Méthode univariée

Méthodes graphiques utilisées: diagramme de dispersion des observations, boxplots, graphiques des quantiles de valeurs brutes ou des résidus

Exemple du fichier « skins »



Distributions Validations

Méthode de Shapiro-Wilk

Individus triés

Moyenne calculée et écart à la moyenne S

Variance b

Comparaison de b^2/S^2 avec table statistique

```
from scipy import stats
```

```
res = stats.shapiro(x)
```

```
res.pvalue
```

Dossier de travail à établir:

Import os

Os.chdir(« ...dossier de travail... »)

Import pandas as pd

Vérification de la version de la librairie

Print(pandas._version_)

Chargement de la feuille de données

X= pd.read_csv(« SKINS.csv », header=0, index_col=0)

- 1ere ligne correspond aux noms des variables (header=0)
- 1ere colonne = identifiants des individus (index_col=0)

Transformations pour normalité

```
import pandas as pd  
data= pd.read_csv("file")
```

→ lecture des données

```
import numpy as np  
import seaborn as sns  
import matplotlib.pyplot as plt
```

→ cartes correlations, histogrammes de distributions

```
print(data.describe())  
sns.pairplot(data)
```

→ statistiques des données

→ carte distributions et relations univariées (correlations “visuelles”)

```
import numpy as np  
from sklearn.preprocessing import PowerTransformer  
YJ = PowerTransformer(method='yeo-johnson', standardize=True)  
data_transformed = YJ.fit_transform(data)
```

Visualisation des distributions

```
plt.hist(data_transformed, bins=30, alpha=0.7, color='green', label='Data_Transformed')  
plt.legend()  
plt.show()
```

On peut également utiliser la librairie seaborn. Pour une variable donnée :

```
Z = pd.DataFrame(data_transformed(X).columns = X.columns)
```

Dataset SKIN

- Indiquer les variables avec des distributions non-normales
- Transformer ces variables
- Repérer les outliers avant et après transformations

Distribution des variables sur 5 colonnes

```
Import math
```

```
NUM_COLS = 5
```

```
NUM_ROWS = math.ceil(data.shape[1] / NUM_COLS)
```

```
_, axes = plt.subplots(NUM_ROWS, NUM_COLS, figsize=(25, 25))
```

```
for col, ax in zip(data, axes.flatten()):
```

```
    g = sns.histplot(x=col, data=data, ax=ax)
```

```
    g.tick_params(axis='x', rotation=90) # rotations 90deg
```

```
plt.suptitle("Distributions variables")
```

```
plt.tight_layout()
```

```
plt.show()
```