

Méthodes de Clustering. Algorithmes.

Hard clustering: 1 individu appartient à un cluster donné.

Soft clustering: Probabilités d'appartenance possibles.

- Centroid-Based → Centres d'inertie des clusters calculés. K MEANS
- **Connectivity-Based** → **distances entre points calculées.** **CAH**
- Density-Based → Densités de points recherchées DBSCAN

CAH (Classification Ascendante Hiérarchique)

Le principe :

Rassembler des individus selon un critère de ressemblance défini sous la forme d'une matrice de distances, exprimant la distance entre chaque individu pris deux à deux.

La CAH va rassembler les individus de manière itérative et produire un arbre de classification (dendrogramme)

La classification est *ascendante* car elle part des observations individuelles

La classification est *hiérarchique* car elle produit des classes ou groupes de plus en plus vastes.

En découpant l'arbre de classification à une certaine hauteur choisie, on produira la partition désirée.

CAH (Classification Ascendante Hiérarchique)

LES ETAPES

1. Les données doivent être numériques
2. Pas de données manquantes
3. Standardiser les données (e.g StandardScaler)
4. Lancer la classification

CAH (Classification Ascendante Hiérarchique)

PRINCIPE

1. n individus constituent des classes à eux seuls.
2. On calcule les distances deux à deux entre individus et les deux individus les plus proches sont réunis en une classe.
3. La distance entre cette nouvelle classe et les $(n-2)$ individus restants est ensuite calculée, et à nouveau les deux éléments (classes ou individus) les plus proches sont réunis.

CAH (Classification Ascendante Hiérarchique)

Calculs des distances entre classes et individus

Nécessité de définir 2 distances :

- la distance usuelle entre deux individus (euclidienne par défaut)
- Une distance entre classes
méthode d'agrégation: distanceMax, distanceMoy, Ward...

Objectif: trouver la partition en K classes des observations dont l'inertie intra-classe est minimale.

→ Choisir une distance entre classes

CAH (Classification Ascendante Hiérarchique)

Distance entre classes: la distance de Ward → évaluation de la perte d'inertie après et avant fusion.

$$D_W^2(C_j, C_\ell) = \frac{n_j n_\ell}{n_j + n_\ell} \|x_{C_j} - x_{C_\ell}\|^2 .$$

Initialisation: toutes les classes composées d'une unique observation. Chaque classe est donc parfaitement homogène, et l'inertie intra-classe est nulle.

Dernière étape de l'algorithme: toutes les observations regroupées pour former une seule classe. L'inertie inter-classe est alors nulle et l'inertie intra-classe est maximum.

A chaque étape de la classification, l'inertie intra-classe augmente alors que l'inertie inter-classe diminue.

Stratégie: regrouper à chaque étape les deux classes dont la fusion entraîne le plus faible gain d'inertie intra-classe (ou la plus faible perte d'inertie inter-classe).

CAH (Classification Ascendante Hiérarchique)

Choix du nombre de clusters

Tracer la courbe de l'inertie intra-classe **$WC(K)$** en fonction de K .

Identifier les étapes où l'on observe une rupture dans cette courbe, synonyme d'une forte dégradation de l'inertie intra-classe.

→ Fiable pour CAH

CAH (Classification Ascendante Hiérarchique)

Example

Librairies pour CAH:

```
From scipy.cluster.hierarchy import dendrogram, linkage
```

Matrice de distances

```
Z= linkage(data, method='ward', metric='euclidean')
```


Affichage du dendrogramme

```
dendrogram(Z, labels=XXX, orientation='left')
```

```
Plt.show()
```


Dendrogramme. Exemple des fromages...

hauteurs de branches proportionnelles à la perte d'inertie associée à la fusion des deux éléments



CAH vs K Means

++

Stabilité

Pas besoin de lancer plusieurs fois l'algo

--

Rapidité

Stratégie d'initialisation choisie différente= résultats différents