

Analyses Factorielles (ACP, ACM, AFDM)

- Pas de données manquantes
- Données centrées (souvent réduites également)
 - ACP → StandardScaler/RobustScaler/MinMax
 - ACM → pandas.get_dummies puis enlever une colonne créée par variable *sensible aux effectifs faibles*
 - AFDM → **vs ACP** (données cont) et **vs ACM + pondérations** (données cat)
- Centre de gravité des individus à l'origine

ACP- ACM- AFDM

Librairies Python

Scikitlearn

fanalysis (attention, normalise automatiquement pas défaut)

acm

```
Import mca  
mca = mca.MCA(pd.get_dummies(df, drop_first=True))
```

Prince

```
pip install --user prince  
Import prince  
mca = prince.MCA()  
mca = mca.fit()  
mca = mca.transform()
```

ACM

$$\sum m_j = M = 7$$

$$j : 1, \dots, C = 5$$

$$m_1 = 3$$

$$m_2 = 2$$

$$m_3 = 2$$

Modele	puissance	longueur	hauteur	poids	CO2
GOLF	75	421	149	1217	143
CITRONC4	138	426	146	1381	142
P607	204	491	145	1723	223
VELSATIS	150	486	158	1735	188
CITRONC2	61	367	147	932	141
CHRY300	340	502	148	1835	291
AUDIA3	102	421	143	1205	168
OUTLAND	202	455	167	1595	237
PTCRUISER	223	429	154	1595	235
SANTA_FE	125	450	173	1757	197

x_{ik}

orig_Autres	orig_Europ	orig_Franc	carb_Diese	carb_Essen	4X4_non	4X4_oui
0	1	0	1	0	1	0
0	0	1	1	0	1	0
0	0	1	1	0	1	0
0	0	1	1	0	1	0
0	0	1	0	1	1	0
1	0	0	0	1	1	0
0	1	0	0	1	1	0
1	0	0	1	0	0	1
1	0	0	0	1	1	0
1	0	0	1	0	0	1

Moyenne	162	444.8	153	1497.5	196.5	N_k	4	2	4	6	4	8	2
Ecart-Type	78.9	38.8	9.5	283.7	47.5	p_k	0.4	0.2	0.4	0.6	0.4	0.8	0.2

μ_k : moyenne de la variable

σ_k : écart-type

n_k : Effectif de la modalité

p_k : proportion = n_k/n

ACM

Modele	orig_Autres	orig_Europe	orig_France	carb_Diesel	carb_Essenc	4X4_non	4X4_oui
GOLF	0.000	2.236	0.000	1.291	0.000	1.118	0.000
CITRONC4	0.000	0.000	1.581	1.291	0.000	1.118	0.000
P607	0.000	0.000	1.581	1.291	0.000	1.118	0.000
VELSATIS	0.000	0.000	1.581	1.291	0.000	1.118	0.000
CITRONC2	0.000	0.000	1.581	0.000	1.581	1.118	0.000
CHRY300	1.581	0.000	0.000	0.000	1.581	1.118	0.000
AUDIA3	0.000	2.236	0.000	0.000	1.581	1.118	0.000
OUTLAND	1.581	0.000	0.000	1.291	0.000	0.000	2.236
PTCRUISER	1.581	0.000	0.000	0.000	1.581	1.118	0.000
SANTA_FE	1.581	0.000	0.000	1.291	0.000	0.000	2.236

$$z_{ik} = \frac{x_{ik}}{\sqrt{p_k}} ; k = C + 1, \dots, P$$

$$ACP + ACM = AFDM$$

Et les outliers??

Pour les variables continues → changement du type de transformation

Pour les variables catégorielles → Attention au poids des modalités

AFDM : ACP non normée...

Modele	puissance	longueur	hauteur	poids	CO2	orig_Autres	orig_Europe	orig_France	carb_Diesel	carb_Essenc	4X4_non	4X4_oui
GOLF	-1.103	-0.614	-0.419	-0.989	-1.127	0.000	2.236	0.000	1.291	0.000	1.118	0.000
CITRONC4	-0.304	-0.485	-0.733	-0.411	-1.148	0.000	0.000	1.581	1.291	0.000	1.118	0.000
P607	0.532	1.192	-0.838	0.795	0.558	0.000	0.000	1.581	1.291	0.000	1.118	0.000
VELSATIS	-0.152	1.063	0.524	0.837	-0.179	0.000	0.000	1.581	1.291	0.000	1.118	0.000
CITRONC2	-1.280	-2.007	-0.628	-1.993	-1.169	0.000	0.000	1.581	0.000	1.581	1.118	0.000
CHRY300	2.256	1.476	-0.524	1.189	1.990	1.581	0.000	0.000	0.000	1.581	1.118	0.000
AUDIA3	-0.761	-0.614	-1.047	-1.031	-0.600	0.000	2.236	0.000	0.000	1.581	1.118	0.000
OUTLAND	0.507	0.263	1.466	0.344	0.853	1.581	0.000	0.000	1.291	0.000	0.000	2.236
PTCRUISER	0.773	-0.408	0.105	0.344	0.811	1.581	0.000	0.000	0.000	1.581	1.118	0.000
SANTA_FE	-0.469	0.134	2.094	0.915	0.011	1.581	0.000	0.000	1.291	0.000	0.000	2.236

$$z_{ik} = \frac{x_{ik} - \mu_k}{\sigma_k} ; k = 1, \dots, C$$

$$z_{ik} = \frac{x_{ik}}{\sqrt{p_k}} ; k = C + 1, \dots, P$$

EXERCICE

Fichier SKIN_AFDM

Paramètres de peaux de 250 femmes

- Paramètres reliées aux Cernes ou aux Paupières. Attention aux femmes qui n'ont pas de cernes.... Enlevées pour traitement des données sans elles ou variables reliées à leur présence catégorisées... A TESTER.
- La zone d'âge (moins de 30 ans ou plus de 50 ans) est indiquée. Variable binaire
- La ville d'habitation est indiquée

EXERCICE

Fichier SKIN_AFDM.csv

1. ACP pour les données numériques uniquement en mettant les variables catégorielles en index.
 - Utiliser StandardScaler
 - Trouver le nombre adéquat de composantes principales par le graphe des VP vs CP
 - Représenter les individus dans l'espace des CP et indiquer leur appartenance aux variables indexées sur le graphe (ville ou catégorie d'âge)

Refaire la réduction de dimension en utilisant RobustScaler. Y a-t-il des changements?

EXERCICE

Fichier SKIN_AFDM.csv

2. ACM pour les données catégorielles uniquement en mettant les variables reliées aux cernes sous forme catégorielles quand on a des femmes qui n'ont pas de cernes (donnée binaire « présence » « absence »)

- Pondérer les données en gardant toutes les variables créées par `get_dummies`
- Représenter les individus dans l'espace des CP créés avec Scikitlearn et fanalysis (comparer les résultats)

EXERCICE

Fichier SKIN_AFDM.csv

3 AFDM pour toutes les données en utilisant prince

- Représenter les individus dans l'espace des CP et comparer les résultats avec ACP et ACM