201-C72
Mathématiques pour l'IA

Zied Ben Salah, Ph.D.

Collège Bois de Bologne
Département de Mathématiques

Automne 2026

À quoi servent les statistiques ?

- Décrire ;
- Comparer ;
- Analyser ;
- Généraliser ;
- Prendre des décisions.

Quelles sont les outils du développement des statistiques ?

Chapitre 1 : Statistiques descriptives

- **Vocabulaire statistique**
- **Présentation de données sous forme graphique**
- **Mesures decriptives**

Définition : Individus, variable et types de variables

Lors d'une étude, l'ensemble observé ou qui sera soumis à l'étude constitue **la population**.

- **Un individu** ou unité expérimentale est un élément de la population.
- **Une variable** est une propriété ou un caractère que l'on observe dans la population (Statut matrimoniale, genre, température, années de scolarité, taille, etc). Elle peut prendre des différentes valeurs d'un individu à un autre .
- Une variable est dite **qualitative** lorsqu'elle classe chaque individu dans un groupe ou une catégorie. On distingue les **variables qualitatives nominales** (groupe non ordonné) et les **variables qualitatives ordinales**(groupe ordonné).
- Une variable est dite **quantitative** lorsque les valeurs sont numérique. Les valeurs prises par une telle variable peuvent être continues (température) ou discrètes (années de scolarité).

Exemples

Considérons les étudiants inscrits au cours de statistiques à l'hiver 2026. On s'intéresse particulièrement à l'âge (en année), au nombre d'années de scolarité, au genre, à la note obtenue, à la cote obtenue, le nombre de frères et soeurs, au statut matrimoniale, au revenu en 2025 et à la couleur des yeux (brun, bleue, noisette, vert et autres). Ces variables peuvent être regroupées ainsi :

- **variables qualitatives nominales** : genre, statut matrimoniale et couleur des yeux .
- **variable qualitative ordinale** : cote obtenue.
- **variables quantitatives discrètes** : nombre de frères et soeurs, nombre d'année de scolarité et l'âge.
- **variables quantitatives continues** : note obtenue et revenu en 2025.

Distribution d'une variable

- La **distribution d'une variable** donne les valeurs (ou catégories) prises par une variable ainsi que les fréquences correspondante (nombre ou pourcentage d'pparition).
- Nous utilisons un tableau (tableau de fréquences) pour représenter (numériquement) cette distribution.
- Lorsque la variable est quantitative continue, les valeurs sont souvent regroupées dans des intervalles (classes).

Tableau de fréquences : résumé des données

Répartition en pourcentage des **jeunes Québécois âgés de 18 à 35 ans**,
selon le **degré de confiance** qu'ils accordent aux groupes environnementaux, **Québec, 2007**

Variable **Lieu** **Moment**

Degré de confiance	Pourcentage des jeunes Québécois (%)
Très confiance	16
Assez confiance	60
Peu confiance	19
Pas du tout confiance	5
Total	100

Variable

Modalités

Signification de fréquences

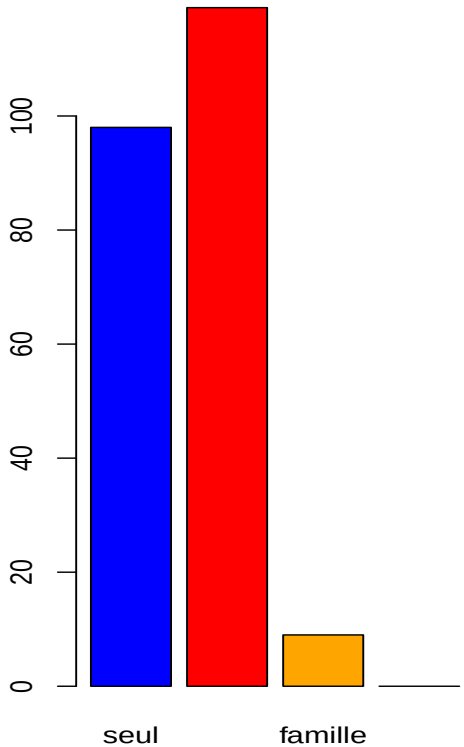
Fréquences relatives

Total

Les diagrammes permettent de représenter des variables qualitatives. On distingue deux catégories de diagramme.

- Le **diagramme circulaire** permet de représenter des proportions. La surface sur le disque représentant une catégorie est proportionnel à la proportion (aussi à l'effectif) dans cette catégorie.
- Le **diagramme à bâtons** permet de représenter les proportions ou les nombres. La hauteur du bâton correspondant à une catégorie qui représente la proportion ou le nombre dans cette catégorie.

Exemples de diagramme



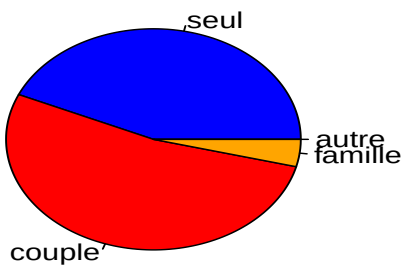


Figure – Répartition de 226 personnes agées selon la situation matrimoniale

Exemple : Degré de satisfaction

Degré de satisfaction	Pourcentage des jeunes Québécois (%)
Très satisfait	50,9
Assez satisfait	34,3
Peu satisfait	10,9
Pas du tout satisfait	3,9
Total	100

Figure – Répartition des jeunes québecois selon le degré de satisfaction

Représentation graphique : Diagramme en secteurs

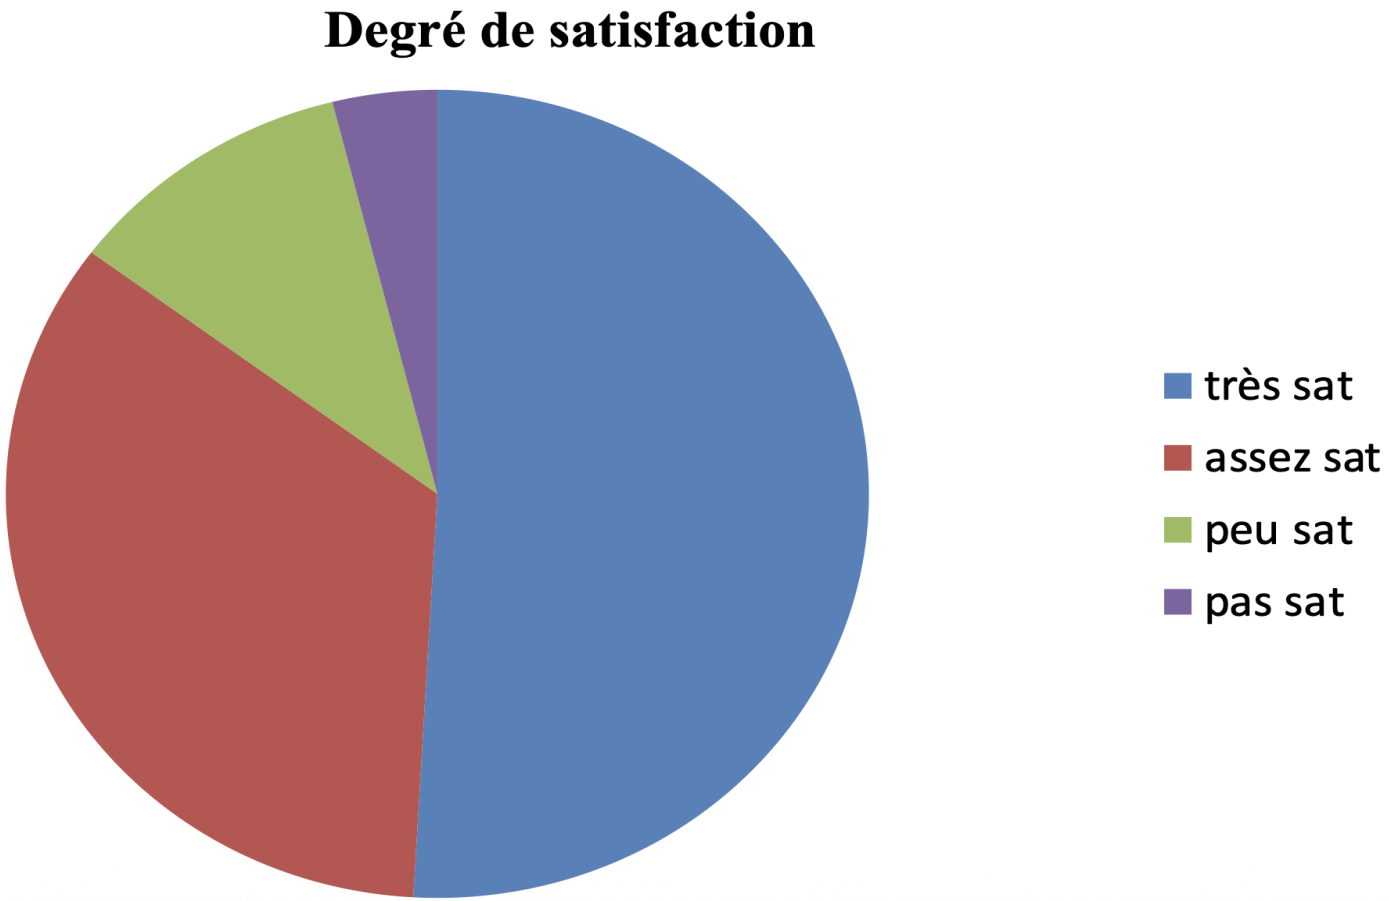


Figure – Répartition des jeunes québecois selon le degré de satisfaction

Diagramme en secteurs :Procédure

- Chaque secteur est proportionnel au pourcentage de la modalité à la quelle il est associé.
- Par exemple, le secteur associé la modalité « Très satisfait », doit couvrir $50,9\%$ de la surface du disque, soit de mesure $\frac{360 \times 50,9}{100} = 183^o$.

Diagramme à bandes verticales

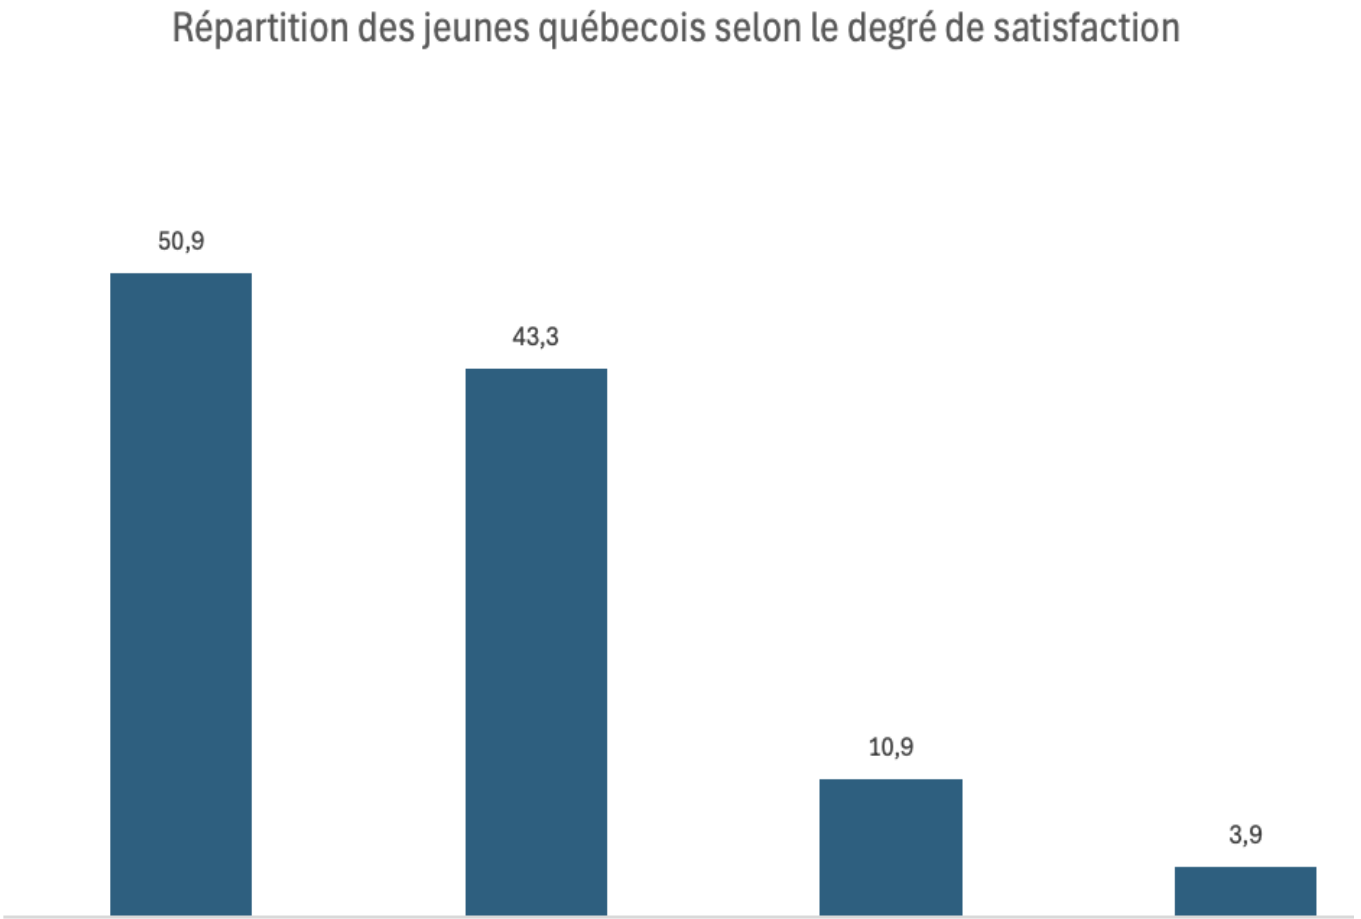


Diagramme linéaire

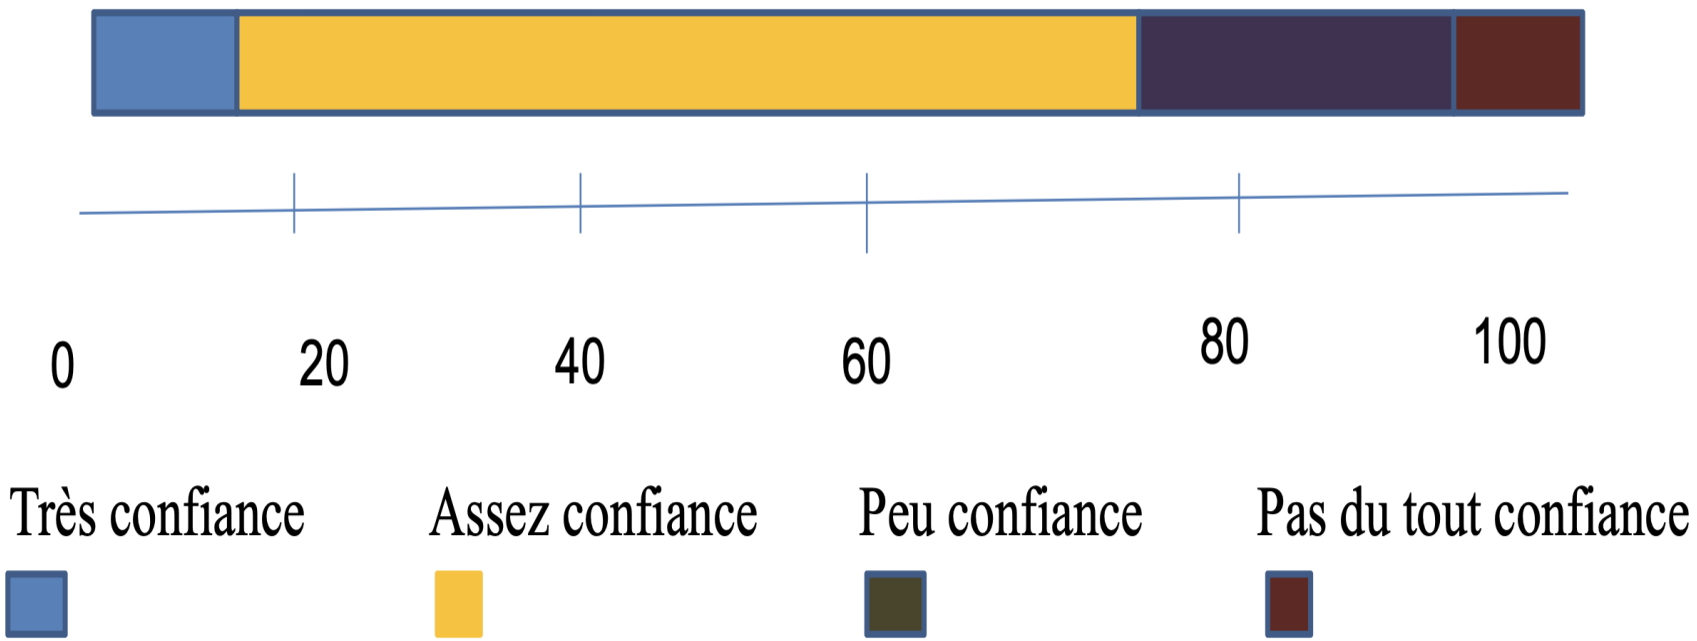


Figure – Répartition des **employés** selon le **niveau de confiance** accordé à une décision administrative .

Diagramme linéaire :Procédure

- On divise le rectangle en autant de parties qu'il y a de modalitiés.
- On accorde par la suite, à chacune de ces parties la proportion appropriée par rapport à l'ensemble.

Comaraison de plusieurs groupes différents

catégorie de masse corporelle	Hommes (%)	Femmes (%)
Poids insuffisant	1,2	4,6
Poids normal	43,1	55,9
Embonpoint	41,4	25,6
Obésité	14,3	13,9
Total	100	100

Figure – Répartition des hommes et femmes selon la catégorie de masse corporelle

Diagramme de compariason

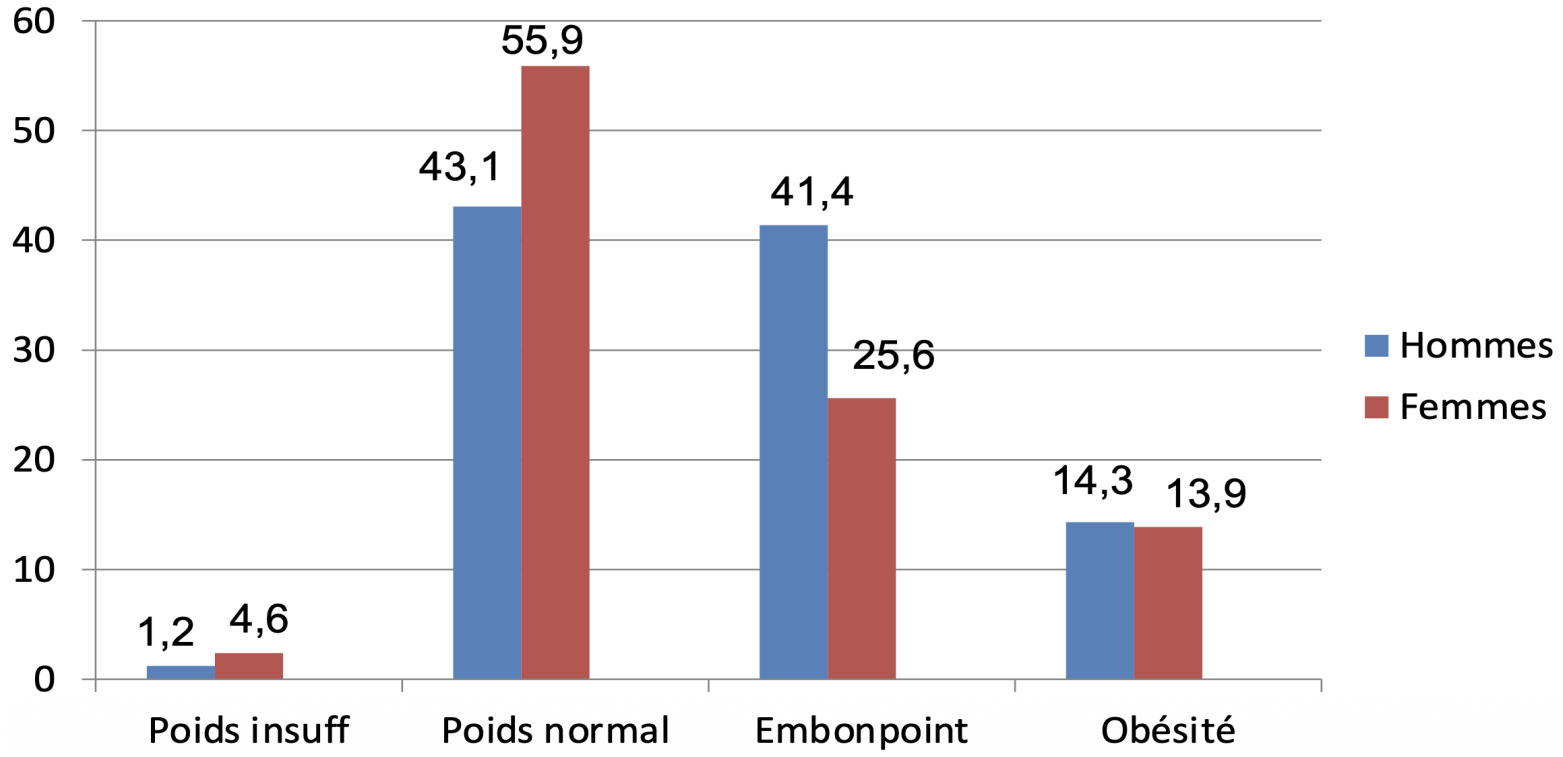


Figure – Répartition des hommes et femmes selon la catégorie de masse corporelle

Diagramme pour variables quantitatives : Histogramme

L'**histogramme** permet de représenter une variable continue. Pour le construire, il faut :

(1) Déterminer le nombre de classe.

(2) Calculer l'**étendue**. C'est la différence entre la plus grande valeur et la plus petite valeur.

(3) Déterminer l'amplitude des classes. Généralement, on divise l'étendue par le nombre de classe (Il faut arrondir le résultat).

(4) On construit les classes en choisissant la plus petite valeur de la série comme valeur minimale de la première classe et la plus grande valeur comme valeur maximale de la dernière classe. Ensuite, pour les classe intermédiaires, la valeur minimale s'obtient en ajoutant l'amplitude à la valeur minimale de la classe précédente.

(5) La hauteur de la bande correspondante à une classe représente la fréquence de cette classe.

Exemple d'histogramme

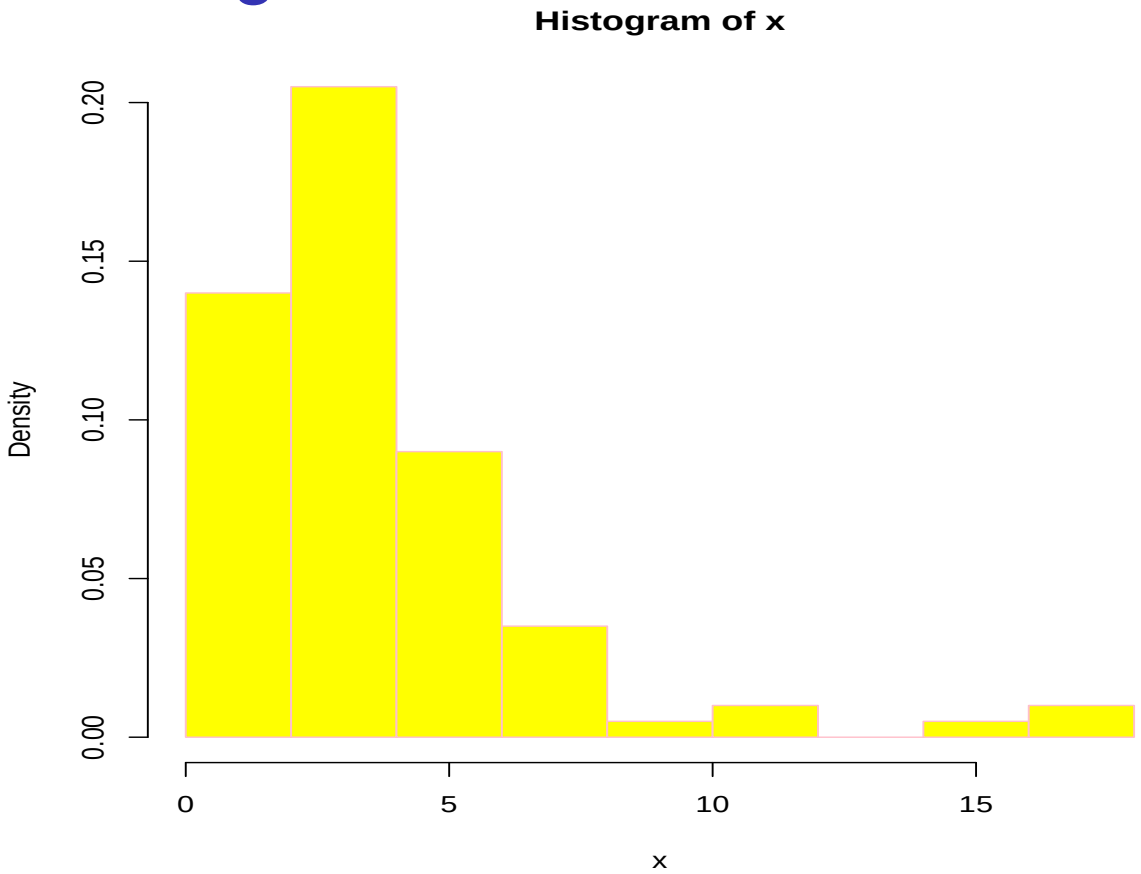


Figure – Répartition des élèves selon la dépense quotidienne X

Exemple

L'Enquête sur les habitudes et les attitudes envers l'étude (Survey of Study Habits and Attitudes, SSHA) est un test psychologique qui évalue les motivations des étudiants, leurs habitudes d'études et leurs attitudes envers l'école. Un collège privé élitiste fait passer le test à un échantillon de 18 étudiantes de première année. Leurs résultats sont

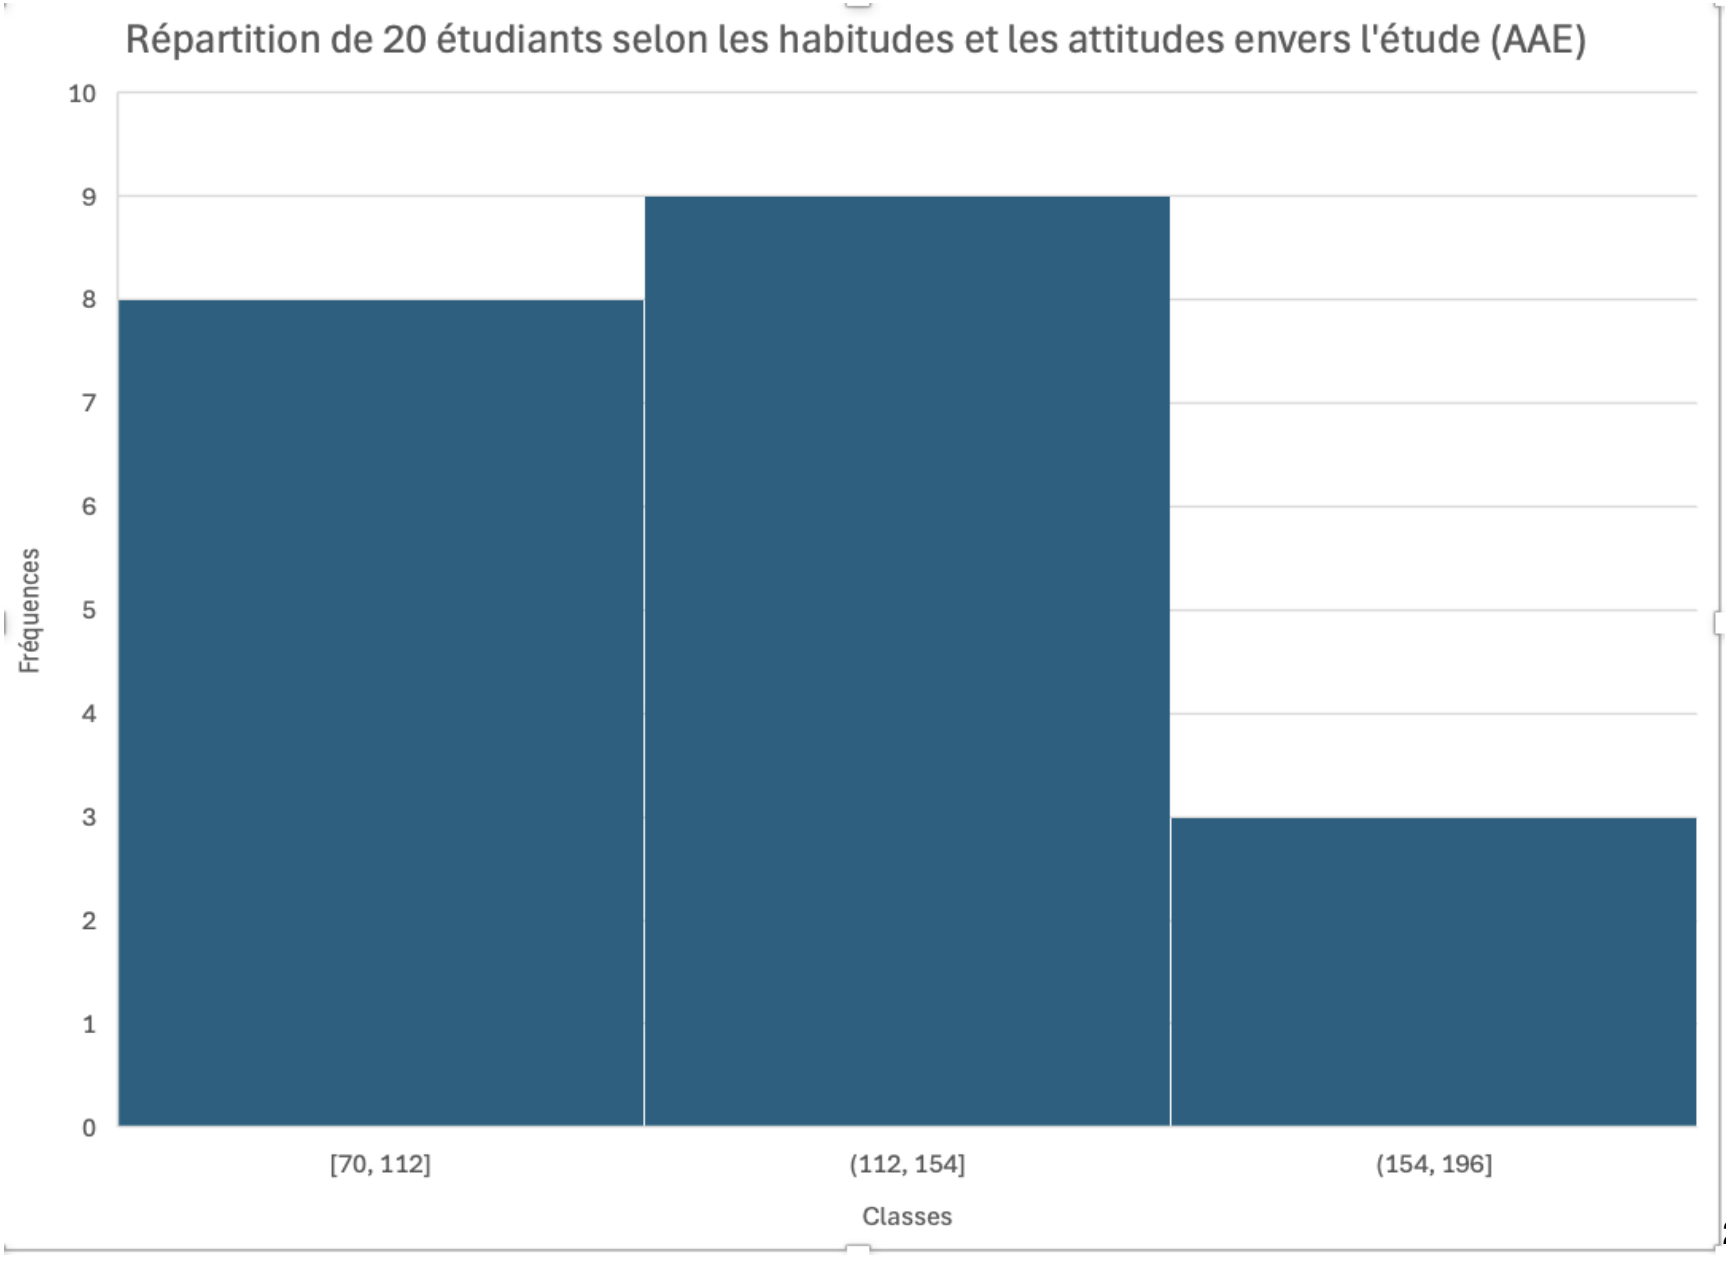
154 109 137 115 152 140 154 178 101

103 126 126 137 165 165 129 199 148

Le collège a également fait passer le test à un échantillon de 20 étudiants de première année. Leurs résultats sont

108 140 114 91 180 115 126 92 169 146

109 132 75 88 113 151 70 115 187 104


Répartition de 20 étudiants selon les habitudes et les attitudes envers l'étude (AAE)
Fréquences
10
9
8
7
6
5
4
3
2
1
0
[70, 112]
(112, 154]
(154, 196]
Classes

Comment analyser des données

1. On regarde le contexte : qu'est-ce qu'on mesure ? Dans quelles unités ? Comment est-ce mesuré ?
2. on observe les données.
3. On cherche la tendance générale, puis les écarts.
4. On calcule des statistiques pour résumer la distribution (résumés numériques, à venir).

Définition

Soit $x_1, \ldots, x_n$ les valeurs prises par n observations d'une variable quantitative. La **moyenne** est la somme de toute les valeurs divisée par le nombre d'observation. Elle est donnée par :

$$\overline{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Losqu'on ordonne les observations $x_{(1)} \leqslant x_{(1)} \leqslant \ldots \leqslant x_{(n)}$, la **médiane** est la valeur qui laisse la moitié des observations à gauche et l'autre moitié à droite. Elle est donnée par :

$$\texttt{médiane} = \begin{cases} x_{(\frac{n+1}{2})} & \texttt{si } n \texttt{ est impair,} \\ \frac{1}{2}\left(x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}\right) & \texttt{si } n \texttt{ est pair.} \end{cases}$$

Remarques :

- Pour des distributions **symétriques**, la moyenne et la médiane sont très proches. Si la distribution est **asymétrique**, la moyenne et la médiane diffèrent. Laquelle est plus grande ?
- La médiane est une mesure **résistante** parce qu'elle est peu affectée par les valeurs aberrantes. Ce n'est pas le cas de la moyenne !

Exemple : âge des filles et garçons

On observe les âges de 8 filles et de 11 garçons. Trouver la moyenne et la médiane des âges de chaque groupe.

Filles	8, 6, 7, 11, 8, 13, 9, 15
Garçons	7, 9, 14, 12, 6, 7, 8, 11, 13, 9, 12

On trouve comme moyenne des âges, **9,63 ans** chez les filles et **9,82 ans** chez les garçons. Les médianes sont respectivement de **8,5 ans** et de **9 ans**.

Mesures de dispersion : Variance et écart-type

Le centre d'une distribution est une caractéristique importante, mais sa dispersion l'est tout autant. Exemple : la taille/poids des personnes.

Définition

Soit $x_1, \ldots, x_n$ les valeurs prises par n observations d'une variable quantitative. La **variance** de l'échantillon est :

$$s^2 = \frac{1}{n-1} \sum_{i=1}^{n} (x_i - \overline{x})^2 .$$

La variance est presque* "la moyenne des écarts $(x_i - \overline{x})$ au carré ".
Elle est en *unités* ^{2}. L'écart type est en *unités*.
* Puisque $\sum_{i=1}^{n} (x_i - \overline{x}) = 0$, les n écarts ne sont pas tous libres de prendre n'importe quelle valeur, seulement $n-1$ le sont. C'est pourquoi on divise par $n-1$ plutôt que n.
On dit que la variance a $n-1$ degrés de liberté.
L'**écart-type** s est la racine carrée de la variance s^2. Il nous indique le positionnement des observations autour de la moyenne.

Exemple : dispersion des âges de filles/garçons

Dans l'exemple sur les âges de 8 filles et de 11 garçons, les variances sont respectivement de **9,6964** et **7,3636**. Ce qui correspond à des écarts-type de **3,1139 ans** pour les filles et de **2,7136 ans** pour les garçons. On dira ainsi que la distribution des âges des filles est beaucoup plus dispersée que celle des garçons.

Quartiles

Définition

Les quartiles divisent les données en quatre parts égales.

- Le premier quartile (Q_1) sépare les 25% inférieurs des données.
- Le deuxième quartile (Q_2) est la médiane de la série.
- Le troisième quartile (Q_3) sépare les 25% supérieurs des données.

Exemple

Les quartiles pourraient varier selon les méthodes appliquées.
Selon la méthode décrite au manuel, les quartiles sont

	Q_1	Médiane	Q_3
Filles	7.5	8,5	12
Garçons	7	9	12

Notez que la médiane sépare les données en deux groupes : le groupe des données inférieures à la médiane, et les groupes des données au dessus la médiane (sans compter la médiane). Q_1 est la médiane du premier groupe, tandis que Q_3 est la médiane du deuxième groupe.

Note : D'autres méthodes pourraient être utilisées (dans certains logiciels).

L'intervalle interquartile

Définition

Soit Q_1 et Q_3 les 1er et 3e quartiles. L'intervalle interquartile est :

$$IQR = Q_3 - Q_1 .$$

C'est une mesure simple de dispersion ; Il s'agit de l'étendue de la moitié centrale des données. C'est également une mesure résistante.

Interprétation

Si la distribution est symétrique, une mesure du centre et une de dispersion résument bien la distribution. Si elle est asymétrique, Q_1 et Q_3 avec la médiane donnent une meilleure idée. Ces mesures ignorent les observations dans les ailes, donc le minimum $x_{(1)}$ et le maximum $x_{(n)}$ peuvent également aider à résumer la distribution.
Le résumé de 5 chiffres (*five-number summary*) est :
Minimum, Q_1, Médiane, Q_3, Maximum

Diagramme en boîte ou *Boxplot*

Principe

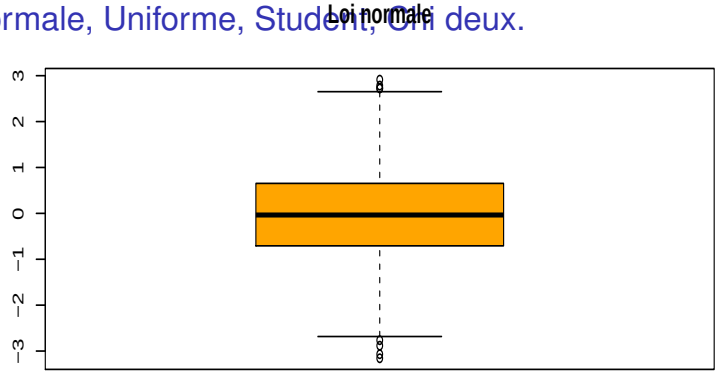
Basé sur le résumé de 5 chiffres

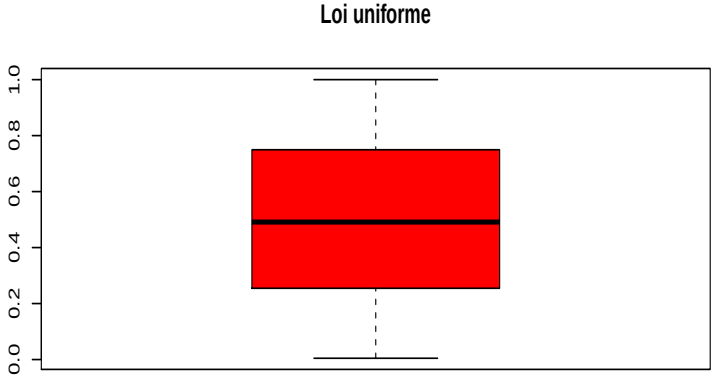
1. La boîte est délimitée par Q_1 et Q_3 ; la longueur de la boîte est donc l'IQR ;
2. La médiane est indiquée par une ligne à l'intérieur de la boîte ;
3. De chaque extrémité de la boîte, une ligne se rend jusqu'au minimum d'un bord et au maximum de l'autre.

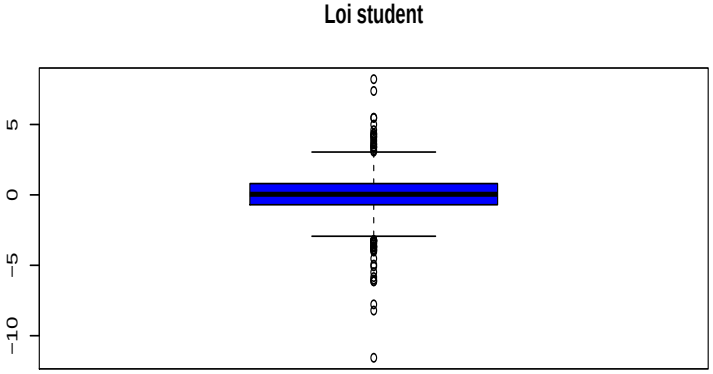
Diagramme en boîte modifié

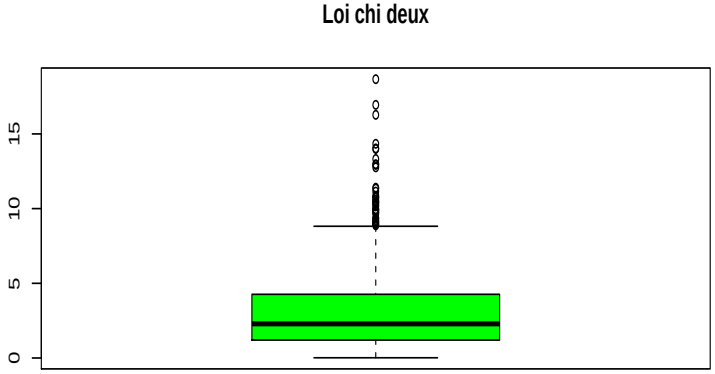
La ligne se rend jusqu'à la plus grande (petite) observation qui ne dépasse pas 1,5 IQR au delà de la boîte. Toutes les observations qui dépassent cette borne sont identifiées par un point ou une ligne.

Boxplot : normale, Uniforme, Student, Chi deux.





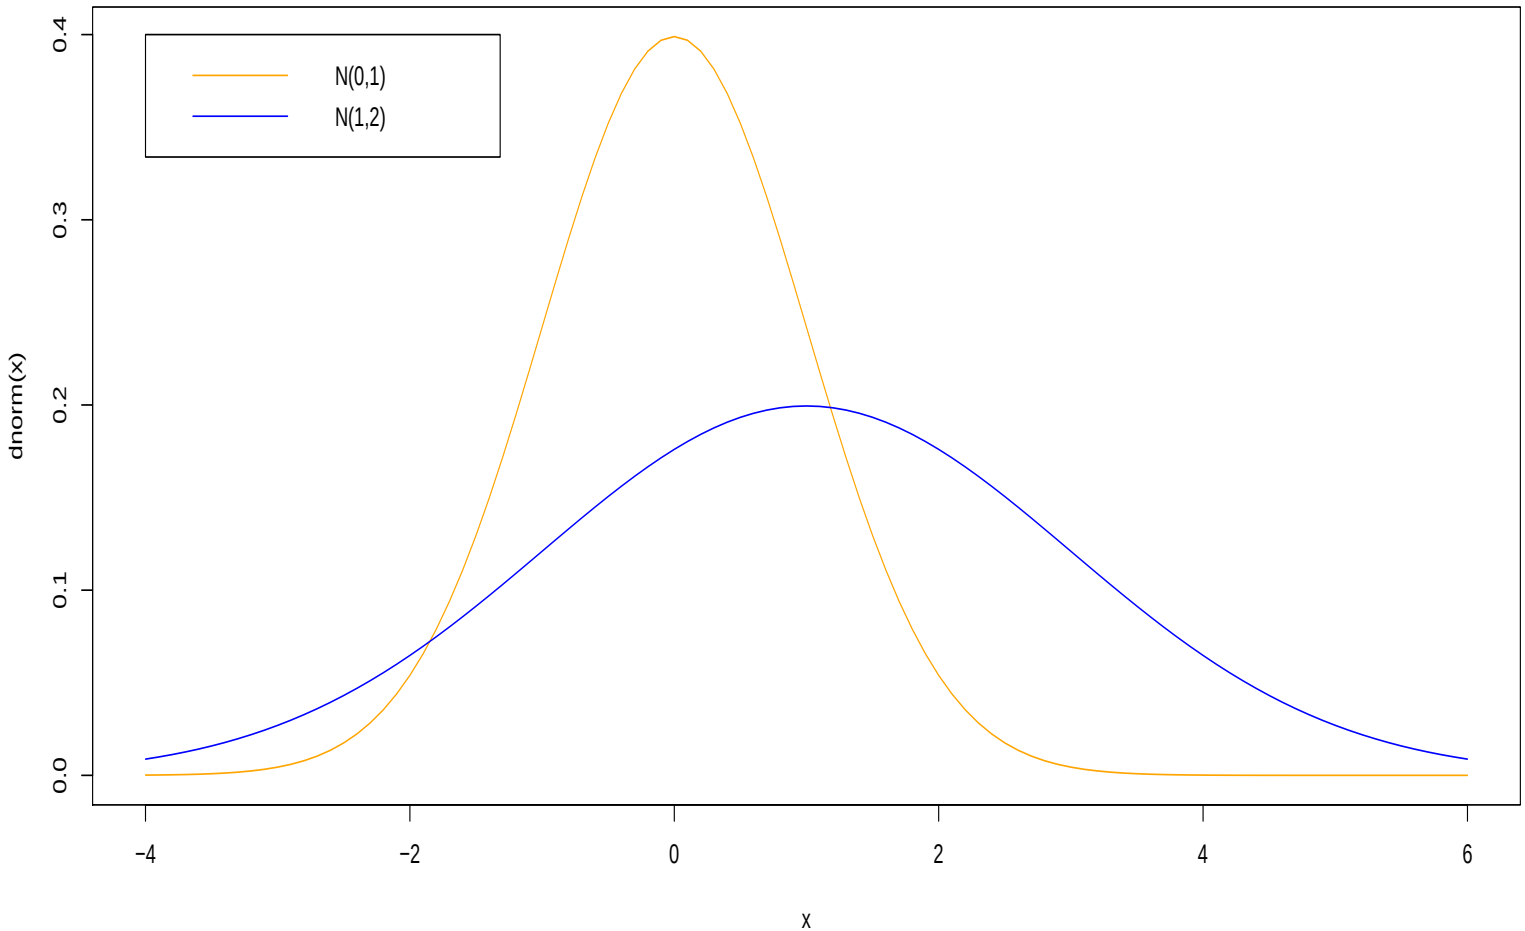




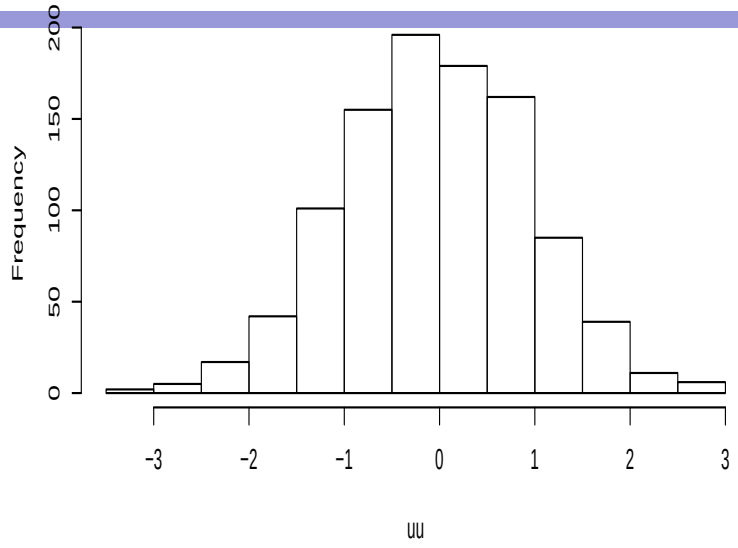
Distribution normale

Plusieurs distributions sont approximativement symétriques et unimodales. La loi normale, qui a la forme d'une cloche, est souvent une bonne approximation. Elle est symétrique par rapport à sa moyenne μ. Son écart-type σ détermine sa *vitesse* de dispertion à mesure qu'on s'éloigne de la moyenne. Elle est notée $N(\mu, \sigma^2)$.
Nous revenons là-dessus dans les prochains chapitres.

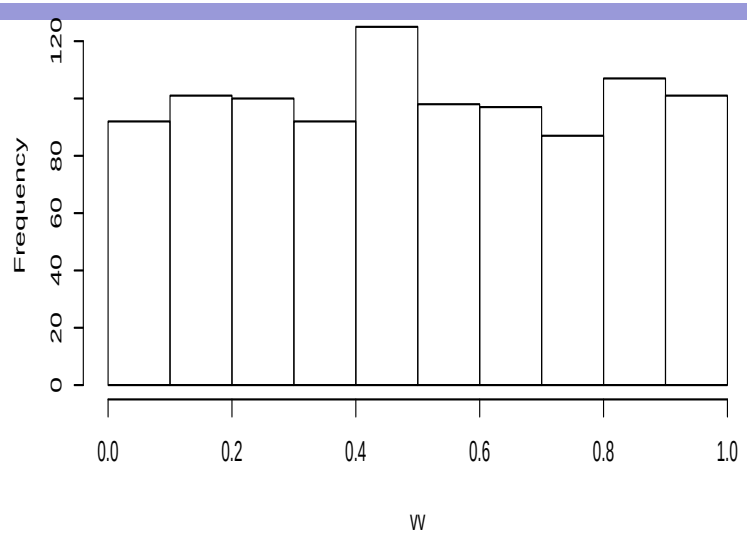
Exemple de distributions normales



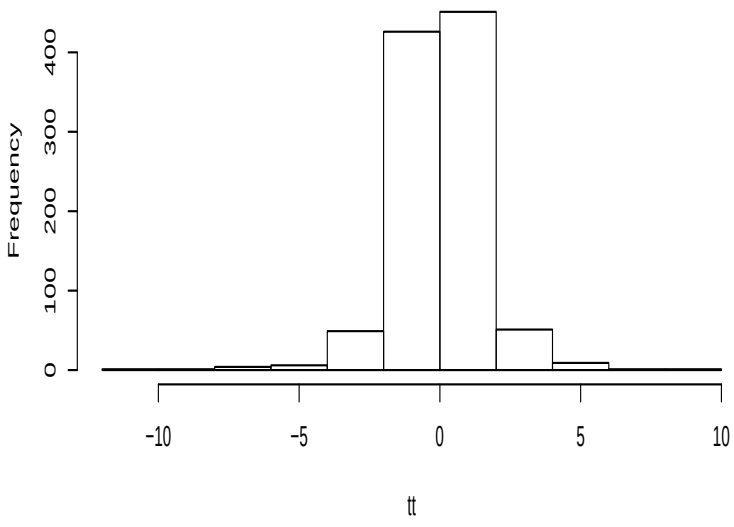
loi normale



loi uniforme



loi student, df=3



loi chi−deux, df=3

