201-C72 Mathématiques pour l'IA

Collège de Bois-de-Bologne

Automne 2026

Chapitre 3 : Vers l'inférence

- Section 3.1 Distribution d'échantillonnage pour la moyenne
- Section 3.2 Distribution d'échantillonnage pour les proportions

Vers l'inférence

Une statistique :

Une statistique calculée à partir d'un échantillon aléatoire ou d'une expérience randomisée est une variable aléatoire. On appelle distribution d'échantillonnage la loi de probabilité d'une statistique.

Remarque Les lois ou distributions de probabilité jouent deux rôles :

- comme distribution d'une population (en échantillonnage, pour décrire les valeurs de la variable pour les N individus de la population, i.e., les salaires des 1250 membres de l'Ordre des optométristes ; dans une expérience pour décrire les résultats possibles, i.e., la distribution de la mesure de sensibilité au contraste.)
- comme distribution d'échantillonnage d'une statistique, i.e., la distribution de la moyenne de 5 observations provenant d'une des deux distributions mentionnées au point précédent.

Moyenne échantillonnale $\overline{X}$

Soit $X_1,\ X_2, ...,\ X_n$ des observations indépendantes provenant d'une même loi (i.i.d. : indépendantes et identiquement distribuées).

Note : Si la taille de la population N est beaucoup plus grand que la taille de l'échantillon n, alors les n observations d'un EAS sont presque indépendantes, de telle sorte que le modèle i.i.d. est presque satisfait.

Attention : Lorsque nous voudrons parler de la situation où les X_i sont indépendantes de même loi, nous dirons que $X_1,\ X_2, ...,\ X_n$ sont i.i.d. alors que le livre parle d'observations provenant d'un EAS. Comme cette dernière situation est une approximation de la précédente, j'aurais préféré utiliser la précédente.

Tel que discuté dans le chapitre 4 (Probabilités), la moyenne échantillonnale ou moyenne de l'échantillon est

$$\overline{X} = \frac{\sum_{i=1}^{n} X_i}{n}.$$

C'est une variable aléatoire. Elle a donc une distribution d'échantillonnage.

Moyenne et écart type de la distribution de $\overline{X}$

Soit $X_1, X_2, \ldots, X_n$ des observations indépendantes provenant d'une même (*i.i.d* : indépendantes et identiquement distribuées) de moyenne $\mathbb{E}[X_1] = \mu$ et de variance $Var[X_1] = \sigma$. Alors,

- la moyenne échantillonnale de $\overline{X} = \frac{\sum_{i=1}^{n} X_i}{n}$ (ou moyenne de l'échantillon) est

$$\mathbb{E}[\overline{X}] = \mu_{\overline{X}} = \mu.$$

- La variance échantillonnale est $Var[\overline{X}] = \sigma^2_{\overline{X}} = \sigma^2/n$.
- L' écart-type échnatillonnal est $\sigma_{\overline{X}} = \sigma/\sqrt{n}$.

Pourquoi ? À discuter en classe !

Notes

- $\overline{X}$ est donc un estimateur sans biais de μ Quelque soit la taille de l'échantillon, la moyenne de la distribution de $\overline{X}$ est la moyenne de la distribution de la population μ (qu'on cherche souvent à estimer).
- Par contre, plus n augmente plus la dispersion diminue, donc la distribution de $\overline{X}$ est de plus en plus concentrée autour de μ.
- La dispersion de $\overline{X}$ est $\sqrt{n}$ fois plus petite que celle d'une seule observation X_1 (ou X_i).
- Donc, la moyenne d'un échantillon est moins variable que des observations individuelles. On peut aussi montrer que les moyennes d'échantillons ont une distribution plus normale que la distribution d'observations individuelles (*Théorème Limite Centrale*).

Distribution de $\overline{X}$ et Théorème central limite

- On peut démontrer que si $X_1,\ X_2,\ \ldots,X_n$ i.i.d. qui suivent une normale $N(\mu,\sigma^2)$ de moyenne μ et d'écart type σ alors

$$\overline{X} \ \sim\ \text{Normal}(\mu,\ \frac{\sigma^2}{n}).$$

- On a déjà vu que la moyenne et l'écart type de $\overline{X}$ sont μ et $\sigma/\sqrt{n}$. Ce qu'il y a de nouveau ici, c'est que si la distribution de la population est normale, alors la distribution de la moyenne de l'échantillon est également normale.

- Le Théorème central limite est le principal théorème des probabilités pour la statistique.

Théorème Limite Centrale (*Central Limit Theorem*)

Soit $X_1,\ X_2,\ \ldots,X_n$ des observations i.i.d. de moyenne μ et d'écartype σ, alors

$$\frac{\overline{X}-\mu}{\sigma/\sqrt{n}} \ \sim\ \text{Normal}(0,1) \quad \text{lorsque } n\longrightarrow\infty \quad \text{(en loi)}\ ;$$

Ce résultat est équivalent à

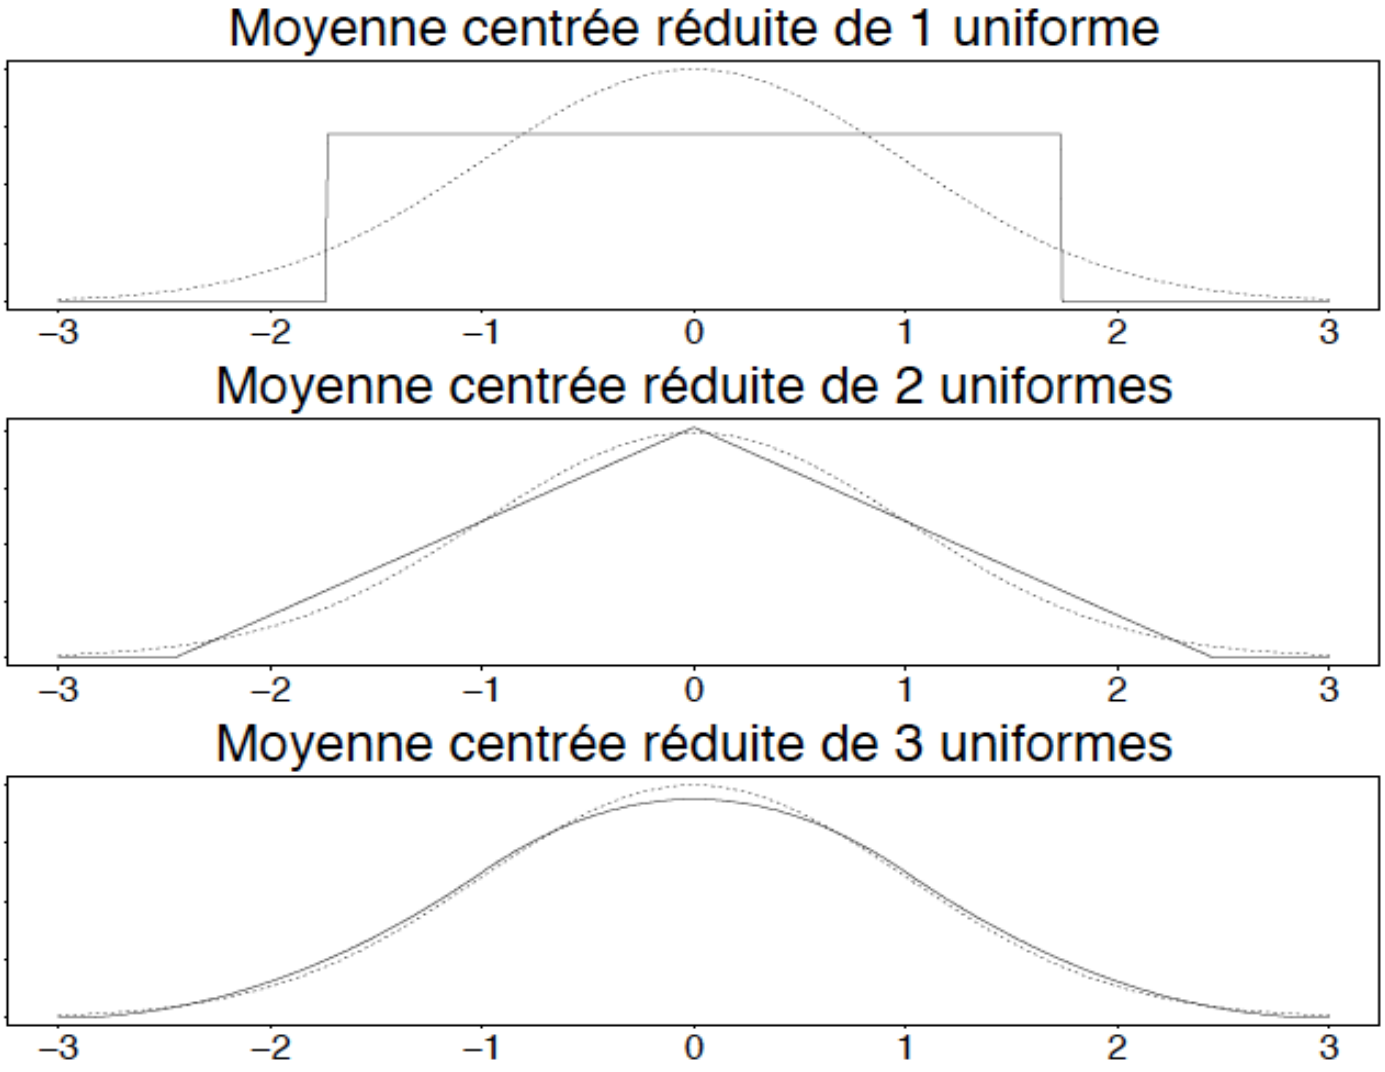
$$\overline{X} \ \sim\ \text{Normal}(\mu,\ \frac{\sigma^2}{n}) \quad \text{lorsque } n\longrightarrow\infty \ \text{(en loi)};$$

Théorème central limite et distribution de $\overline{X}$

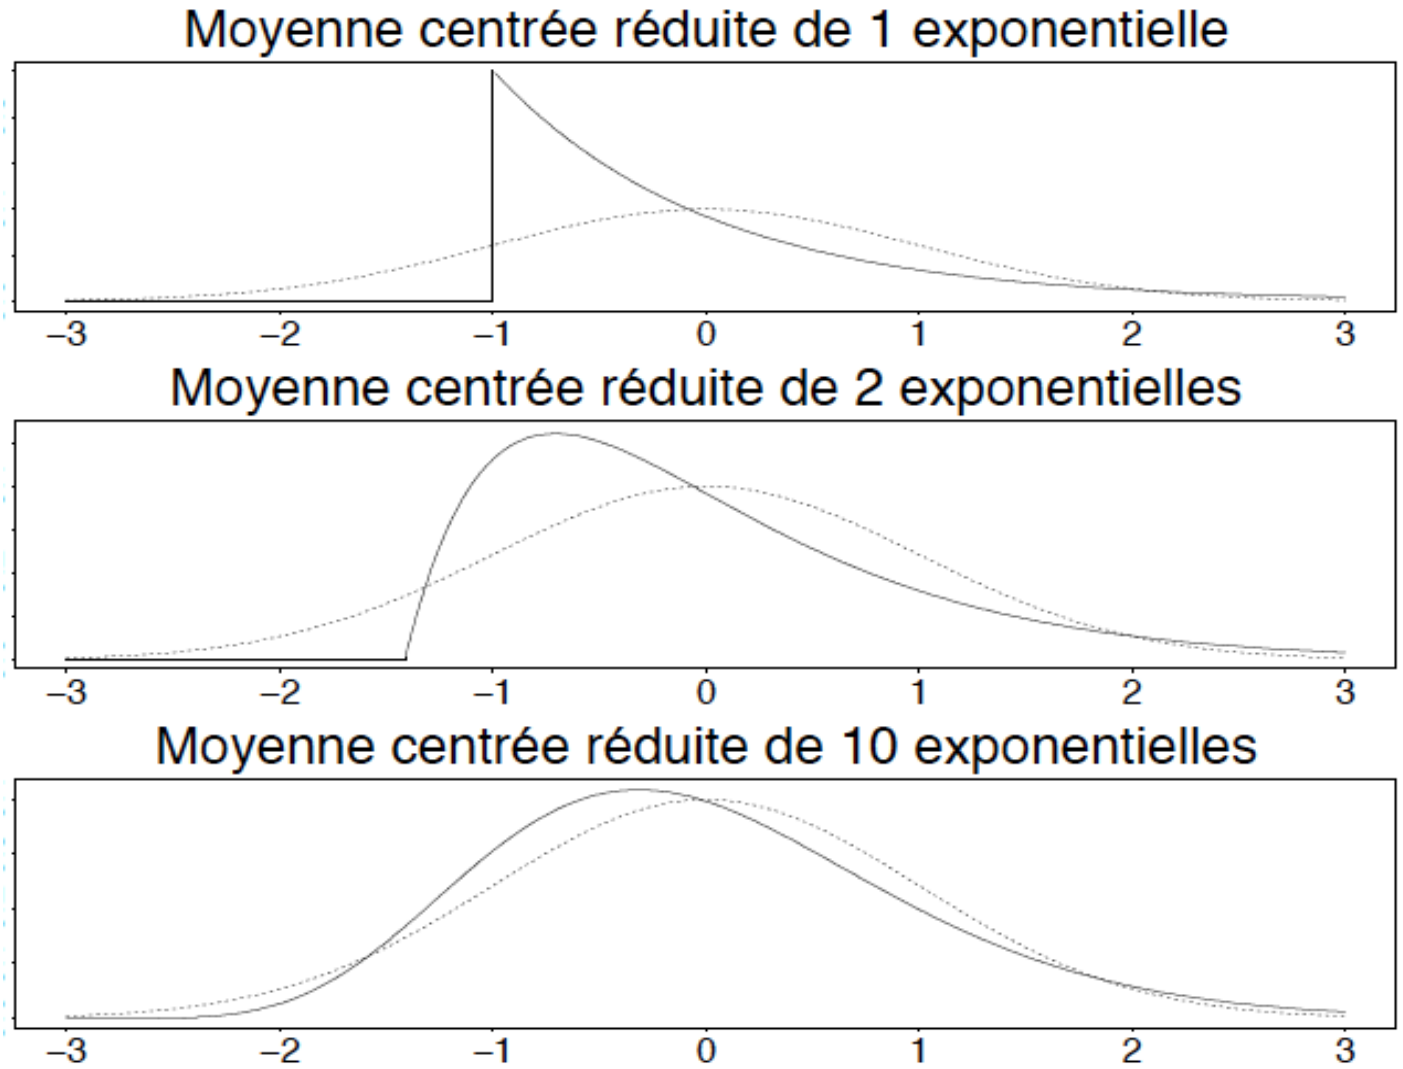
Le théorème central limite assure que quelque soit la distribution d'origine des observations X_i, la distribution de la moyenne d'un échantillon $\overline{X}$ se rapproche de plus en plus de celle d'une **normale**.

- On utilise parfois ce théorème pour justifier le fait que la distribution de certaines variables soit normale (l'effet cumulatif de plusieurs composantes représentant la variable).
- Il existe d'autres "théorèmes central limite" pour d'autres statistiques comme la médiane qui disent également que la distribution de la médiane se rapproche de plus en plus de celle d ?une normale (Dans ce cas, l'estimation de la variance de la médiane est beaucoup plus compliquée).
- On a vu que si les X_i sont normales, alors $\overline{X}$ suit une loi normale, mais ce résultat est plus général : toute combinaison linéraire de variables aléatoires normales est distribuée selon une loi normale.

observations de distribution uniforme



observations de distribution exponentielle

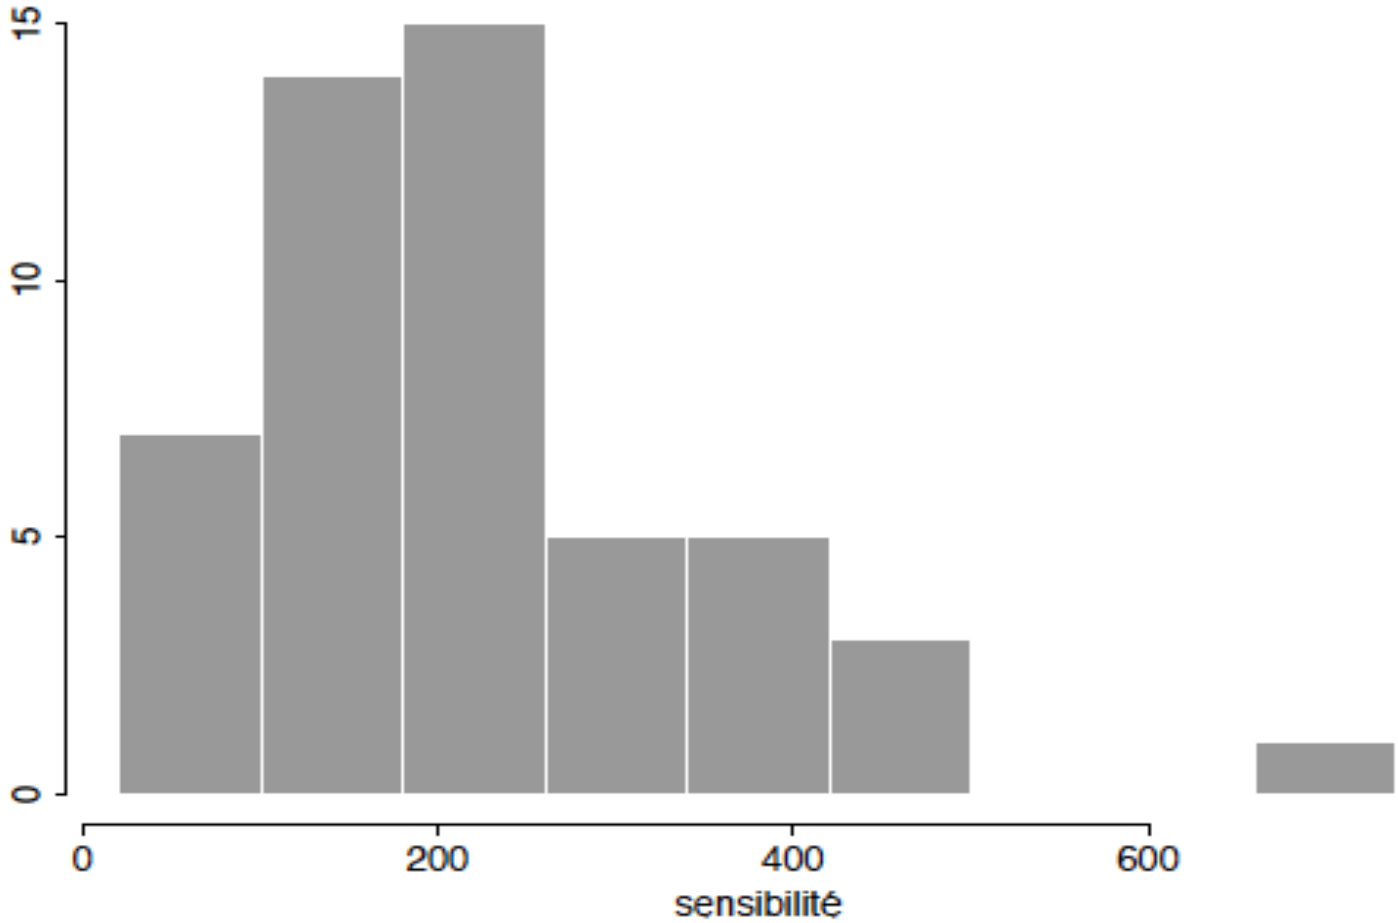


Notes sur le Théorème central limite

- On a vu que pour la distribution uniforme, même pour $n = 3$ observations, l'approximation du théorème central limite est très bonne, alors que pour la distribution exponentielle, $n = 10$ est toujours insuffisant.
- La différence est causée par l'asymétrie de la distribution exponentielle alors que la distribution uniforme est symétrique.
- Donc, si la distribution originale est symétrique, l'approximation normale sera bonne même pour de très petites tailles d'échantillon alors que plus la distribution sera asymétrique, plus il faudra une taille d'échantillon importante pour qu'elle soit bonne.

Exemple : sensibilité au contraste

Considérons des données sur la mesure de la sensibilité au contraste pour 50 individus.



Sensibilité au contraste (suite)

Supposons que la moyenne de la mesure de la sensibilité au contraste mesurée à une fréquence spatiale de $6c/deg$ est de 200 dans la population alors que l'écart type est de 100. Dans l'échantillon de taille 50, la moyenne est de $220,1$.

Question : Quelle est la probabilité que la moyenne d'un échantillon de taille 50 dépasse 220 ?

$$\mathbb{P}(\overline{X} > 220) = \mathbb{P}(\frac{\overline{X} - 200}{100/\sqrt{50}} > \frac{220 - 200}{100/\sqrt{50}})$$

$$= \mathbb{P}(Z > 1,4142) = 1 - 0,9213 = 0,0787 \ ,$$

en utilisant la Table A pour $Z \sim N(0,1)$.

Notez que la distribution est asymétrique, mais puisque l'échantillon est de taille 50, l'approximation par le théorème central limite est bonne.

Effectifs et Proportion Échantillonnale

Dans un sondage auprès de 1785 personnes, on leur a demandé s'ils étaient satisfaits du gouvernement en place.

Le nombre de personnes qui ont répondu affirmativement est l'effectif de l'échantillon et est une variable aléatoire X (discrète).

Si la taille de l'échantillon est n, la proportion échantillonnale (ou proportion de l'échantillon) est une variable aléatoire (continue) donnée par

$$\widehat{p} = X/n.$$

Par exemple, si 1000 des 1785 personnes ont répondu "**oui**", alors la valeur prise par la proprortion de l'échantillon $\widehat{p}$ est $1000/1785$, soit

$$\widehat{p} = 0,56.$$

Distribution des effectifs

Lorsque la taille de la population N est beaucoup plus grande que celle de l'échantillon n, le nombre de succès (ou l'effectif) X d'un EAS de taille n est approximativement distribué selon une distribution binomiale $B(n, p)$ où p est la proportion de succès dans la population (voir section v.a. discrètes, Chap 4).

L'effectif X est une v.a. discrète qui suit $B(n, p)$,

$$\mathbb{P}[X = k] = C_n^k \, p^k \, (1-p)^{n-k} \quad \text{où } C_n^k = \frac{n!}{k!\,(n-k)!} \text{ pour } \quad k = 0, ..., n \, ,$$

pour $k = 0, ..., n$ et $0! = 1$.

C_n^k donne le nombre de *combinaisons* de k succès dans n épreuves n'ayant que deux issues : *Succès (S)* avec probabilité p et *Échec (E)* avec probabilité $(1 - p)$.

Notation $X \sim \mathrm{B}(n, p)$, i.e. l'effectif X (nombre de succès) suit la loi (ou la distribution) binomiale de paramètres n et p.

Moyenne et variance des effectifs

Nous remarquons que

$$X = \sum_{i=1}^{n} U_i \ ,$$

où $U_1,\ U_2,\ \cdots U_n$ est une suite des variables aléatoires i.i.d. telle que

$$\mathbb{P}[U_1 = 1] = p \text{ et } \mathbb{P}[U_1 = 0] = 1 - p \ .$$

En conséquence,

- La moyenne de l'effectif X est

$$\mathbb{E}[X] = \mu_X = n\,p \ .$$

- La variance de l'effectif X est

$$Var[X] = \sigma_X^2 = n\,p\,(1-p).$$

Proportion échantillonnale $\widehat{p}$

Tel que défini précédemment, la proportion échantillonnale est

$$\widehat{p} = \frac{X}{n}.$$

Alors

$$\mathbb{E}[\,\widehat{p}\,] = \mu_{\widehat{p}} = p$$

et

$$Var[\,\widehat{p}\,] = \sigma^2_{\widehat{p}} = \frac{p\,(1-p)}{n}.$$

Notes :

- Puisque $\mathbb{E}[\,\widehat{p}\,] = p$, la proportion échantillonnale est un estimateur sans biais de la proportion de la population ;
- Plus la taille de l'échantillon est grande, moins que la proportion échantillonnale est variable et plus elle se rapproche de la proportion de la population ;
- La distribution d'échantillonnage de $\widehat{p}$ est basée sur celle de la binomiale.

Exemple :

On a un EAS de taille 1785 d'une très grande population et on veut savoir la proportion de gens qui sont satisfaits du gouvernement. Si 60% de la population est satisfaite du gouvernement, quelle est la probabilité que la proportion dans l'échantillon soit d'au moins 58% ?

Cette probabilité est

$$\mathbb{P}[\,\widehat{p} \geq 0,58\,] = \mathbb{P}[X \geq 0,58 \times 1785] = \mathbb{P}[X \geq 1035,3]$$

$$= \mathbb{P}[X = 1036] + \mathbb{P}[X = 1037] + \cdots + \mathbb{P}[X = 1785].$$

Ces probabilités sont difficiles à calculer, surout lorsque n est grand **!**

Comment approximer cette probabilité ?

Il faut penser au Théorème central limite pour une telle approximation.

Approximation par le théorème central limite

Puisque $U_1, \cdots, U_n$ sont i.i.d., alors la distribution de la variable aléatoire

$$\frac{1}{n}\sum_{i=1}^{n} U_i = X/n = \widehat{p}$$

s'approche de plus en plus d'une normale de moyenne et de variance données par

- $$\mathbb{E}[\,\widehat{p}\,] = p$$

et

- $$Var[\,\widehat{p}\,] = p(1-p)/n.$$

Donc la proportion échantillonnale $\widehat{p} \sim$ est approximativement Normale de moyenne p et d'écart-typ $\sqrt{p(1-p)/n}$, ce qui est équivalent à

$$\frac{\widehat{p} - p}{\sqrt{p(1-p)/n}} \sim N(0,1) \text{ , pour } n \text{ suffisamment grand.}$$

Approximation normale de $\widehat{p}$ et X

On a vu que l'effectif d'un EAS où la taille de la population est beaucoup plus grande que la taille de l'échantillon suit approximativement une loi $B(n, p)$.

Donc d'après le Théorème central limite, la proportion échantillonnale $\widehat{p}$ d'un EAS est approximativement normale de moyenne p et d'écart type $\sqrt{p\,(1-p)/n}$.

Note

- Par un simple changement d'échelle, la loi de l'effectif X, où $X \sim B(n, p)$, est approximativement normale de moyenne $n\,p$ et d'écart type $\sqrt{n\,p\,(1-p)}$, lorsque n est grand.
- L'approximation est meilleure lorsque $n\,p \geq 10$ et $n\,(1-p) \geq 10$.

Exemple (suite)

Continuons l'exemple précédent où $n = 1785$, $p = 0,60$ et on veut calculer

$$\mathbb{P}[\ \widehat{p} \geq 0,58\ ].$$

Puisque $p = 0,60$, alors la moyenne de la distribution échantillonnale de $\widehat{p}$ est $\mu_{\widehat{p}} = 0,60$ et l'écart type est $\sigma_{\widehat{p}} = \sqrt{0,60 \times 0,40/1745} = 0,0116$. Alors Alors

$$\mathbb{P}[\ \widehat{p} \geq 0,58\ ] = \mathbb{P}[\ \frac{\widehat{p} - 0,60}{0,0116} \geq \frac{0,58 - 0,60}{0,0116}\ ] \cong \mathbb{P}[Z \geq -1,72\ ] = 0,9573\ ,$$

où $Z \sim N(0,1)$.

Note

Cette approximation est facile à se souvenir : $\widehat{p}$ et X sont approximativement distribués selon une loi normale avec leur moyenne et leur écart-type respectifs.

Exemple (suite) :Distribution de $\widehat{p}$

