201-C72-BB
Mathématiques pour l'IA

Zied, Ben Salah

Collège de Bois-de-Boulogne

Automne 2026

Test d'indépendance du *Khi-carré*

- Section 1 Liens entre deux variables statistiques
- Section 2 Test d'indépendance du *Khi* carré

1. Liens entre des variables

Pour analyser les liens entre des varaibles, nous devrions d'abord les décrire ainsi que les classifier.

Variables indépendantes

Lorsqu'il n'existe aucun lien entre deux **variables**, on dit qu'elles sont **indépendantes**.

- Le **genre** et la **note** obtenue dans un cours sont deux variables indépendants (dans certains contextes !).
- Le **salaire** et la **taille** sont indépendants.
- Le **programme d'étude** et le **genre** sont indépendants **!!**
- Le **nombre d'accidents** de voiture et le **genre** (ou l'**âge**) sont indépendants **!!**

Remarque

Ces exemples sont très souvent des **hypothèses** et non plus de **réponses** définitives. Elles peuvent varier d'un contexte à un autre. Nous verrons à l'aide du test d'indépendance du *Khi* carré comment décider de **rejeter** ou **valider** de telles hypothèses.

Variables corrélées

Lorsqu'il existe un lien entre deux **variables**, on dit qu'elles sont **corrélées**.

On distingue plusieurs types de corrélation (dépendance) :

- **Corrélation positive :** Lorsque les deux variables augmentent (ou diminuent) conjointement (le salaire et l'expérience, le nombre de calories consommé et le poids).
- **Corrélation négative :** Lorsque les deux variables varient en sens contraire. Si l'une diminue, l'autre augmente et inversement (le nombre de calories consommé et le poids perdu)
- **Interdépendance :** Lorsque les deux variables influent l'une sur l'autre (l'âge et l'expérience)
- **Concomitance :** Le lien entre les deux variables est dû à l'influence d'une troisième (consommation de la glace et nombre de cas de grippe)
- **Causalité :** Lorsque une varible X agit directement sur une autre variable Y, c'est à dire X influe sur Y. Nous utilisons l'équation $Y = f(X)$ pour décrire ce lien (X : expérience et Y : salaire)

Indépendance de deux facteurs

On choisit un EAS de taille fixe n d'une seule et unique population. On classifie chaque individu selon deux facteurs contenant r et c catégories, respectivement.

Par exemple :

• Le ***statut socio-économique*** : faible, moyen, élevé & le ***type de fumeur*** : présentement, dans le passé, jamais
ou

• Le ***genre*** : masculin et féminin & le ***but poursuivi*** : avoir de bonnes notes, être populaire ou réussir dans les sports).

L'hypothèse d'intérêt est que ***les deux facteurs sont indépendants***.

Soit X_{ij} le nombre d'individus dans l'échantillon qui sont dans la catégorie i du premier facteur et la catégorie j du second facteur. Une façon de présenter les données serait sous la forme d'un tableau à deux facteurs.

Tableau à deux facteurs

	Facteur 2				
Facteur 1	1	2	$\cdots$	c	Total
1	X_{11}	X_{12}	$\cdots$	X_{1c}	r_1
2	X_{21}	X_{22}	$\cdots$	X_{2c}	r_2
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
r	X_{r1}	X_{r2}	$\cdots$	X_{rc}	r_r
Total	c_1	c_2	$\cdots$	c_c	n

où les r_i et les c_j sont les totaux (aléatoires) des rangées et des colonnes, respectivement. Donc

$$n = \sum_{i=1}^{r} r_i = \sum_{j=1}^{c} c_j$$

Hypothèse d'indépendance

Soit p_{ij} , la probabilité d'être classifié dans la catégorie i du facteur 1 et la catégorie j du facteur 2. Alors

$$p_{i\,.} = \sum_{j=1}^{c} p_{ij} \text{ et } p_{.\,j} = \sum_{i=1}^{r} p_{ij}$$

représentent les probabilités marginales pour les facteurs 1 et 2, respectivement, par exemple les probabilités d'être un gars ou une fille d'une part et les probabilités de vouloir avoir de bonnes notes, être populaire ou réussir dans les sports, d'autre part.

L'hypothèse d'intérêt est l'indépendance des deux facteurs. Sous cette hypothèse,

Nombre espéré et test du *khi*-deux

Si l'hypothèse nulle est vraie, la proportion espérée de personnes dans la cellule i, j est $p_{i,j} = p_{i\,.}\; p_{.\,j}$ qui est estimé à partir du tableau à deux facteurs par $\widehat{p}_{i\,.}\; \widehat{p}_{.\,j}$, où

$$\widehat{p}_{i\,.} = \frac{r_i}{n} \quad \text{et} \quad \widehat{p}_{.\,j} = \frac{c_j}{n}.$$

Si H_0 est vraie, le nombre espéré de personnes dans la cellule i, j est $n\, p_{i,j} = n\, p_{i.}\; p_{.j}$ qui est estimé par $n\, \widehat{p}_{i.}\; \widehat{p}_{.j} = r_i\, c_j / n$.

On a donc des nombres de personnes observés X_{ij} et des nombres espérés $n\, \widehat{p}_{i.}\; \widehat{p}_{.j} = r_i\, c_j / n$ dans chaque cellule i, j. Si H_0 est vraie, ces nombres devraient être proches. On utilise la statistique du *khi-deux de Pearson* pour mesurer la distance (l'écart) entre les tableaux observé et espéré :

$$X^2 = \sum_{i=1}^{r} \sum_{j=1}^{c} \frac{\left(X_{i,j} - r_i\, c_j / n\right)^2}{r_i\, c_j / n}$$

$$= \sum_{\text{toutes les celleules}} \frac{\left(\text{Observé} - \text{Espéré}\right)^2}{\text{Espéré}}$$

Test *khi*-deux

Si l'hypothèse nulle est vraie, la statistique X^2 suit approximativement une distribution χ^2 avec $(r-1)(c-1)$ degrés de liberté.

- Si H_0 n'est pas vraie, les valeurs observées et espérées seront différentes et X^2 aura tendance à être grand.
- Le degré de liberté *dl* est

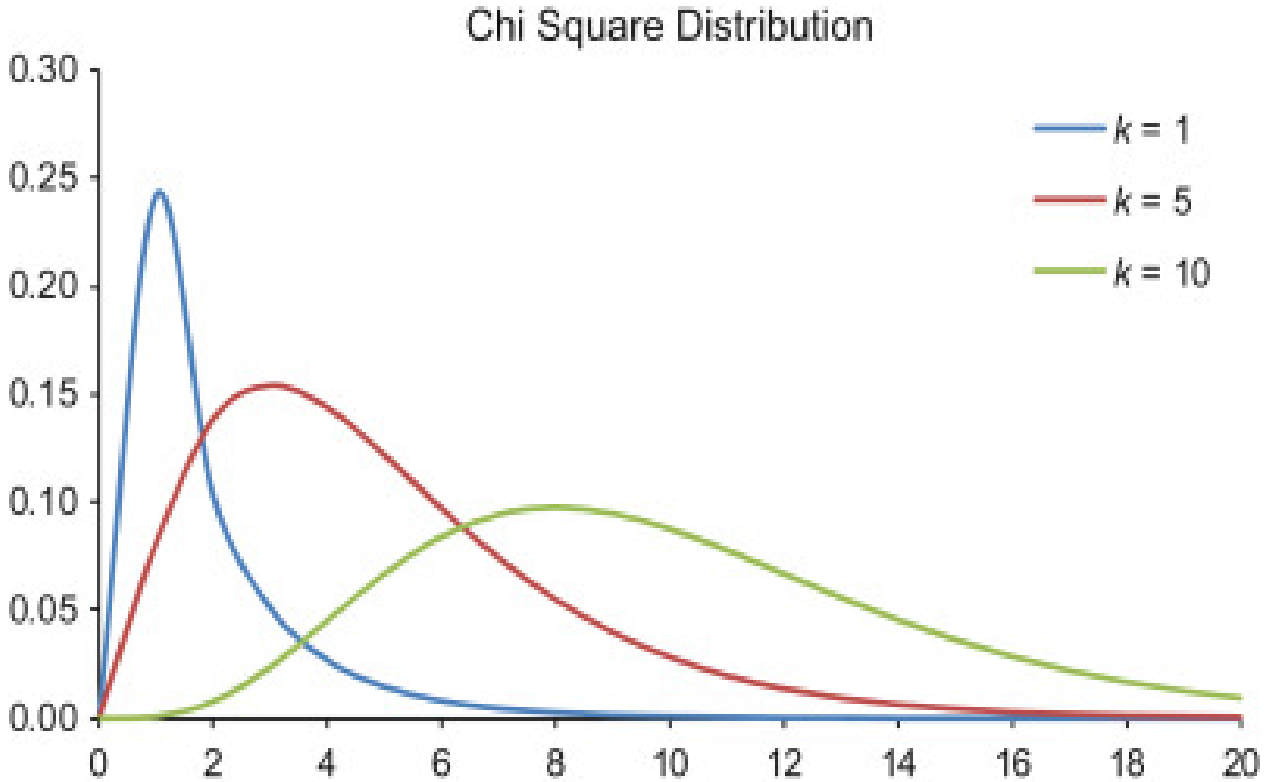
$$dl = \text{nombre de paramètres indépendants} - \text{ nombre de paramètres estimés .}$$

Dans ce cas $dl = (rc-1) - (r-1) - (c-1)$ puisque $\sum_{i=1}^{r}\sum_{j=1}^{c} p_{ij} = 1$ et $\sum_{i=1}^{r} p_{.j} = \sum_{j=1}^{c} p_{i.} = 1$. Donc

$$dl = \nu = rc - 1 - (r-1) - (c-1) = (r-1)(c-1).$$

Distribution *khi*-deux avec k degrés de liberté : χ^2_k

Soit $Z_1, Z_2, ..., Z_k$ des variables aléatoires i.i.d. normale standard, alors $\sum_{i=1}^{k} Z_i^2$ suit une distribution *khi-deux* à k degrés de liberté (*dl*), dénotée par χ^2_k.



2. Test d'indépendance du *Khi* carré

Nous étudions dans cette section le lien d'indépendance (ou de corrélation) entre deux variables. En particulier, nous verrons un critère nous permettant de rejeter (ou de valider) l'hypothèse d'indépendance H_0 entre deux variables X et Y.
Autrement dit, nous allons confronter les hypothèses

H_0 : X et Y sont indépendantes : l'hypothèse nulle (ou l'hypothèse d'intérêt)

vs H_a : X et Y sont dépendantes : l'hypothèse alternative (ou la contre-hypothèse).

Exemple des buts vs le genre

Nous cherchons analyser le lien entre le genre (Masculin, Féminin) et le but poursuivi (avoir de bonnes notes, être populaire ou réussir dans les sports). En particulier, nous nous demandons si ces deux variables sont indépendantes. Existe t-il un lien entre ces deux facteurs (genre et but). Est-ce que le caractère genre pourrait influencer le choix du but à poursuivre ?

Comment répondre à une telle question ?

Nous choisissons un échantillon aléatoire simple (A.S.) d'étudiants de taille n ($n = 478$) et l'on classifie les individus selon les deux variables (genre et but).

2. Test d'indépendance du *Khi* carré

Nous obtenons un tableau de fréquence *à double entrée* qui classifie les 478 étudiants selon le genre et le but poursuivi.

	But poursuivi			
Genre	Notes	Populaire	Sports	Total
Filles	130	91	30	251
Garçons	117	50	60	227
Total	247	141	90	478

Tableau de le fréquences observées.

Ce tableau contient $2 \times 3 =$**6** fréquences **observées** des individus selon toutes les catégories.

Hypothèses du test de Khi-carré

Nous confrontons les hypothèses

H_0 : le genre et le but pousuivi sont indépendants

vs

H_a : Il y a une dépendance entre le genre et le but poursuivi.

Théoriquement, i H_0 est vraie, nous devrions trouver les fréquences suivantes

	But poursuivi			
Genre	Notes	Populaire	Sports	Total
Filles	$\frac{251\times247}{478} = 129,7$	$\frac{251\times141}{478} = 74,0$	$\frac{251\times90}{478} = 47,3$	251
Garçons	$\frac{227\times247}{478} = 117,3$	$\frac{227\times141}{478} = 67,0$	$\frac{227\times90}{478} = 42,7$	227
Total	247	141	90	478

Tableau de fréquences théoriques (ou espérées).

Ce tableau contient **6** fréquences **espérées** (ou théoriques) des individus selon toutes les catégories.

Satatistique du test d'indépendance du *Khi* carré

Note Si H_0 est vraie, les fréquences observées et celles espérées devraient être proches. On utilise la statistique *Khi*-deux pour mesurer l'écart entre les tableaux

observé et espéré.

$$\chi^2 = \sum \frac{(\text{Observé} - \text{Espéré})^2}{\text{Espéré}}.$$

Note : Si H_0 est vraie, la valeur de χ^2 aura tendance à être faible.
Note : Si H_0 n'est pas vraie, χ^2 aura tendance à être grande.
Note : Étant donné que χ^2 dépend de l'échantillon sélectionné, donc plusieurs valeurs de χ^2 sont possibles. La distribution de la statistique χ^2 suit la loi *Khi*-deux ou *Khi*-carrée, notée χ^2_ν, de degré de liberté $\nu = (2-1) \times (3-1) =$**2**.

D'une façon générale, le **degré de liberté** ν est donné par

$$\nu = (\#\text{de cathégorie de la 1e variable -1}) \times (\#\text{de cathégorie de la 2e variable -1}).$$

Distribution *Khi* carré



La distribution ***Khi* carré**, χ^2, de degré de liberté $\nu = 1, 2, 3, 4, \ldots$ est décrite par la courbe ci-haut. La proportion des surfaces rouge α sont données dans le Tableau du *KHI CARRÉE* (voir Table E).

Dans le cas des variables *genre* et *Buts poursuivi*, la statistique

$$\chi^2 = \sum \frac{(\text{Observé} - \text{Espéré})^2}{\text{Espéré}}$$

est donnée par la somme des valeurs $\frac{(\text{Observé} - \text{Espéré})^2}{\text{Espéré}}$ dans tableau suivant :

	But poursuivi		
Genre	Notes	Populaire	Sports
Filles	$\frac{(130-129,7)^2}{129,7} = 0,000693$	$\frac{(91-74,0)^2}{74,0} = 3,9054$	$\frac{(30-47,3)^2}{47,3} = 6,3274$
Garçons	$\frac{(117-117,3)^2}{117,3} = 0,000767$	$\frac{(50-67,0)^2}{67,0} = 4,3134$	$\frac{(60-42,7)^2}{42,7} = 7,0091$

Donc

$$\chi^2 = \sum \frac{(\text{Observé} - \text{Espéré})^2}{\text{Espéré}} = 21,46.$$

Étapes du Test d'indépendance

- **Seuil de signification :** On fixe un niveau de signification α (0.05 ou 0.02 ou 0.01).
- **Degré de liberté :** On détermine ν (ici $\nu = 2$).
- **Valeur critique de χ^2 :** on détermine $\chi^2_{\alpha,\nu}$ à l'aide de la Table de la loi *Khi-deux* (voir manuel du cours).
- **Comparaison :** On compare la valeur observée χ^2 avec $\chi^2_{\alpha,\nu}$
- **Décision :** Si $\chi^2 \geq \chi^2_{\alpha,\nu}$, nous rejettons l'hypothèse H_0. Si $\chi^2 \leq \chi^2_{\alpha,\nu}$, nous rejettons l'hypothèse H_a.

Revenons à l'exemple **Genre** vs **But**. Si le niveau de confiance est fixé à $C = 98\%$, $\alpha = 0.02$ et donc, $\chi^2_{\alpha,\nu} = \chi^2_{0.02,2} = 7,82$ d'après Table E (aide-mémoire). Il s'avère que $\chi^2 = 21,46 > \chi^2_{0.02,2} = 7,82$ et donc $\chi^2 = 21,46$ se situe dans la zone de rejet.
Ainsi, à un seuil de signification de 2%, nous rejettons l'hypothèse que les buts porsuivis et le genre sont des facteurs indépendants.