201-SN1-BB
Mathématiques pour l'IA

Zied, Ben Salah

Collège de Bois-de-Boulogne

Automne 2026

Corrélation linéaire et droite de régression

- Section 1 Nuage de points
- Section 2 Corrélation
- Section 3 Régréssion des moindres carrés

Étude de deux variables

Les principes pour étudier deux variables plutôt qu'une demeurent les mêmes :

- Combinaison de représentations graphiques et de résumés numériques (statistiques) ;
- Chercher l'allure générale ;
- Chercher des modèles statistiques compacts pour résumer les données en plus de statistiques descriptives pour certains aspects..

Il y a deux types de relation pour deux variables.

- Association ;
- Cause à effet.

Une variable explicative est une variable qui tente d'expliquer le comportement d'une autre, soit la variable expliquée.

Relation entre deux variables quantitatives & Nuage de points

Le graphique de deux variables quantitatives est un nuage de points. C'est un graphique formé de points de coordonnées $(x_1, y_1) \cdots (x_n, y_n)$ correspondant aux valeurs de deux variables X et Y (n : nombre d'observations ou taille de l'échantillon).

On distingue deux variables :

- **Une variable explicative X :** une variable qui tente expliquer le comportement de l'autre, soit Y .
- **Une variable expliquée Y :**

Exemple :

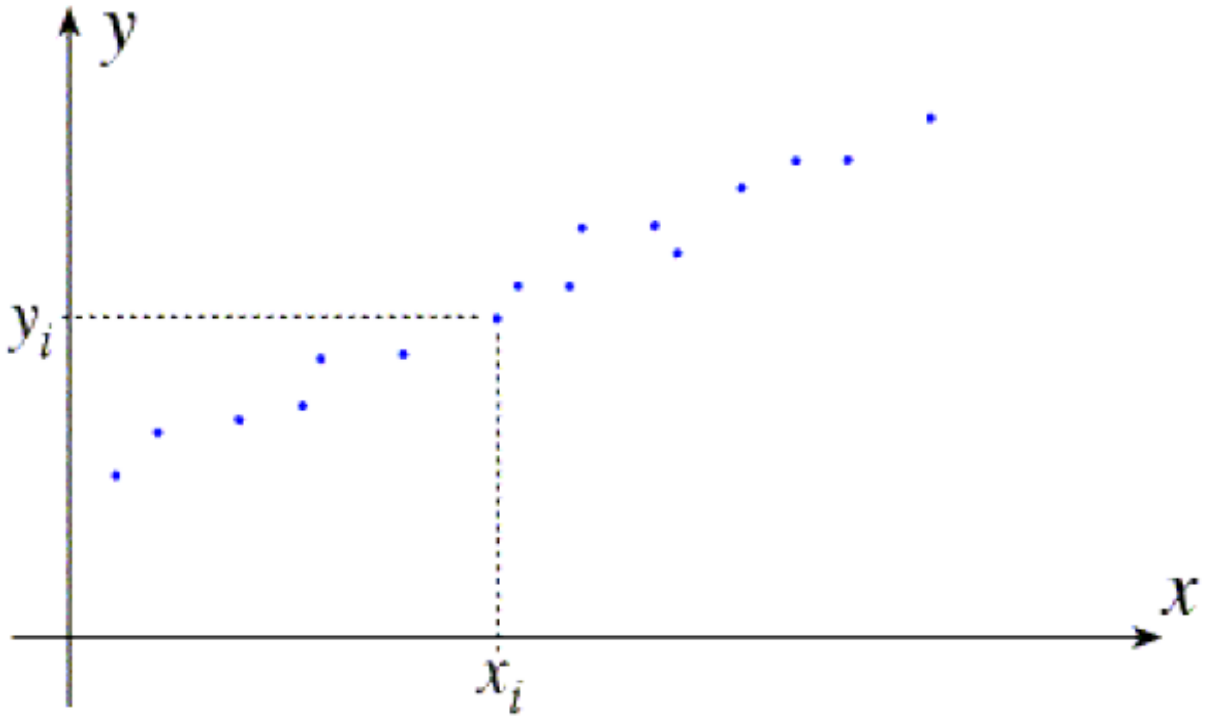
- X : expérience et Y : salaire ;
- X : âge et Y : expérience ;
- X : temps de jeu et Y : nombre de parties jouées.

Comment représenter le nuage de points

On suppose qu'on n observations. Chaque couple de valeurs (x_i, y_i) correspond aux valeurs respectives de deux variables X et Y du i^e individu. On place tous les points de coordonnées $(x_1, y_1) \cdots (x_n, y_n)$ pour obtenir le graphique du **nuage de points**.

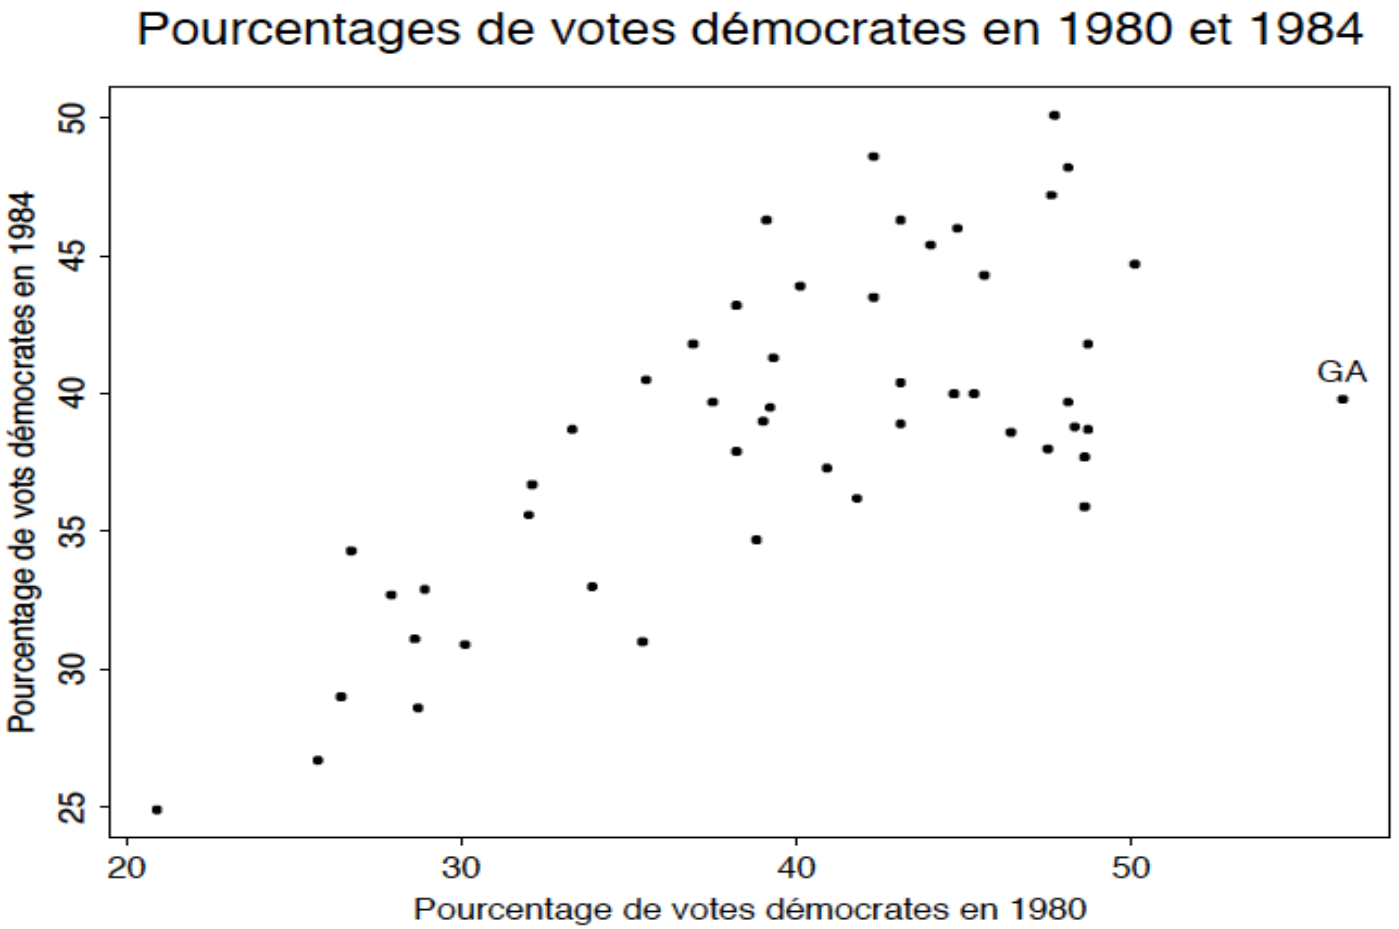
On distingue deux variables :

- la valeur de X de la i^e observation, x_i, est toujours placée sur l'axe horizontal.
- la valeur de Y de la i^e observation, y_i, est toujours placée sur l'axe vertical.



x_i et y_i sont les valeurs respectives de deux variables X et Y (associées à la i^e unité statistique/individu).

Nuage de points : Vote des démocrates



Relations entre deux variables quantitatives

Liaison positive et négative

Deux variables sont positivement (négativement) liées lorsque des valeurs au-dessus de la moyenne pour la variable 1 (variable X) correspondent à des valeurs au-dessus (au-dessous) de la moyenne pour la variable 2 (variable Y) et les valeurs au-dessous de la moyenne pour la variable 1 correspondent à de valeurs audessous (au-dessus) de la moyenne pour la variable 2.

Les deux variables tendent à augmenter (ou diminuer) ensemble lorsque la liaison est positive (négative).

En regardant un nuage de points, on cherche d'abord l'allure générale, puis des déviations importantes de celle-ci. On peut décrire l'allure générale par la forme, la direction et la force de la relation. Un type important de déviation est une valeur aberrante.

Comment mesurer la force de la **relation linéaire** entre deux variables ?

Autrement dit, comment s'assurer si la relation entre deux variables X et Y pourrait être expliquée par un modèle linéaire, soit de la forme

$$y = a + bx$$

(où a et b sont des constantes)

Nous pourrions observer :

- **l'allure du nuage de points :** plus le nuage de points a tendance à se regrouper autour d'une **droite**, plus la **corrélation linéaire** (relation linéaire) est forte. Inversement, plus la dispersion de points est forte, plus la corrélation linéaire entre les deux variables est faible.
- Calcul du **Coefficient de corrélation** r :

$$r = \frac{1}{(n-1)} \sum_{i=1}^{n} \left(\frac{x_i - \bar{x}}{s_x} \right) \left(\frac{y_i - \bar{y}}{s_y} \right).$$

Coefficient de corrélation r

Une formule plus facile à utiliser pour le calcul de la corrélation :

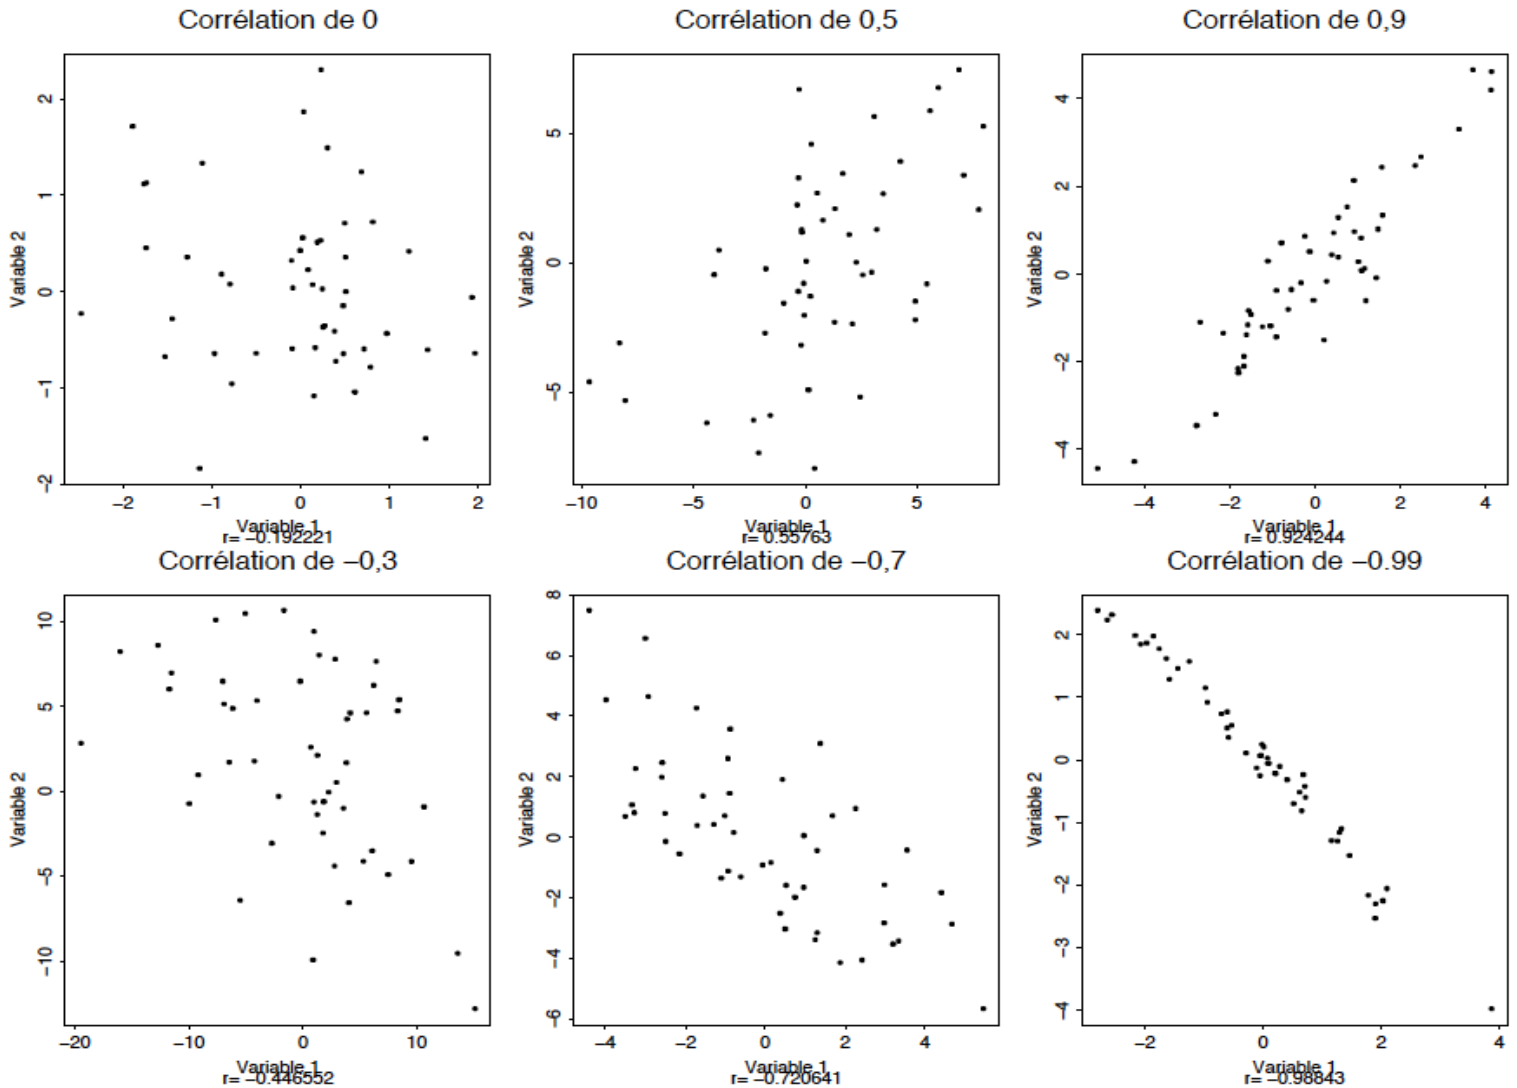
$$r = \frac{\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{(n-1)s_x s_y},$$

$\bar{x}$ (et $\bar{y}$), s_x (et s_y) sont respectivement les moyennes et les écart-types de X et Y.

Notes

- r est une valeur vérifiant $-1 \leq r \leq 1$;
- Plus r est proche de 1 ou de -1, plus la corrélation linéaire est forte (Plus la présence d'un lien linéaire $Y = a + bX$) ;
- Si r est **positif** (respect. **négatif**) alors la corrélation est **positive** (respect. **négative**) ;
- Plus r est proche de 0, plus le nuage de points a tendance à se disperser (la corrélation linéaire est de plus en plus faible). Inversement, Plus r est proche de 1 ou de -1, plus le nuage de points a tendance à se regrouper autour d'une **droite** (la corrélation linéaire est donc forte).

Différentes corrélations



Régression linéaire simple

Lorsque la relation entre deux variables quantitatives X et Y est linéaire (r est suffisamment proche de 1 ou de -1), comment peut-on résumer cette relation ?

En estimant la droite de régression, soit la droite qui décrit la relation de dépendance d'une variable par rapport à une autre. Dans ce cas, on tente d'exprimer la variable expliquée en fonction de la variable explicative. Il faut donc trouver la droite qui se "rapproche" le plus des données, ce qu'on appelle ajuster une droite aux données (*fitting a line to data*). Pour ça, il faut se donner un critère. C'est la droite qui se "rapproche" le plus des points et qui décrit donc le mieux l'allure du nuage. Elle s'appelle la droite de régression ou la *droite des moindres carrés*.

Cette droite satisfait l'équation $y = a + b\,x$ et elle permet

- La prévision pour des valeurs de X observées ou d'autres valeurs ;
- c'est à dire, si x_0 est la valeur de la variable explicative pour laquelle on veut prévoir la valeur y_0 de la variable expliquée, alors la prévision est

$$y_0 = y = a + b\,x_0.$$

Une droite est représentée par l'équation

$$y = a + b\,x\ .$$

Soit $(x_1, y_1), \ldots, (x_n, y_n)$ les n paires de données. Puisqu'ils ne seront pas tous sur la droite, il y aura un écart entre ces points et la droite. La droite de régression **minimise** la somme du **carré de l'écart** vertical entre le point et la droite.

Droite de régression

Identifier la droite de régression, revient à calculer les coefficients a et b de son équation : $y = a + bx$ (b est la pente de la droite).

Les coefficients a et b sont donnés par

- $b = r \cdot \frac{s_y}{s_x}$
- $a = \bar{y} - b\,\bar{x}$.

r : coefficient de corréalation

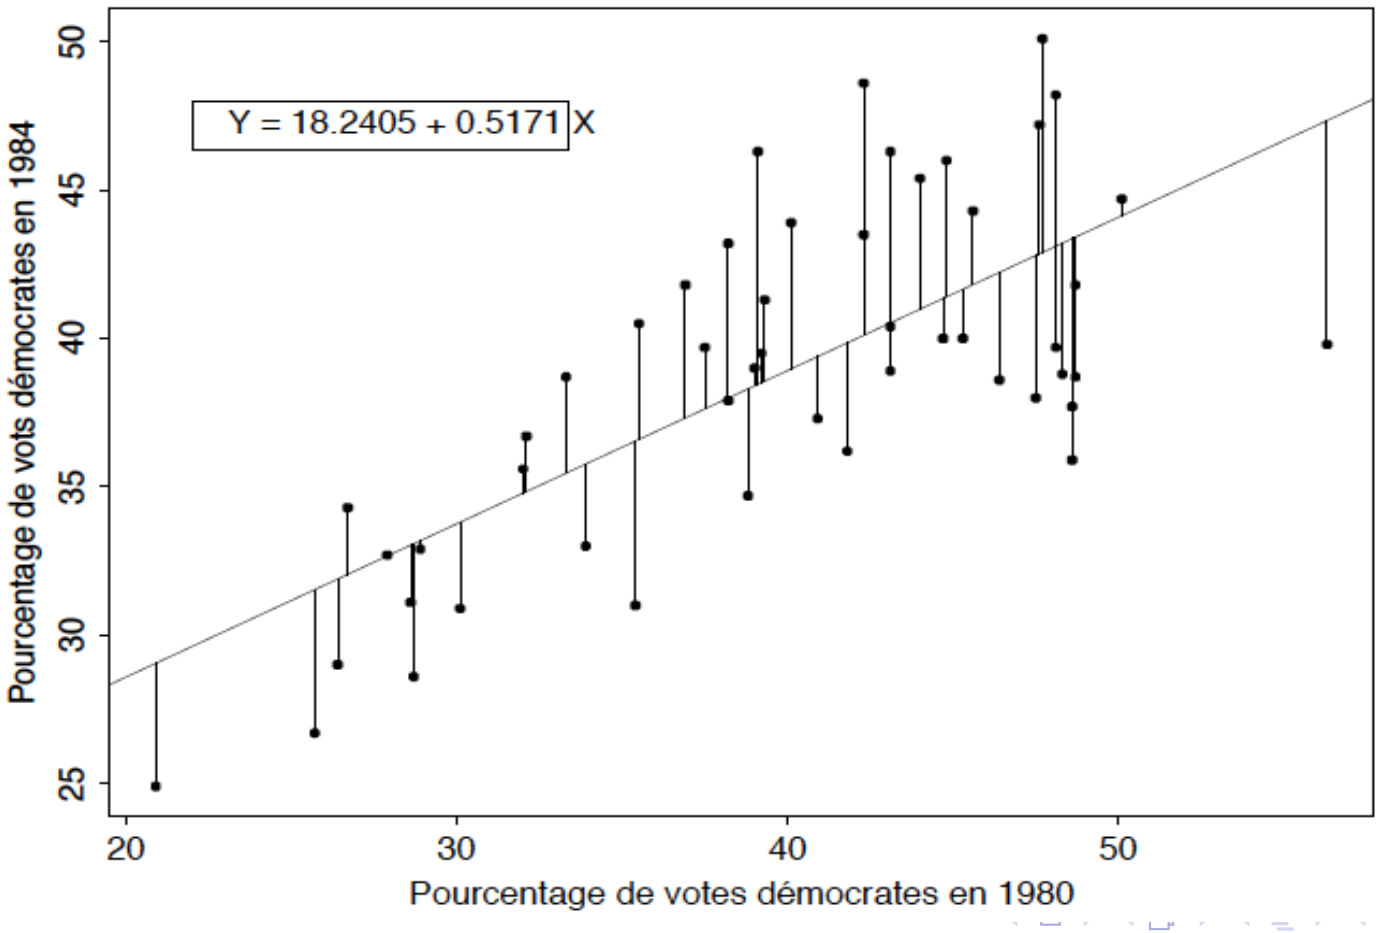
$\bar{x}$: moyenne de la variable explicative X,

$\bar{y}$: moyenne de la variable explicative Y,

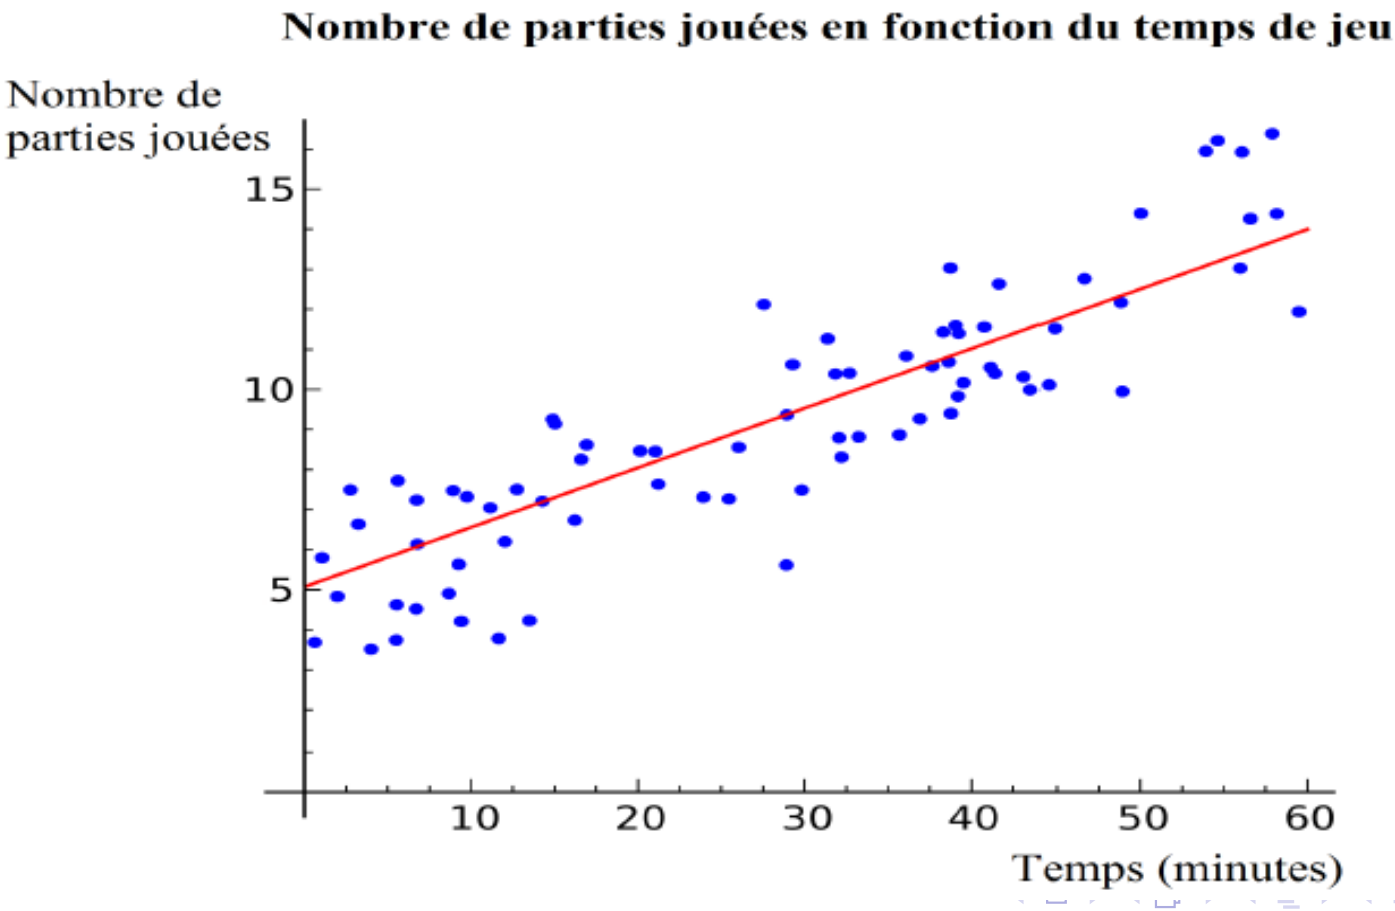
s_x : écart-type de la variable explicative X,

s_y : écart-type de la variable explicative Y.

Droite de régression/moindre carrés : Vote des démocrates



Droite de régression : Parties jouées vs temps de jeux



Notes

- La droite de régression passe par le point de cordonnées $(\bar{x}, \bar{y})$;
- Si la valeur x_0 est éloignée de nos données observées, on veut alors faire une **extrapolation**. Ce qui peut être dangereux puisque les données ne pourront pas nous aider à décider si le modèle utilisé tient pour une telle valeur de x_0.

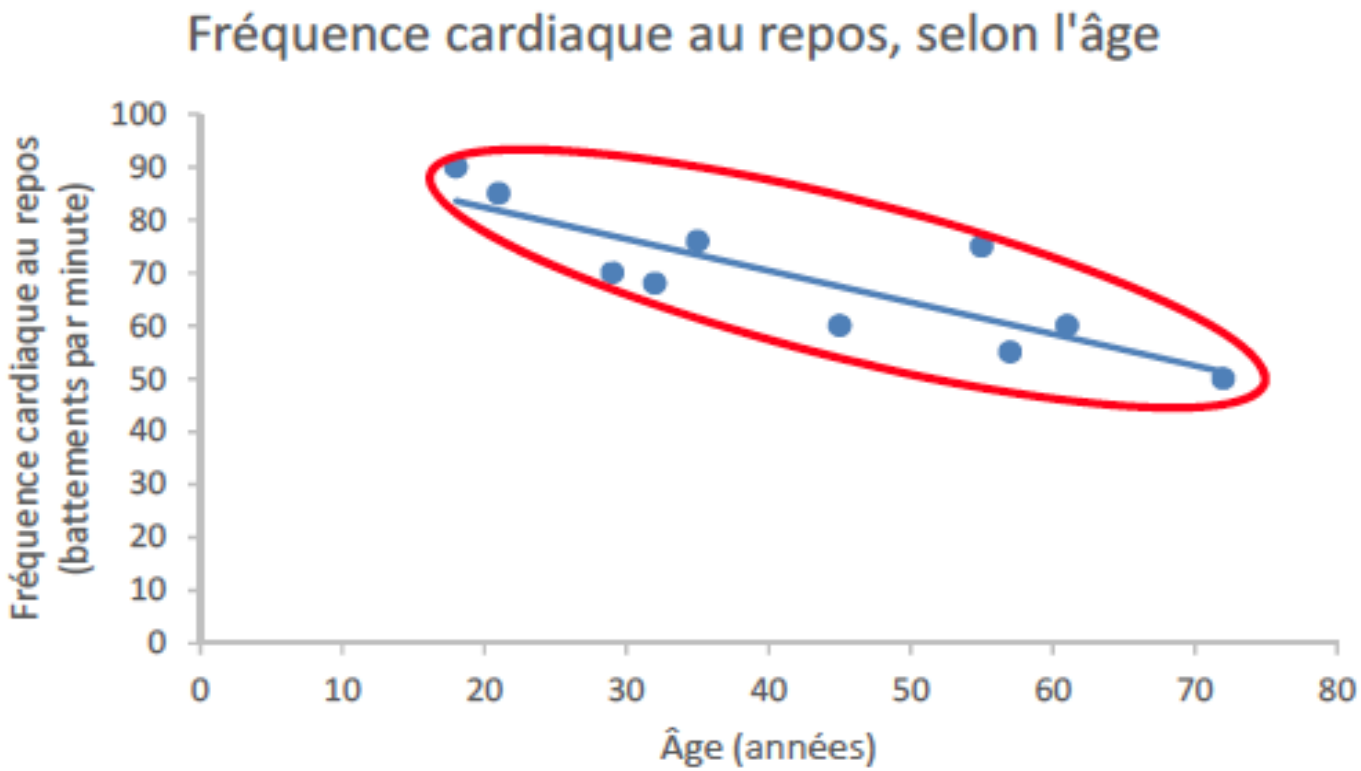
Exemple : Âge et Fréquence cardiaque

Âge de 10 adultes et leur fréquence cardiaque au repos exprimée en nombre de battements par minute (bpm)

Âge (années)	Fréquence cardiaque (bpm)	Âge (années)	Fréquence cardiaque (bpm)
18	90	21	85
45	60	29	70
57	55	55	75
61	60	72	50
32	68	35	76

STATISTIQUE CANADA, Fréquence cardiaque au repos moyenne, selon l'âge et le sexe, population à domicile, Canada, 2009 à 2011, publication 82-626-X. < http ://www.statcan.gc.ca/pub/82-626-x/2013001/t004-fra.htm >.

Âge et fréquence cardiaque : Nuage de points



Nuage de points et droire de régression.

Relation entre l'âge et fréquence cardiaque

• Le nuage de points semble indiquer un lien entre les deux variables. On peut entourer le nuage de points d'un ovale relativement étroit.

• Le modèle linéaire décrit bien cette relation puisque les points s'agglutinent autour d'une droite.

• La corrélation entre ces deux variables est négative et elle parait relativement forte. La pente de la droite de régression est négative : les valeurs faibles d'âge (en dessous de la moyenne d'âge) sont associées aux valeurs élevées de fréquence cardiaque (au dessus de la moyenne des bpm) , et les valeurs fortes d'âge aux valeurs faibles de fréquence cardiaque.

- Les moyennes observées de l'âge et de la fréquence cardiaques sont respectivement

$$\bar{x} = \frac{\sum_{k=1}^{10} x_k}{10} = 42,5 \text{ ans}, \quad et \quad \bar{y} = \frac{\sum_{k=1}^{10} y_k}{10} = 68,9 \text{ bpm} .$$

- Les écart-types observées de l'âge et de la fréquence cardiaque sont respectivement

$$s_x = \sqrt{\frac{\sum_{k=1}^{10}(x_k - 42,5)^2}{9}} = 18,25 \text{ ans}, \quad et \quad s_y = \sqrt{\frac{\sum_{k=1}^{10}(y_k - 68,9)^2}{9}} = 12,92 \text{ bpm} .$$

- On a $\sum_{k=1}^{10} x_k\, y_k = 27\,491$, et donc le coefficient de corrélation est

$$r = \frac{\sum_{i=1}^{n} x_i y_i - n\bar{x}\bar{y}}{(n-1)s_x s_y} = \frac{27\,491 - 10 \times 42,4 \times 68,9}{9 \times 18,25 \times 12,92} = -0,8441 .$$

- Droite des moindres carrés : $y = a + b\,x$, où la pente $b = r \cdot \frac{s_y}{s_x} = -0,597$ et l'ordonnée à l'origine $a = \bar{y} - b\,\bar{x} = 94,309$. L'équation de la droite des moindres carrés est donc $y = 94,31 - 0,597\,x$ (à vérifier avec Excel/autre logiciel !).

Prédiction

Nous utilisons la droite de régression pour prédire en moyenne la fréquence cardiaque (*une valeur de la* ***variable expliquée***) pour une personne âgée de 25 ans (*une valeur donnée de la* ***variable explicative***).

• **Prédiction :** Selon ce modèle linéaire, la fréquence cardiaque (en moyenne) d'un adulte de 25 ans est environ

$$\widehat{y} = 94,31 - 0,597 \times \widehat{x} = 94,31 - 0,597 \times 25 = 79,4 \text{ bpm} .$$

Coefficient de détermination r^2

Le coefficient de détermination $r^2 \in [0, 1]$ (Carré du coefficient de corrélation) représente la proportion des données expliquées par le modèle linéaire.

• **Âge et Fréquence cardiaque :** Selon ce modèle linéaire çi-haut, $r^2 = 0,7125 = 71,25\%$. Ceci veut dire que $71,25\%$ des données de la fréquence cardiaque (variable expliquée) peuvent être expliquées (ou prédites) par ce modèle linéaire, tandis que $28,75\%$ de ces données sont expliquées par d'autres facteurs (autre que le lien linéaire).

• Tout comme r, le coefficient de détermination r^2 est un bon indicateur sur l'adéquation du modèle linéaire avec les données observées. Plus r^2 est proche de 1, plus le modèle de régression linéaire est adéquat. À l'inverse, plus r^2 est proche de 0, moins la présence d'une corrélation linéaire entre les deux variables.