# Partie 1 : Probabililités & Variables aléatoires

## Calcul de probabilités & dénombrement

1. Supposons qu'on a 8 étudiants (3 filles et 5 garçons).
   (a) On souhaite placer les 8 étudiants en ligne pour une photo. Combien de dispositions différentes sont possibles ?
   (b) On veut former un bureau composé d'un(e) *président(e)*, un(e) *vice-président(e)*, et un(e) *secrétaire*. Combien de bureaux différents peut-on former ?
   (c) On veut choisir un groupe de 4 étudiants parmi ces 8 pour participer à un concours.
      i. Combien de groupes différents peut-on former ?
      ii. Combien de groupes contiennent obligatoirement deux filles ?
      iii. Quelle est la probabilité d'avoir un groupe contenant au moins une fille ?

**Réponse**

(a) **Nombre de dispositions différentes pour la photo :**

Il s'agit de placer les 8 étudiants de manière ordonnée en ligne. Le nombre de dispositions possibles correspond au nombre de permutations de 8 éléments.

**Résultat :** $8!$

*Calcul numérique :* $8! = 40\,320$ dispositions.

(b) **Nombre de bureaux différents (président(e), vice-président(e), secrétaire) :**

L'ordre des rôles est important et les personnes choisies doivent être distinctes. Il s'agit donc d'un arrangement de 3 éléments parmi 8.

**Résultat :** $A_8^3$

*Calcul numérique :* $A_8^3 = \frac{8!}{(8-3)!} = 8 \times 7 \times 6 = 336$ bureaux.

(c) **Choix d'un groupe de 4 étudiants parmi les 8 :**

i. **Nombre de groupes différents :**

L'ordre des membres au sein du groupe n'a pas d'importance. Il s'agit donc d'une combinaison de 4 éléments parmi 8.

**Résultat :** $\binom{8}{4} = \frac{8!}{4!(8-4)!} = \frac{8\times7\times6\times5}{4\times3\times2\times1} = 70$ groupes.

ii. **Nombre de groupes contenant obligatoirement deux filles :**

Pour former ce groupe, on doit choisir précisément 2 filles parmi les 3 disponibles *et* compléter le groupe en choisissant 2 garçons parmi les 5 disponibles.

**Résultat :** $\binom{3}{2} \times \binom{5}{2} = 3/times10 = 30$

iii. **Probabilité d'avoir un groupe contenant au moins une fille :**

Il est plus simple de passer par l'événement contraire, qui consiste à former un groupe composé uniquement de garçons (aucune fille). Le nombre de groupes formés uniquement de garçons est $\binom{5}{4}$.

La probabilité de l'événement contraire est :

$$P(\text{Aucune fille}) = \frac{\binom{5}{4}}{\binom{8}{4}}$$

Par conséquent, la probabilité d'avoir au moins une fille est :

**Résultat :** $1 - \frac{\binom{5}{4}}{\binom{8}{4}} = \frac{13}{14} \approx 0{,}9286$ .

### Probabilités conditionnelle, probabilités totales & méthode de Bayes

2. Dans un cours de statistique, l'enseignant présente trois thèmes, A, B et C. Pour évaluer un étudiant, l'enseignant choisi au hasard un thème selon les probabilités suivantes : $P(A) = 0.3$, $P(B) = 0.2$ et $P(C) = 0.5$. L'enseignant observe que les prestations des élèves dépendent du thème. Il range ces prestations en trois catégories : E pour un échec total, R pour une interrogation à revoir pour confirmer la compréhension du sujet et S pour un succès.
L'enseignant constate les performances suivantes :
• thème A : 25% des étudiants obtiennent un succès S, 30% sont à revoir R, le reste en échec E ;
• thème B : 40% des étudiants sont en échec, pour 40% en succès, le reste étant à revoir ;
• thème C : on atteint ici 50% d'échec, 30% à revoir, le reste en succès.

(a) Calculez la probabilité qu'un étudiant soit en échec dans cette procédure d'évaluation.

(b) Sachant que l'étudiant est à revoir, calculez la probabilité qu'il ait été interrogé sur le thème C.

**c)** les évènements « être interrogé sur le thème B » et « obtenir un échec E » sont-ils indépendants ? Justifiez votre réponse.

**Réponse**

**a)** D'après la *loi des probabilités totales*, la probabilité qu'un *étudiant soit en échec* $(E)$ est

$$\begin{aligned} P(E) &= P(E|A)\,P(A) + P(E|B)\,P(B) + P(E|C)\,P(C) \\ &= 0.45 \times 0.3 + 0.4 \times 0.2 + 0.5 \times 0.5 \\ &= 0,465. \end{aligned}$$

**b)** C'est clairement une application du *théorème de Bayes* (combinaison de la définition d

ela probabilité conditionnelle avec la loi des probabilités totales). On demande

$$\begin{aligned} P(C|R) &= \frac{P(R|C)\,P(C)}{P(R|A)\,P(A)+P(R|B)\,P(B)+P(R|C)\,P(C)} \\ &= \frac{0.3\times 0.5}{0.3\times 0.3+0.2\times 0.2+0.3\times 0.5} \\ &= \frac{15}{28}\,. \end{aligned}$$

**c)** La probabilité d'« être interrogé sur le thème B » et d'« obtenir un échec E » est

$$P(B\cap E) = P(E|B)\,P(B) = 0.4\times 0.2$$

qui est différente de

$$P(B)\,P(E) = 0.2\times 0.465\,.$$

Donc les deux évènements ne sont pas indépendants.

3. Une entreprise possède trois machines $A$, $B$ et $C$. La machine A produit 40% des pièces, la machine B produit 35% des pièces, et la machine C produit 25% des pièces.

Les pourcentages de pièces défectueuses sont :

— 3% si la pièce provienne de la machine A,

— 5% la pièce provienne de la machine B,

— 8% la pièce provienne de la machine C.

On choisit une pièce au hasard, et on définit les évènements suivants :

— $A, B, C$ les événements « *la pièce provient de la machine A, B ou C (resp.)* »,

— $D$ l'événement « *la pièce est défectueuse* ».

(a) Calculez $P(C\cap D)$ et $P(C\cup D)$.

(b) Calculez la probabilité qu'une pièce soit défectueuse.

(c) Calculez la probabilité qu'une pièce soit non défectueuse.

(d) Sachant qu'une pièce est défectueuse, déterminez la probabilité qu'elle provienne de la machine C.

(e) Les événements « provenir de la machine B » et « être défectueuse » sont-ils indépendants ? Justifiez.

**Réponse**

(a) **Calcul de $P(C\cap D)$ et $P(C\cup D)$ :**

— Pour l'intersection :

$$P(C\cap D) = P(C)\times P(D|C) = 0{,}25\times 0{,}08 = \mathbf{0{,}02}$$

— Pour l'union, on utilise la formule $P(C \cup D) = P(C) + P(D) - P(C \cap D)$.
En utilisant la valeur de $P(D) = 0{,}0495$ (calculée à la question 2) :

$$P(C \cup D) = 0{,}25 + 0{,}0495 - 0{,}02 = \mathbf{0{,}2795}$$

(b) **Calcul de la probabilité qu'une pièce soit défectueuse ($P(D)$) :**
D'après la formule des probabilités totales, la famille $\{A, B, C\}$ formant un système complet d'événements :

$$\begin{aligned}
P(D) &= P(A \cap D) + P(B \cap D) + P(C \cap D) \\
P(D) &= P(A) \times P(D|A) + P(B) \times P(D|B) + P(C) \times P(D|C) \\
P(D) &= (0{,}40 \times 0{,}03) + (0{,}35 \times 0{,}05) + (0{,}25 \times 0{,}08) \\
P(D) &= 0{,}012 + 0{,}0175 + 0{,}02 \\
P(D) &= \mathbf{0{,}0495} \quad (\text{soit } 4{,}95\%)
\end{aligned}$$

(c) **Calcul de la probabilité qu'une pièce soit non défectueuse ($P(\overline{D})$) :**
Il s'agit de l'événement contraire de $D$ :

$$P(D^c) = 1 - P(D) = 1 - 0{,}0495 = \mathbf{0{,}9505} \quad (\text{soit } 95{,}05\%)$$

(d) **Calcul de la probabilité qu'elle provienne de la machine C sachant qu'elle est défectueuse ($P(C|D)$) :**
D'après la formule de Bayes :

$$P(C|D) = \frac{P(C \cap D)}{P(D)} = \frac{0{,}02}{0{,}0495} = \frac{200}{495} = \frac{40}{99} \approx \mathbf{0{,}404} \quad (\text{soit environ } 40{,}4\%)$$

(e) **Indépendance des événements $B$ et $D$ :**
Rappelons que deux événements $B$ et $D$ sont indépendants si et seulement si $P(D|B) = P(D)$ (ou $P(B \cap D) = P(B)P(D)$). Puisque $P(D|B) = 0{,}05 \neq \mathbb{P}(D) = 0{,}0495$, les deux évenements sont **dépendants**.

### Variables aléatoire et lois de probabilités

4. **Loi de Poisson** On suppose que le nombre d'accidents par jour $X$ est une variable aléatoire qui suit une loi de Poisson du paramètre 2 (un taux de 2 accident par jour), soit la probabilité d'avoir $n$ accidents ($n \in \mathbb{N} = \{0, 1, 2, 3, ...; \}$)est

$$\mathbb{P}(X = n) = \frac{2^n}{n!}\, e^{-2} \quad \text{pour} \quad \text{où } 0! = 1! = 1 \text{ et } n! = n \times (n-1) \times \cdots \times 2 \times 1 \text{ pour } n \geq 2.$$

(a) Calculez le nombre moyen d'accidents par jour, $\mathbb{E}[X]$.
Indication : Utilisez l'égalité $\sum_{n=0}^{\infty} \frac{2^n}{n!} = e^2$.

(b) Quelle est la probabilité de ne pas avoir d'accidents.

(c) Quelle est la probabilité d'avoir au moins un accident par jour (i.e. avoir un accident ou plus).

**Réponse**

(a) le nombre moyen d'accidents par jour est

$$\mathbb{E}[X] = \sum_{n=0}^{\infty} n\frac{2^n}{n!}e^{-2} = e^{-2}\sum_{n=1}^{\infty} n\frac{2^n}{n!} = 2e^{-2}\sum_{n=1}^{\infty}\frac{2^{n-1}}{(n-1)!} = 2e^{-2}e^2 = 2\ .$$

(b) La probabilité de ne pas avoir d'accidents est

$$\mathbb{P}[X=0] = \frac{2^0}{0!}e^{-2} = e^{-2} = 0,1353\ .$$

(c) La probabilité d'avoir au moins un accident par jour est

$$\mathbb{P}[X \geq 1] = 1 - \mathbb{P}[X=0] = 1 - e^{-2} = e^{-2} = 1 - 0,1353 = 0,8647\ .$$

.

5. **Loi binomiale**

On lance deux fois un dé équilibré et on observe la *somme* de deux faces obtenues. On répète cette expérience 100 fois. Soit $X$ est le nombre de fois à obtenir une *somme multiple de 6*.

(a) Quelle est la loi de $X$ ? Spécifiez ces paramètres.

(b) Déterminez $\mathbb{P}(X \geq 2)$.

(c) Quelle est l'espérance de $X$, $\mathbb{E}[X]$ ? Quelle est $\mathbb{E}[X^2]$ ?

(a) $X$ suit une bibmiale de paramètre $n = 100$ et $p = 3/6^2 = 1/12$.

(b) $\mathbb{P}(X \geq 2) = 1 - \mathbb{P}(X < 2) = 1 - \mathbb{P}(X \leq 1) = 1 - (\mathbb{P}(X=0) + \mathbb{P}(X=1)) = \cdots\cdots$ (à claculer).

(c) $E(X) = np = 100/12 = 25/3$, $Var(X) = np(1-p) = 1100/(12)^2$ et $\sigma = 10\sqrt{11}/12$ . $\mathbb{E}[X^2] = Var(X) + E(X)^2 = 11100/(12)^2$ .

6. **Variable aléatoire continue**

Le temps d'attente $T$ (en heure ) à un centre de services sociaux est un temps aléatoire de fonction de densité $f(x) = \begin{cases} \lambda(x - x^2) & \text{si } x \in [0,1[ \\ 0 & \text{sinon} \end{cases}$ , où $\lambda$ est une constante.

(a) Quel est le paramètre $\lambda$ ?

(b) Quelle est la proportion de bénéficiaires qui attendront moins de 45 minutes pour obtenir le service ?

(c) Déterminez $\mathbb{E}[X]$, $Var[X]$ et l'écart-type $\sigma_X$ .

(d) Soit $Y$ est une v.a. indépendante de $X$ et de même loi. Déterminez $\mathbb{E}[X(1-Y)]$ et $Var[2Y - X]$.

**Réponse**

**a)** Par intégration simple, nous cherchons $\lambda$ telle que

$$\int_{-\infty}^{\infty} f(x)\,dx = \lambda \int_0^1 (x - x^2)\,dx = 1$$

soit

$$\lambda(\frac{1}{2} - \frac{1}{3}) = \lambda\frac{1}{6} = 1\ .$$

D'où, $\lambda = 6$.

**b)** Notons que $45\,\text{min} = 3/4$ h, La probabilité cherchée est donc

$$\mathbb{P}\left(X \leq \frac{3}{4}\right) = \int_{-\infty}^{3/4} f(x)\,dx = \int_0^{3/4} 6(x - x^2)\,dx = 3(3/4)^2 - 2(3/4)^3 = \frac{27}{32}\ .$$

**c)** Par une simple intégration, l'espérance de $X$ est

$$\mathbb{E}[X] = 6\int_0^1 x(x - x^2)\,dx = 6\int_0^1 x^2 - x^3)\,dx = 6(\frac{1^3}{3} - \frac{1^4}{4}) = \frac{1}{2}(\text{ heure })\ ,$$

soit une moyenne de 30 minutes.

La variance de $X$ est

$$Var(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = 6\int_0^1 x^2(x - x^2)\,dx - \frac{1}{2}^2 = 6(\frac{1^4}{4} - \frac{1^5}{5}) - \frac{1}{4} = \frac{3}{10} - \frac{1}{4} = \frac{1}{20}\ .$$

Notez que l'écart-type de $X$ est $\sigma_X = \sqrt{Var(X)} = \dfrac{1}{2\sqrt{5}}$ heures.

**d)** Par indépendance et par linéarité de l'espérance,

$$\mathbb{E}[X(1-Y)] = \mathbb{E}[X - X\,Y] = \mathbb{E}[X] - \mathbb{E}[XY] = \mathbb{E}[X] - \mathbb{E}[X]\mathbb{E}[Y] = \frac{1}{2} - \frac{1}{2}\times\frac{1}{2} = \frac{1}{4}\ \text{heure} = 15\ \text{minutes}\ ,$$

Même chose, en combinant les propriétés de la variance avec l'indépendance

$$Var[2Y - X] = 2^2 Var[Y] + (-1)^2 Var[X] = 3Var[X] = \frac{3}{20}\ (\text{heure})^2,$$

où on a utilisé le fait que $V[X] = Var[Y] = 1/20$ (même loi).

7. **Loi exponentielle**

Le temps d'attente $T$ (en heure ) à un centre de services sociaux est un temps aléatoire qui obéit à une loi exponentielle de paramètre $\lambda > 0$, i.e. la fonction densité de $T$ est

$$f_T(t) = \lambda\, e^{-\lambda t}\ ,\ \text{pour } t \geq 0.$$

Sachant que le temps d'attente moyen est 25 minutes :

(a) Quel est le paramètre $\lambda$ ?

(b) Quelle est la proportion de bénéficiaires qui attendront moins de 30 minutes pour obtenir le service ?

(c) Le directeur du service responsable du centre d'emploi étudiant souhaite faire l'énoncé suivant : « seulement 10% des gens attendent plus de $k$ minutes pour obtenir le service ». Trouvez ce temps $k$.

**Réponse**

(a) Puisque $T$ est en heure, donc $\mathbb{E}[T] = 25\ min = \frac{25}{60}\ h = \frac{5}{12} = \frac{1}{\lambda}$, donc

$$\lambda = \frac{12}{5} = 2,4\ .$$

Cela signifie que l ?on sert en moyenne 2,4 bénéficiaires par heure.

(b) On a évidemment 30 min = 0,5 heure. En utilisant une simple intégration, la proportion de bénéficiaires qui attendront moins de 30 minutes pour obtenir le service est

$$\mathbb{P}[T < 0,5] = \int_0^{0,5} \lambda e^{-\lambda t} dt = e^{-\lambda 0} = e^{-\lambda(0,5)} = 1 - e^{-1,2} = 0,6988.$$

(c) On cherche $k$ (en minutes) telle que

$$10\% = 0,1 = \mathbb{P}[T \geq k/60] = 1 - \mathbb{P}[T < k/60] = 1 - \int_0^{k/60} \lambda e^{-\lambda t} dt = e^{-0,04k}\ .$$

Ainsi $-0,04k = \ln(0,1)$ et donc $k = -\ln(0,1)/0,04 = 57,565$. Le directeur du service responsable du centre d'emploi étudiant annoncerait que : « seulement 10% des gens attendent plus de 57 minutes et 34 secondes pour obtenir le service ».

8. **Loi normale**

Un professeur d'éducation physique d'une école secondaire organise une épreuve d'athlétisme pour les garçons âgés de 14 ans. On considère que les garçons de 14 ans prennent en moyenne 13.2 secondes pour courir une distance de 100 mètres, alors que l'écart-type est de 0.6 seconde. De plus, on suppose que le temps pour courir le 100 mètres obéit à une loi normale. Utilisez la table de la loi normale $N(0,1)$ pour répondre aux questions suivantes :

(a) Quelle est la proportion de garçons de 14 ans qui prendront plus de 14 secondes pour parcourir le 100 mètres ?

(b) Afin de recruter les meilleurs coureurs du groupe pour représenter l'école dans une compétition nationale, le professeur souhaite déterminer le temps, en secondes, qui permettra d'isoler les plus rapides. Plus spécifiquement, il veut que seulement 1% des garçons soit capable de courir le 100 mètres avec un temps plus court que celui qu'il déterminera. Quel est ce temps ?

**Réponses**

**a)** Soit $X \sim N(13.2, (0.6)^2)$ le temps (en secondes) de courir le 100 mètres. La proportion

de garçons qui prendront plus de 14 est

$$\mathbb{P}\left(X > 14\right) = \mathbb{P}\left(Z \sim N(0,1) > \frac{14 - 13.2}{0.6}\right) = 0.5 - \mathbb{P}\left(0 < Z < 1.33\right) = 9.18\%. .$$

**b)** Notons par $k$ ce temps. On cherche $k$, telle que $P\left(X \leq k\right) = 0,1$ où $X \sim N(13.2, (0.6)^2)$ est le temps pour courir 100 mètres. Notons que $k$ doit être inférieure à 13.2 et donc

$$P\left(X \leq k\right) = P\left(Z \leq \frac{k - 13.2}{0.6}\right) = 0,01\ ,$$

c'est à dire

$$\frac{k - 13.2}{0.6} = -z_{1\%} = -2.33\,, \quad \text{soit } \frac{13.2 - k}{0.6} = z_{1\%} = 2.33 \Longleftrightarrow k \simeq 11.8 \text{ secondes.}$$

# Partie 2 : Statistiques & inférence

## Test d'hypothèse sur une moyenne

1. Le pointage typique à la partie mathématique de cet examen est habituellement de 475. La distribution du pointage est normale avec un écart type de 100. Mais comme ce n'est qu'une minorité des finissants du secondaire qui font l'examen, quelqu'un fait le commentaire suivant : "Si tous les finissants du secondaire faisaient l'examen, la moyenne ne dépasserait pas 450". Afin de vérifier cette hypothèse, on fait une expérience. On prend un EAS de 500 finissants de la Californie et la moyenne de leur pointage est de $\overline{x} = 461$.
   (a) Donnez un intervalle de confiance de niveau 95% pour la moyenne du Test SAT en spécifiant l'erreur standard et la marge d'erreur pour un niveau de confiance de 95% . Rapportez l'intervalle de confiance de niveau 95% dans une phrase qui explique la signification du 95%.
   (b) Testez l'hypothèse que la moyenne du Test SAT est de 450 contre l'hypothèse *unilatérale*. Assurez vous de bien spécifier les hypothèses nulle et alternative, et de calculer la statistique de test ainsi que la valeur-p. Que conluez-vous ? Y a-t-il suffisamment d'évidence pour rejeter l'hypothèse que la moyenne ne dépasse pas 450 ?
   (c) Est-ce que le résultat en b) est significatif au niveau 1%, l'est-il au niveau 0,5% ?
   (d) Décrivez en mots l'erreur de type I et l'erreur de type II pour un test d'hypothèse de niveau $\alpha$.

   **Réponse**

   (a) l'intervalle de confiance de niveau 95% pour la moyenne du Test SAT est

   $$[452,23\ ,\ 469,77]\,.$$

   La marge d'erreur pour un niveau de confiance de 95% est $8,77$ points.
   Ainsi, nous sommes confiants à 95% que la moyenne du Test SAT se situe entre 452,23 et 469,77 points.

   (b) Nous testonsl'hypothèse $H_0$ que la moyenne du Test SAT est de $\mu$ =450 contre l'hypothèse *unilatérale*$H_a: \ \mu > 450$. La statistique de test est

   $$z = \frac{\overline{x} - 450}{\sigma/\sqrt{n}} = 2,46 > z_{5\%} = 1,645\ .$$

   Ainsi, sur la base de cet échantillon, au niveau de signification 5%, nous rejetons $H_0$. Il y a lieu de penser que la moyenne du Test SAT est supérieure à 450 points.

   (c) Le résultat en b) est encore significatif au niveau 1% puisque on a $z = 2,46 > z_{1\%} = 2,33$. Toutefois, comme $z = 2,46 < z_{0,5\%} = 2,58$, nous ne rejetons pas $H_0$ au niveau 0,5%.

(d) Voir notes de cours (tableau) concernant l'erreur de type I et l'erreur de type II.

### Test d'hypothèse sur une proportion

2. On pense que 40% des parents accepteraient une réduction de salaire en échange de meilleures mesures de conciliation *famille-travail*. Un sondage mené auprès d'un échantillon aléatoire de 1503 parents montre que 556 d'entre eux accepteraient une telle diminution.

   **a)** (10 pts) Ce résultat permet-il de conclure que la proportion des parents qui accepteraient cette diminution de salaire est différente de 40% ? Faites le test pour un seuil de 5%. Énnoncez clairement les hypothèses, et présentez toutes les étapes du test.

   **b)** (5 pts) Votre conclusion aurait-elle était la même si vous aviez employé un seuil de 1% ?

**Réponse**

**Étape 1 : Annonce des hypothèses du test** Nous testions

$$H_0 : p = 0{,}40 \quad \text{(La proportion est égale à 40\%)}$$
$$H_1 : p \neq 0{,}40 \quad \text{(La proportion est différente de 40\%, test bilatéral)}$$

**Étape 2 : Conditions d'application** On vérifie si la taille de l'échantillon est suffisante pour utiliser l'approximation normale :

$$np = 1503 \times 0{,}40 = 601{,}2 \geq 5$$
$$n(1-p) = 1503 \times 0{,}60 = 901{,}8 \geq 5$$

Les conditions sont respectées, nous pouvons utiliser un test $Z$ pour une proportion.

**Étape 3 : Statistique de test** La formule de la statistique de test est :

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p(1-p)}{n}}} = \frac{0{,}3699 - 0{,}40}{\sqrt{\frac{0{,}40 \times 0{,}60}{1503}}} = \frac{-0{,}0301}{\sqrt{\frac{0{,}24}{1503}}} = \frac{-0{,}0301}{0{,}012636} \approx -2{,}38$$

**Étape 4 : Région critique (Seuil $\alpha = 0{,}05$)** Pour un test bilatéral au seuil $\alpha = 0{,}05$, la valeur critique $Z_{\alpha/2}$ est obtenue via la table de la loi normale centrée réduite :

$$Z_{0{,}025} = 1{,}96$$

La règle de décision est de rejeter $H_0$ si $|Z| > 1{,}96$ (c'est-à-dire si $Z < -1{,}96$ ou $Z > 1{,}96$).

**Étape 5 : Décision et conclusion** Puisque la valeur calculée $Z_{\text{calc}} = -2{,}38$ est inférieure à $-1{,}96$ (elle se situe dans la région de rejet) :

$$|-2{,}38| > 1{,}96$$

**On rejette l'hypothèse nulle $H_0$.**

**Conclusion :** Au seuil de signification de 5%, les données de ce sondage permettent de conclure que la proportion de parents prêts à accepter une réduction de salaire est significativement différente de 40%.

### b) Test d'hypothèse au seuil de 1%

Pour un seuil de signification de $\alpha = 0{,}01$ en test bilatéral, la nouvelle valeur critique est :

$$Z_{0{,}005} = 2{,}575$$

La région de rejet correspond maintenant à $|Z| > 2{,}575$.

Comparons notre statistique de test calculée ($Z = -2{,}38$) à ce nouveau seuil :

$$|-2{,}38| \leq 2{,}575$$

La valeur se situe cette fois-ci dans la région d'acceptation (ou de non-rejet).

**Conclusion : Non, la conclusion n'aurait pas été la même.** Au seuil de 1%, on ne peut pas rejeter $H_0$. Il n'y aurait pas assez de preuves de modification pour affirmer que la proportion est différente de 40%.

3. Un fabriquant d'automobiles aimerait connaître la proportion de ses clients qui sont insatisfaits des services reçus chez leur concessionnaire local. Le département des relations publiques va enquêter auprès d'un échantillon aléatoire simple de clients et calculer un intervalle de confiance de niveau 99% pour la proportion de clients insatisfaits. À partir d'enquêtes précédentes, ils croient que la proportion sera d'environ 0,2.
   (a) Calculez la taille de l'échantillon nécessaire pour obtenir une marge d'erreur d'environ 0,015.
   (b) Si 10% de l'échantillon se disent insatisfaits, quelle sera la marge d'erreur de l'intervalle de confiance de niveau 99% pour cette taille d'échantillon.

**Réponse** Nous cherchons à estimer une proportion de clients insatisfaits avec un niveau de confiance de 99%. Le niveau de confiance de 99% correspond à un seuil de signification $\alpha = 0,01$. La valeur critique de la loi normale centrée réduite est $z_{\alpha/2} = z_{0{,}005} \approx 2,58$ (ou plus précisément $2,5758$).

(a) **Calcul de la taille de l'échantillon nécessaire**

Ici la proportion observée est $p = 0,2$ (ce qui implique $1 - p = 0,8$). Afin d'avoir une marge d'erreur souhaitée de $ME = 0,015$, on doit sélectionner un échantillon de taille au moins égal à

$$n = \left(\frac{z_{\alpha/2}}{E}\right)^2 \times p(1-p) = \left(\frac{2,576}{0,015}\right)^2 \times 0,2 \times 0,8 = 29492,32 \times 0,16 \approx 4718,77$$

, soit une taille d'au moins **4719 clients**.

(b) Pour une proportion observée est $p = 0,10$ (et donc $1 - p = 0,90$), nous recalculons la marge d'erreur avec la taille d'échantillon trouvée ($n = 4719$).

La marge d'erreur devient :

$$E = z_{\alpha/2} \times \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} = 2,576 \times 0,004367 \approx 0,01125 \; .$$

Si 10% de l'échantillon se disent insatisfaits, la marge d'erreur de l'intervalle de confiance sera d'environ **0,0113** (ou $1,13\%$).

### Test d'indépendence (Khi-deux)

4. Il y a quatre types sanguins chez les humains : O, A, B et AB. Dans une étude faite à partir d'échantillons sanguins de la Banque de sang d'Hawai, les individus sont classifiés selon leur type sanguin et leur groupe ethnique. Les groupes ethniques sont Hawaiens, Hawaiens-blancs, Hawaiens-chinois et blancs. On fait l'hypothèse que les spécimens de la banque de sang constituent des échantillons aléatoires des différents groupes ethniques de la poulation hawaienne.

| Type sanguin | Hawaiens | Hawaiens-blancs | Hawaiens-chinois | blancs |
|---|---|---|---|---|
| O | 1 903 | 4 469 | 2 206 | 53 579 |
| A | 2 490 | 4 671 | 2 368 | 50 008 |
| B | 178 | 606 | 568 | 16 252 |
| AB | 99 | 236 | 243 | 5 001 |

Y a-t-il lieu de conclure que les types sanguins et l'ethnicité sont reliés ? Expliquez de quelle façon vous arrivez à cette conclusion (faites un test de niveau 1% ou moins).

**Réponse** Nous testions :
$H_0$ : Les types sanguins et les groupes ethniques sont des facteurs non liés (indépendants)
vs
$H_a$ : Les types sanguins et les groupes ethniques sont des facteurs liés (dépendants).
Après avoir fait les tableaux de fréquences théorique, nous la claculaons la statistique du test de Khi-deux

$$\chi^2 = \sum \frac{(O-E)^2}{E} = 1077,315$$

qui est largement grand pour rejeter largement l'indépendance peu importe le niveau de signification. Cela que les facteurs « type sanguin » et « groupe ethnique » semblent fortement reliés,

### Corrélation linéaire

5. Un laboratoire teste l'*usure de pneu* après un certain *kilométrage* . Les mesures suivantes ont été obtenues.

| $x_i$ (Kilométrage) | 0 | 4 | 8 | 12 | 16 | 20 | 24 | 28 | 32 |
|---|---|---|---|---|---|---|---|---|---|
| $Y_i$ (Épaisseur) | 394.33 | 329.50 | 291.00 | 255.17 | 229.33 | 204.83 | 179.00 | 163.83 | 150.33 |

$$\sum_{i=1}^{8} x_i = 144, \qquad \sum_{i=1}^{8} x_i^2 = 3\,264, \quad \sum_{i=1}^{9} y_i = 2197.32\ , \quad \sum_{i=1}^{8} y_i^2 = 589\,887.083 \text{ et } \sum_{i=1}^{8} x_i\, y_i = 28\,167,77\ .$$

On ajuste une régression linéaire pour expliquer l'usure en fonction du kilométrage. Les variables sont $X$, le kilométrage (en 10000 km), et $Y$, l'épaisseur de la semelle (en 0.001 cm).

(a) Faites le nuage de points et décrivez la relation entre les deux variables.

(b) Déterminez $\bar{x}$, $\bar{y}$, $s_x$, $s_y$, $r$, le coefficient de corrélation $r$.

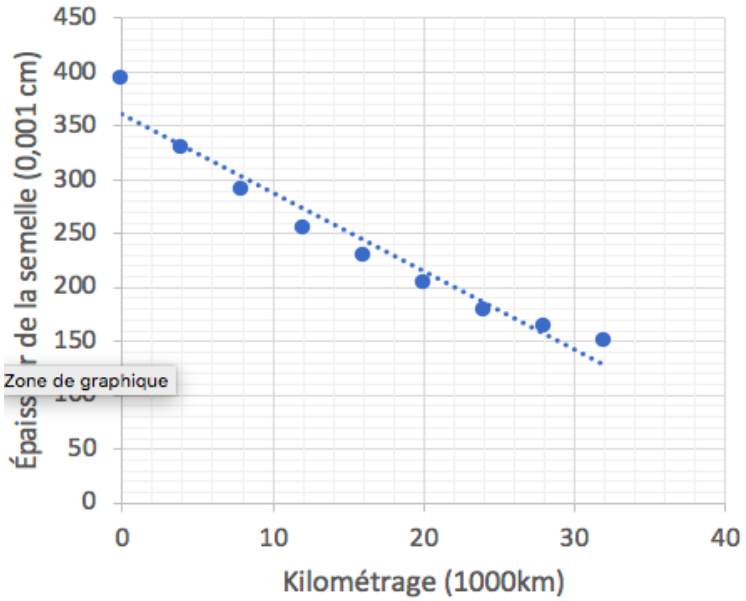
(c) Trouvez l'équation de la droite ajustée (la droite des moindres carrés) $\widehat{y} = a+bx$. Rajoutez la au graphique du nuage de points.

(d) Quel est le coefficient de détermination $r^2$ ? Que signifie-t-il ?

(e) Quelle est votre prévision de l'épaisseur (en 0.001 cm) de la semelle du pneu après 40 kilomètre.

### Réponses

(a) Il suffit de palcer les données $(x_i, y_i)$ dans un repère orthonormé et obtenir le nuage de points (voir gahique en bas)




les points sont bien concentrés autour d'une ligne descendante (presque alignés). Le lien linéaire semble être fort et négatif.

(b) Il suffit d'utiliser le calcul intermédiaire ainsi que les formules pour trouver :

$$\bar{x} = \frac{1}{9}\sum_{i=1}^{9} x_i = 16,\ \bar{y} = \frac{1}{9}\sum_{i=1}^{9} y_i = 244,1466,$$

$$s_x = \sqrt{\frac{1}{8}\Big[\sum_{i=1}^{9} x_i^2 - 9\bar{x}^2\Big]} = 10,944,\ s_y = \sqrt{\frac{1}{8}\Big[\sum_{i=1}^{9} y_i^2 - 9\bar{y}^2\Big]} = 81,715.$$

$$r = \frac{\sum_{i=1}^{9} x_i y_i - n\bar{x}\bar{y}}{(8)s_x s_y} = -0,976\ .$$

(c) Les paramètres $a$ et $b$ dans notre modèle de régression simple sont

$$b = r \cdot \frac{s_y}{s_x} = -7,28 \text{ et } a = \bar{y} - (-7,28) = 360,64\,\bar{x}.$$

Soit une droite de régression d'équation

$$y = -7,28x + 360.64$$

Il faut tracer cette droite avec le nuage de points (dans la même figure).

(d) Rappelons que c'est le carré du coefficient de corrélation

$$r^2 = 95.26\%$$

Il signifie qu'environ 95% de la variabilité de l'usure de pneus est expliquée par le kilométrage selon le modèle linéaire. Et donc, environ 5% des données de $Y$ sont expliquées par d'autres facteurs, autre que le modèle linéaire.

(e) La prévision moyenne de l'épaisseur (en 0.001 cm) de la semelle du pneu après 40 kilomètre est

$$\widehat{y} = -7.28(40) + 360,64 = 68,8\ .$$